# 广义隐晦信息的理解与检测：语用、修辞、编码语言及多模态研究综述

**摘要：** 隐晦信息的理解不仅要求推断字面之外的含义，还可能涉及交际意图、立场及危害判断。会话含意、隐喻、反讽和狗哨、谐音等编码表达依赖语境与社群知识；隐晦有害内容进一步涉及攻击对象和规范性判断，而图文组合可能形成单一模态难以识别的意义或风险。围绕这些问题，相关研究形成了语用与修辞理解、编码语言与动态词义分析、语境化有害内容检测以及多模态意义与安全评估等方向，并发展出概率语用建模、监督与对比学习、检索增强、多模态融合及大模型安全对齐等方法。然而，不同研究的预测目标、标注依据、可用信息与评价指标并不相同，实验分数难以直接反映模型是否真正理解隐含意义。本文梳理上述领域的核心任务、数据资源与方法进展，区分表达识别、意义解释、有害判断和安全回应，并重点比较训练与测试信息预算、标注真值和评价协议。结合现有论文的正反实验结果，本文归纳三项具有条件性的跨领域认识：词典、候选意义与检索先验限定开放语义能力的可测范围；解释生成或解释监督的性能收益不能直接证明解释忠实；安全策略变化可能使有害漏检与正常请求误拒呈现不同趋势。最后，讨论标注分歧、数据捷径、跨模态依赖和版本差异对研究结论的影响，提出受控对照、反事实验证与双侧安全评价的后续研究方向。

**关键词：** 隐晦信息；计算语用；修辞理解；编码语言；隐式有害内容；多模态风险；Ground Truth；评价可靠性

## 1 引言

### 1.1 背景与研究动机




**图1｜广义隐晦信息研究地图。** 上层区分语用、修辞、社群编码和跨模态意义等表达/意义机制；规范性危害与安全回应属于另一个分析层。T1–T6 是可交叉的评价任务，X/G/E 是各实验必须记录的证据条件。图示不表示认知或算法的因果顺序。

非“无语境与有语境”的简单二分，指示词和指称也会依赖语境；本稿更关心一项任务的输出究竟是字面约定内容，还是特定交际条件支持的额外意义、行动或立场。

以一句表面疑问“你能把窗户关上吗？”为例，系统可以识别其疑问句形式，亦可以在具体生活情境中将其解释为间接请求。前者是句法/字面层的识别，后者涉及言语行为。再如“真是准时啊”在迟到的会话语境中可能表达反讽，而在实际准点的语境中也可能是真诚评价。这里的“可能”十分重要：脱离共同前提、说话者关系和明确的人工解释任务，不能给所有使用者强加唯一的心理意图。

### 工作性定义与概念边界

本文采用以下工作性定义：**广义隐晦信息是指在语言或多模态交际中，其研究关注的意义、评价立场或交际功能不能仅由直接字面表达充分确定，因而需要额外的语境、语用推理、修辞映射、社群约定、编码形式或模态间关系才能获得可信解释的信息。**该定义旨在组织不同研究谱系的任务边界，不是主张这些文献已经采用共同的“隐晦信息”官方标签体系。

必须区分的概念如下：

详见表1：概念与任务边界。表1将概念的性质、意图隐藏和有害性分开记录；这是工作性分类，经验上允许交叉。

**表1｜概念与任务边界**

| 概念 | 判定核心 | 必须非字面? | 必须故意隐藏? | 必然有害? | 反例或交叉 |
|---|---|---|---|---|---|
| 隐含意义 | 目标解释不由表面断言充分给出 | 否 | 否 | 否 | 间接请求可无害 |
| 细微表达 | 线索稀少、强度低或不显著 | 否 | 否 | 否 | 难察觉不等于隐含 |
| 修辞/非字面 | 字面与预期解读存在隐喻、反讽等关系 | 依任务定义 | 否 | 否 | 艺术隐喻可无害 |
| 社群编码/狗哨 | 特定群体约定的义项；狗哨涉及受众差异 | 否 | 不一律 | 否 | 普通社群缩略词可无害 |
| 形式伪装 | 同音、拼写或字符变化 | 否 | 不一律 | 否 | 普通错别字未必有规避意图 |
| 语境依赖 | 解释受场景、会话、社群或时间影响 | 否 | 否 | 否 | 指示词消歧不自动纳入 |
| 有害性 | 指定政策、目标与受众下的规范性判断 | 否 | 否 | 是目标标签 | 显性辱骂也可有害 |

**表注**。 这是本文工作性分析维度，不是已验证的认知因果模型。术语与语用任务参见 [1][7]；“有害”需标明政策和标注主体。

“Dog Whistle”在本文中属于具有受众知识差异或多重受众解释机制的重要编码现象，但**不是所有编码语言的同义词**；是否存在有意双层沟通需看具体研究证据。[4]研究已知狗哨编码义的语境使用判定，而[5]研究词项发现，两者即使包含相似词汇也不具有相同预测标签。[7]则展示了中文编码策略和应用任务的关联，但出现编码并不自动代表仇恨或违规。

这些概念**可以相交但不能互为定义**。一段表达可能既是反讽又具有编码社群义，但无害；也可能没有任何隐喻或暗语，却借上下文表达隐含的群体偏见。另一方面，单纯视觉不完整或文本指代歧义，如果没有明确的隐含/非字面/编码/风险研究目标，应作为相邻语境理解而不是核心收录对象。

**包含与排除的四个判定例**。 无害隐喻若研究源目标映射，仍是T1/T2核心；只把谐音字符还原为常用字而不涉及社群编码义的任务是邻接信息处理；普通图文有害Meme可以属于T4，却不自动具备T5严格图、文单独Safe而组合Unsafe的标签；纯显式危险请求的泛化RLHF不作为隐晦意义核心方法，但直接研究

组合风险后的误拒与帮助性时可作为相邻T6。纳入的判断对象是**预测目标、语义机制及其真值**，而非数据中是否出现“图像”“情绪”或“安全”一词。

## 2.2 五轴任务与证据记录框架

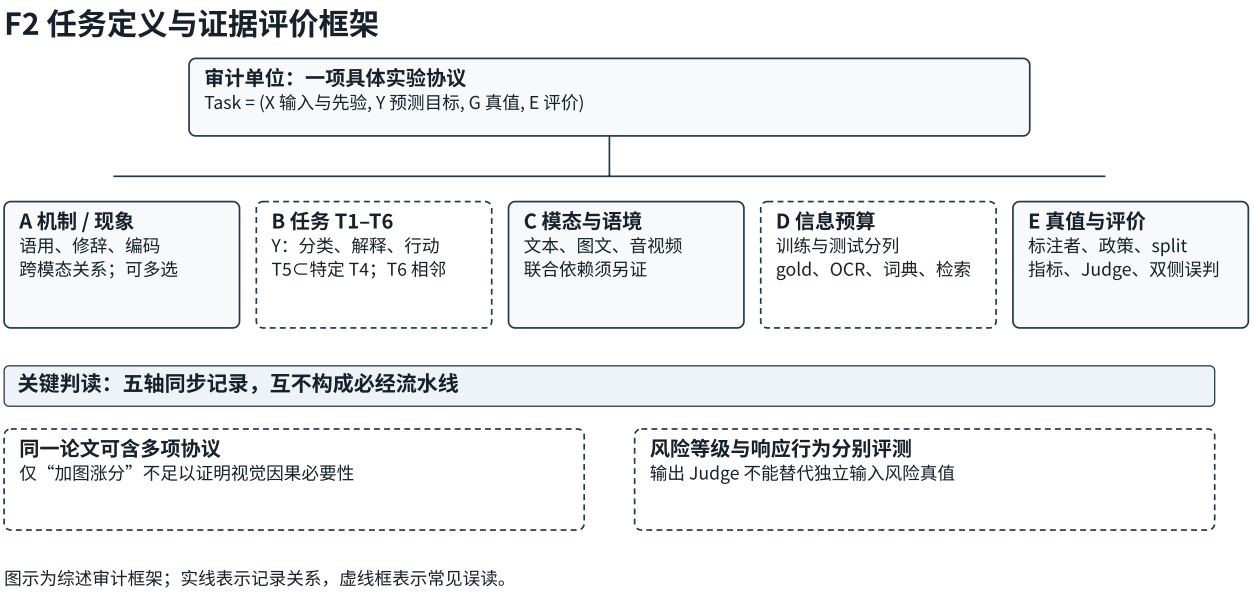



**图2｜任务定义与证据评价框架。** 五轴共同描述一项具体评测协议：表达机制、预测任务、模态/语境、训练与测试信息预算、Ground Truth 与评价。实线是同步记录关系，虚线框提示常见误读；T5 是 T4 的特定联合条件，T6 是相邻的行为评价。

若以“隐喻、仇恨、VLM、DPO”并列为一级类别，会把表达机制、风险类别、模型类型和训练方法混在同一个层次。为避免此问题，本文以五个**分析上应分离、但经验上可能相互影响**的维度（图2）记录具体实验协议，并将其作为后文比较论文的共同依据。它们不是数学意义上必须统计独立的变量。

**A. 表达与意义机制**。记录实例涉及会话含意、间接言语行为、隐喻/反讽/委婉语、编码/狗哨、形式伪装或跨模态组合关系。它描述*为什么需要超出字面的语义证据*；群体立场是T3可能判断的语用属性，歧视/危害为T4的规范性评价对象，安全回应属T6，**不把三者冒充语言意义机制**。

**B. 研究预测目标**。记录模型究竟在判定现象存在、生成/选择解释、判断交际功能、给出有害性类别，还是生成安全回应；同一个机制可对应多个不同任务，同一任务也可能利用不同机制。

**C. 输入模态与情境条件**。记录文本、图文、多图、音视频、对话轮次、社群身份和时间信息，以及分组/配对方式。模态个数和模态之间是否构成不可替代语义关系，是两个不同的问题。

**D. 训练/测试可用信息预算**。严格区分原始可观测文本/图像/音频，与作者提供的词典释义、gold情绪、源/目标概念、外部检索、OCR和Oracle caption等辅助内容。需分别记录这些字段是在训练时、测试推理时还是仅供评测者使用；提供gold辅助信息与模型自行预测辅助属性不是同等信息预算。

**E. Ground Truth与证据协议**。记录标注单位、标注者、指南、分歧、train/test拆分、真实外部时间/社群分布，以及衡量选择、开放解释或输出行为的指标。两篇论文同样报告F1，若标签、样本或指标平均方式不同，就不能依数值高低直接推导方法优劣。

## 2.3 计算语用与操作性Ground Truth

计算语用研究为上述问题提供了可检验的建模和评价方式。概率语用模型通常通过说话者—听者之间对表达选择及潜在意义的假设进行推断，但模型中的先验、候选空间与语境构造会直接决定其适用边界。[3]进一步将修辞策略纳入RSA式语用推断；其研究目标是策略条件下的意义判断而非有害内容分类。[8]通过固定问句、改变语境的选择任务评价会话含意；[29]利用视觉情境及候选行动评价间接表达的适宜解释。这些研究提供的是**在特定构造任务和候选空间中的模型行为证据**，不应被解释为真实说话者内心意图已被直接观察或完全恢复。

上述任务虽然都与“语用”有关，却没有共同的心理意图金标。DRInQ在给定五个候选含意时评估语境化选择，并以人类共识构造测试答案；VAGUE在视觉语境和四个候选行动中评估模型的适宜判断；$(RSA)^2$依赖定义好的策略、先验与候选意义空间。其Accuracy或候选概率只支撑**各自协议下的选择或拟合表现**，不能据此判定真实发话者意图已被完整恢复，或直接与开放式意义解释的准确率合并。

## 2.4 T1–T6与Task = $(X, Y, G, E)$：任务目标与可观测标签

表2：T1–T6 的输入、输出与 Ground Truth按 X/Y/G/E 给出六类任务的典型标注与评价限制。

**表2｜T1–T6 的任务层级、输入与 Ground Truth**

| 任务及与其他任务的关系 | X：原始输入／测试辅助 | Y：预测目标 | G：标签及来源 | E：评价及不能推断的内容 | 代表 |
|---|---|---|---|---|---|
| T1 表达识别（形式层） | 文本/图文，现象定义；部分数据含OCR | 现象存在、类别或片段 | 人工现象标签／部分合成标注 | Macro-F1或span指标；不证明实例意义已恢复 | [7][12] |
| T2 意义恢复（语义层） | 上下文、候选义或源／目标概念；候选常预先给定 | 候选意义、蕴含关系或开放解释 | 人审意义／构造选项经核验／参考解释 | 候选准确率、解释匹配与人评各不同；不等于说话者心理意图 | [3][22] |
| T3 语用功能（交际层） | 对话轮次/视觉场景及候选行动 | 间接请求、含意、立场或行动 | DRInQ的人类共识；VAGUE的构造行动经人工筛选（并非同类GT） | MCQ Acc/人审；候选上限与负项难度均需列出 | [8][29] |
| T4 规范危害（风险层） | 文本/多模态内容、目标、社会语境、适用政策 | 危害类别/程度 | 人工规范判断、政策或生成代理标签；分歧需保留 | 双侧错误/类别召回；不能从修辞识别自动推断危害 | [2][6] |
| T5 联合模态风险（**T4的条件性特例**） | 图像I/文本T/联合(I,T)及环境；应报告分别输入条件 | 联合输入的风险类别/等级 | 联合GT；严格S-S-U还需要单图Safe、单文Safe、联合Unsafe的可比标签 | 分组F1/联合错判及反事实对照；**图文并置≠S-S-U** | [36][24] |
| T6 安全回应（**独立相邻行为层**） | 风险请求、回应政策、模型的可用场景 | 拒答、警示、帮助、转介或实际行动 | 响应Judge、人审或安全/帮助双维判定，**不是T4输入GT** | 危险侧不安全回答、正常侧误拒和帮助性分报；不推断模型内在$P_{\text{in}}$ | [38][35] |

**表注**。 Task = $(X, Y, G, E)$是本综述单实验协议的记录式：至少分别列`X_raw / X_train_aux / X_test_aux / G_source / E_denominator / Judge`。T1–T3可共现，T5在本文操作性定义下是满足联合证据条件的T4特殊设定，T6是回应行为研究而非T4→T5→T6必经流水线。跨任务F1/Accuracy/ASR不能组成一个统一SOTA排名。

T1–T6不是必须逐级运行的算法流水线。例如，有害性分类器可能直接从原始内容估计T4标签，未显式输出T2或T3解释；而纯反讽研究可能只解决T1/T2，无需转向风险判断。任务之间存在概念联系，但只有同时给出独立中间标签和控制实验，才能进一步声称某种中间语义表征**因果促进**了有害性判断。

这里还需注意T5的特殊地位。对于一对模态 $I, T$ 和语境 $C$，可用 $G(I, T \mid C)$ 表示在指定政策下的**联合输入风险标签**；$G(I, \varnothing \mid C)$ 与 $G(\varnothing, T \mid C)$ 表示在人类标注协议允许时的单模态条件判断。研究可讨论具有不同形式的联合关系风险，但**严格证明某项危险判断必须依赖两种模态**，还需人审的单模态/联合风

险标签、对照或精心控制的配对干预；单纯去掉图片后分数降低不足以证明模型掌握了正确关系。双方单独安全、组合危险（S-S-U）是尤其明确的联合协同模式，却只是T5的更窄子类，且并非所有数据都拥有同协议的三条件人工GT。普通Hateful Meme图文分类器即使同时读取图与文，也不自动意味着其数据满足这种严格标签条件。

## 2.5 纳入/排除示例与解释、危害及响应的不同GT

前文任务的另一个关键界限体现在Ground Truth来源。对同一个被标为含有隐喻的句子，源域标注者可能给出“像洪水一样”的修辞标签；危害评审者则还需判断其中是否出现群体贬低、说话者是在赞同还是批评、语境是否为引用或社群内部自述。修辞检测与有害性判断的Ground Truth并不天然一致。[9]中的人工监督主要针对隐喻源域，而非每条语句的独立“非人化/仇恨成立”标签，因此不宜用其修辞准确率证明模型可靠识别了歧视性意图。

[6]进一步给出了真实社交平台中的规范性评价案例。其研究对象既包含可能的隐式歧视也包含显性讨论，并未为每条实例提供独立显性/隐性标签；9位受过专门培训的高年级本科研究志愿者参与标注，每条目标句由3人参考邻近语境作出判断；作者报告Fleiss's κ为0.25。论文提供社群内部求助、反用和引用引发分歧或误报的质性案例，但缺少在同一模型和相同数据划分下比较“目标句单独输入”与“目标句加语境”的控制消融。因此，不能将该论文表述为已定量证明“上下文使模型更准确”。其论文称总量2,400，但正例242与负例2,160相加为2,402；该算术差异未由原始CSV核实，因此不能直接制作精确类别比例图，后续须遵守数据使用/自动审核用途的许可限制。

在多模态生成系统中，这种区分还延伸到模型行为。可把输入风险人审标签记为 $G_{\text{in}}$，模型可见的输入风险预测记为 $P_{\text{in}}$，实际输出的行为类型记为 $R_{\text{beh}}$，输出是否安全且帮助用户完成合理任务记为 $Q_{\text{out}}$。四者不是同一种Ground Truth：系统可以把危险输入识别正确，却仍给出危险指导；也可以把无害输入错误拒绝；甚至可能因保守拒答而提高某一安全评估分数，同时降低帮助性。若模型只生成最终回答而不显式报告风险分类，$P_{\text{in}}$ 可能并不可观测，不能仅由拒答行为反推其内部识别过程。[38]与[35]分别对安全侧误拒和后训练中的风险感知与回应行为提供不同任务证据。

**纳入与排除的操作性判断**。无害反讽、约定编码义的实例使用和需要语境的间接言语行为，即使没有有害标签，仍可作为T1–T3的核心对象；带独立规范性风险GT的隐晦歧视文本属于T4。若图文风险结论确实针对关系或联合证据展开，并能说明GT或受控条件，则可在T5讨论；只含图片和文本的普通二分类器并不自动满足严格联合依赖。相反，普通指示词消歧、纯字符恢复、一般OCR、纯隐写和不涉及隐含机制的一般显式危险输入仅作为邻接背景，除非研究问题具体关联本文的隐含意义或联合模态风险。仅评估拒答或回答质量的工作归为相邻T6，不冒充T4/T5输入风险真值。

### 本章小结

本章建立了两项贯穿全文的约定。其一，广义隐晦信息是组织研究的工作性范围，隐含、修辞、编码、细微和有害性是相交而不等同的属性；文献是否属于核心研究，需要根据其操作性任务和真实标签决定。其二，论文比较必须保留表达机制、预测任务、输入与测试信息、Ground Truth及评价协议的多轴信息。只有这样，后文才能分别讨论文本修辞、社群编码、有害性以及多模态关系，并在第8章横向对比方法族而不制造虚假的统一SOTA排序。

### 3.4 测试形式的边界

同一“理解”标题下，测量对象可能相距很远。DRInQ 的五选一准确率要求在给定候选中选出共识含义；$(RSA)^2$ 的 PragMega+ 报告正确候选获得的平均概率；SemanticQA 的解释任务比较生成文本与参考解释的 METEOR/BERTScore，联合任务还把片段抽取是否正确计入综合分；反问线性探针的 AUROC 则只显示隐藏状态携带可供线性分类的信息。这些量的分母、随机基线、参考答案空间及信息预算不同，不能把数值放进统一排行榜。 [8][3][11][14]

尤需警惕“解释流畅”替代“解释忠实”。已有项目卡记录SemanticQA一个公开路径会在同一次提示中请求抽取与解释；由于固定源码版本尚未给出，本文只将它作为复核线索。联合分数下降也可能来自抽取边界、格式与参考解释覆盖不足，不能自动认定独立步骤的错误传播。[14] 的探针即便跨域保持分类能力，也未发现稳定唯一的反问表示方向；[10] 的二维可视化和局部词扰动同样不能直接呈现模型内部语用推理。更可信的比较需要同一表达在不同语境下的配对判断，分别给出字面与非字面负例，并报告候选意义、对象和立场的独立标注。这里的后两项属于综述提出的评价要求，而非上述论文已完成的统一实验。[11][14][10]

### 3.5 从修辞到社群编码的桥梁

委婉表达可以经由替代词、谐音或跨语言变形固定为社群约定，隐喻也可能成为群体内部识别信号；但两者没有必然包含关系。CodedLang [7] 在真实中文评论中标注编码片段和主要编码方式，其“Newspaper Eat”一例需要音系与翻译链的逆推，不能仅以传统隐喻源目标映射说明。Silent Signals [4]则预给狗哨词项与编码定义，再判断具体上下文是否用了该义；一个表达在其他语境仍可按普通义使用。这些材料共同把研究问题从修辞类型扩展到受众共享知识、实例多义与词义变化。 [7][4]

由此进入第4章时，需要先问研究者究竟是在发现一种表达、消歧其一次使用、恢复所指意义，还是评价其危害。反讽、隐喻、委婉和编码都可能承载无害交流；无论形式多隐晦，仅凭形式标签都不能推出交际者有规避审核的目的。编码表达与有害性之间还隔着目标、立场及规范判断，这一层将在第5章讨论。[7][4][31]

## 4 编码语言、狗哨与动态词义

### 4.1 编码语言、狗哨与形音变体




**图3｜编码语言任务关系。** 词项发现、实例义消歧、意义恢复和有害性判断分别对应不同输入先验与真值；虚线仅为可分析的关系，不表示既有研究已训练并验证统一端到端系统。详见表3。

**表3｜编码语言方法：不同先验、GT和指标分母**

| 论文/任务 | 已知先验与额外信息（训练／测试） | G及计数单位 | 实际方法与正面作用 | 评价分母／开放边界 |
|---|---|---|---|---|
| Silent Signals [4] | **测试给定**已知狗哨词及编码义定义 | **instance**：该语境是否使用编码义；论文模型筛阳主集16,550与400正例人工审查不等价 | LLM上下文用义消歧；抽样正例人工Precision约85.3%（扩展可接受义约89.4%，均按作者抽审口径） | 非开放词项发现；发布说明曾提示版本差异，本轮未固定历史README，撤去发布版精确计数并记O，不能写成主集逐条人审或整体Recall |
| FETCH! [5] | 已知参考词典约20%种子+可检索社群语料，回收**其余既有词条** | **type/root**词项回收；P分母为输出候选，DPR分母为语料出现的留出参考根词，按根词去重 | 正式Table4 Balanced PREDICT P/DPR/F0.5=14.81/1.65/5.70%；Table5同场景DIRECT Llama2-13B=2.97/13.58/3.52% | 正式§3.4/Tables4–5：F0.5用P与DPR；两管线非同模型／等输出预算；词典type回收不是时间外新义 |
| FA-Net [31] | 源域有标签；目标域**未标注**文本参与适应；预先给定候选词位置/类别（所审类别33/9/12） | 固定类别目标义映射 | 域内/跨域相似伪正对+熵约束，作者报告协议内Acc@k改善 | 不是完全目标域不可见、也不是开放义生成；伪正对错配率未独立人审 |
| Coded Lang [7] | 中文评论及编码现象；词面/策略标签 | **span/策略/评论评分**为三个不同任务 | 7,744评论、900编码正例（作者协议）；可支持中文编码检测和策略分类 | 星级不等于目标隐义或毒性GT；正例选择密度不能视为整个平台自然流行率 |
| SeTox [16] | **测试时**在线搜索语境；训练工具轨迹SFT；`model-unknown`相对于指定基座 | 624新词测试：Unsafe490/Safe134；known319/unknown305 | 检索与工具监督用于新词毒性判断，作者报告相应协议改善 | DR/KDR/UDR为Unsafe子集检测率；Acc/F1含两类；搜索快照及严格未来时间外新词仍未核 |

**表注。** **词项type发现→实例义消歧→候选义分类→安全判断**是分析关系，**不是五篇论文共享已验证端到端系统**。FETCH数字是正式论文P级报告，未重跑列表／去重；未固定的README发布差异只记O，不保留精确整数。

编码语言的计算问题不能由“含有生僻词”概括。表达者可能改变读音、字形、语言或符号组合，使表面形式与交际中预期的意义之间出现需要逆向恢复的距离；这种转换也可能借助社群习惯而非纯形式规则。CodedLang [7]以中文在线评论为对象，在 7,744 条评论中标注编码片段，其中 900 条被判有编码表达。其七类主要策略包括两类谐音、拼音等语音替代、表情符号、字形替代、跨语言语音编码及密码式表达。分类法描述“怎样被编码”，并不自动回答“为何编码”或“是否有害”。作者由种子、词典匹配和人工扩展收集低频样例，因而构造语料的正类比例与七类分布都不能当作整个中文互联网的自然发生率。[7]

狗哨语言在编码表达中强调受众差异：同一表面词对一般读者可保持普通解释，对熟悉特定社群约定者可能传递次级意义。Silent Signals [4]研究的正是这种已知表达在具体句子中的普通义/编码义消歧。这里“狗哨”作为研究对象并不要求每个实际使用者都可被确认有恶意；对个别语句的说话者意图仍需语境与独立证据。形音变体与狗哨也不是同义：前者可仅为表面变换，后者的关键在于受众共享的第二解释。有些无害的评论编码只是绕开直白评价或营造幽默，有些政治或歧视性表达则可能同时具备编码和社会风险。综述据此把形式机制、受众条件与有害判断分别记录。 [4][7]

P023 的评测进一步展示这一区分。论文 Table 2 考察是否存在编码表达，Table 3 考察评论级策略多标签，Table 4 用原始、遮蔽和词典解码后的评论预测商家星级。识别出某类策略不保证恢复其具体评价意义；星级也只是平台原始字段，既非逐例“解码正确”真值，更非危害标签。作者在同批已编码评论上比较遮蔽与解码，能够诊断形式变化对下游任务的影响，但不同编码与非编码评论的性能差异还混有话题、评论长度和星级分布。 [7]

## 4.2 已知编码词的实例消歧

给定词典条目时，研究问题不再是“找到这个词”，而是“本次出现是否用了词典给出的编码义”。Silent Signals 输入目标词、编码义定义及上下文，让模型在几种问法与定义下重复判断，再用输出一致性筛选高置信实例。方法实质上把社群先验作为显式输入，利用语言模型的语境判断扩充可用语料；它没有训练一个从零发明狗哨含义的解码器。作者既构建人工小评测集，也给出大规模模型筛选的正例主集；两者的 Ground Truth 质量和样本分母不同。论文报告的主集为16,550条模型筛阳数据；此前所见发布说明提示版本口径差异，但本轮未固定其README历史版本，故撤去发布版精确整数，差异仅记O，亦不把论文主集称作逐条人工核实的金标。 [4]

这种设置的优势是把多义词放回具体上下文，比“词典命中即风险”更接近真实判别；局限是定义本身可能带偏模型，普通义、引述、批评或戏仿都需要负例检验。论文小型人工检测、消歧评测与自动高置信抽样采用不同的提示与评分条件，不能把其中一次 Precision 直接当成整个自动标注流程的正确率，更不能据部分人机对照断言语言模型普遍优于懂社群语境的读者。综述判断是：已知定义下的实例消歧为开放词义研究提供了必要组件，但它尚未解决词典未收录的新表达和意义随时间漂移的问题。 [4]

## 4.3 词项发现与开放词义

当词项未知，输出的单位就从句子中的二元用义变成候选表达类型。FETCH! [5]以部分已知狗哨作为种子，用共同语境的句向量和近邻检索取得候选，再由模型过滤、抽取关键词；论文还考察直接让语言模型提词的基线。EarShot 等流程优化的是候选词项的发现与排序，指标包括词项 Precision、发现比例和偏重 Precision 的 F0.5，既非逐句普通义/编码义消歧，也非目标词义解释准确率。 [5]

**作者正式版指标实例（P）**。 §3.4及Tables 4–5以词项而非帖子计分：Precision的分母是系统输出候选词项，命中参考根词或其表面变体算正例；DPR的分母是该场景语料中实际出现的留出参考根词，按根词去重；F0.5由Precision和DPR计算。Table 4的Balanced场景RoBERTa R4＋KeyBERT为P=14.81%、DPR=1.65%、F0.5=5.70%；Table 5同场景DIRECT Llama2-13B为2.97%、13.58%、3.52%。同场景的精度／发现比例取舍不能化约为全面更强；两管线模型、筛选、输出规模亦不等预算。它们是**已收录词典type回收**的作者结果，不是逐句用义正确率或真正词典外未来新义准确率。本轮核了正式表和定义，未重跑预测列表／去重实现。

该研究的重要评测边界是“未见”的定义。主实验把已存在于参考狗哨词典的词项约 20% 用作种子，约 80% 暂不向系统提供，检验能否从语料中回收；这构成词典留出，不构成现实世界先按时间封存、后来才出现的新狗哨。基准中的词项出现多由正则命中确认，无法逐句排除普通义或引用；词典外真正新词还可能被自动指标误算为错误。作者在附录给出若干词典外候选的质性分析，但它们没有形成完整人工标注的开放世界测试集。因而，论文证明了一个有用的种子检索研究设置，并报告在三种稀疏度条件下的实验结果；它尚未证明现实时间外新义已被可靠发现。 [5]

与 Silent Signals 对照可见，前者在“未知词项”上承担更困难的候选搜索，后者在“已知词义”上提供更清楚的实例判断。两者不宜按 F0.5 与消歧 F1 排名。若要检验真实演化，未来数据需记录词项首次出现与定义形成时间、社群边界、语境中普通义负例及人工确认的词典外用例，并保证模型训练和外部检索只接触测试时间以前的信息。这是综述提出的评价条件，非 FETCH! 已完成的时间外实验。 [4][5]

### 4.6 从编码义到危害判断的桥梁

本章四项任务可以概括为不同的输入输出契约：词项发现问“哪些类型值得检查”，实例消歧问“此处是否为编码义”，意义解码问“它对应哪个解释”，危害判断问“在给定对象、立场和规范下是否有害”。FETCH!、Silent Signals、FA-Net、SeTox 分别为这些问题提供代表实验，却没有在同一批样本、同一预算与共享金标上组成经过验证的端到端流水线。CodedLang 的评论星级还展示：即使有解码形式，下游评价也不会自动改进。 [4][5][31][16][7]

因此，编码系统的错误需要按层定位。词项型检测容易漏掉真正新形式，也可能把普通义词项误报为狗哨；固定候选解码可能排除真实新义；搜索增强系统可能得到过时或不可靠的证据；即便前三层都正确，引用他人说法、批评歧视或社群内部自述仍可能改变危害判断。第5章由此把目标群体、说话者立场、话语功能和规范性 Ground Truth 置于中心，讨论隐晦有害内容，而不把“编码”作为有害性的替代标签。 [4][31][16][6]

## 5 语境化隐晦有害内容检测

### 5.1 隐式仇恨、隐性毒性、刻板印象与非人化

表4：语境化有害内容的 Ground Truth汇总主要标注对象、语境来源与限制。

**表4｜语境化有害内容：代表性 Ground Truth 与规范边界**

| 论文 | G：样本/标注对象与来源 | 语境、监督与输出 | 可支持的结论及边界 |
|---|---|---|---|
| Latent Hatred [17] | 隐式仇恨标签及针对性类别（人审） | 标注隐含陈述，供解释/分类研究 | 隐含陈述并非观察到作者全部真实意图 |
| ToxiGen [2] | 大规模对抗式生成文本，标签由提示策略/人审子集构造 | 用于压力测试与分类 | 缺显性词面不等于逐句隐义GT；对抗难度与人工有害标签一致性可能发生张力，不能以生成提示替代人工共识 |
| When People are Floods [9] | **隐喻源域**人审GT | 移民语境、隐喻域解释 | 只有隐喻人审，不可称每例具有独立“非人化”和“仇恨”标签 |
| Sheep's Skin [21] | 显性有害请求改写为隐喻并人审核意图保持 | 合成配对与审核提示协议 | 检测器漏检只支持特定改写/提示条件；负侧误报并未全面控制 |
| AUTALIC [6] | 9名受训高年级本科研究志愿者、每例3人；原始标签`-1/0/1`中`-1`（不相关/上下文不足）先合入0再多数票 | 邻近真实社群话语；个体分歧与多数票二分类 | 作者总数2,400与242+2,160=2,402存在2条差；Fleiss κ=0.25；无同样本删语境因果消融；最终CSV数尚未核 |

**表注**。 本表按**GT类型选取代表研究**，不是第5章所有方法清单；ImpCon、SMARTER、RV-HATE、CADET见正文§5.2–5.5。AUTALIC仅允许符合其授权条件的研究用途，对商业及自动内容审核开发/部署有额外许可要求；在获取并核读原始CSV之前不自行“修正”论文统计。

“隐式有害”首先是标注目标的问题，而非缺少禁忌词的纯形式问题。某句可在没有粗口时传播群体刻板印象或非人化比拟；另一句含有污名化词语，却可能是受害者自述、引述后反驳或求助。隐式仇恨、广义毒性、歧视性措辞、刻板印象和非人化并非一套可互换的金标：它们在攻击对象、所需上下文、规范阈值与允许的“不确定”状态上均可能不同。以“无显性辱词”筛样，是有用的困难例代理条件，却不是每条样本都存在复杂语用含意的证明。 [2][17][6]

较早的 Latent Hatred [17]把隐式仇恨的形式类别与隐含陈述纳入基准讨论，为“分类标签以外还需解释攻击何在”提供基础研究背景；本项目对该篇目前只有官方出版信息及索引级材料，故不从其题名推写具体训练损失或实验数值。ToxiGen [2]则从数据稀缺与虚假相关出发：按目标群体与有害/无害提示组织生成示例，并在解码阶段把语言流畅度与现有分类器的错误方向结合，形成对抗难例。论文报告约 27.4 万条机器生成文本，且通过人工子集、人写外部测试及微调前后对照检验效用（§3–5、Tables 2/4）。这支持“受控生成可以丰富指定检测器的压力测试，并在所测外部数据上改善 AUC”；生成时的提示标签仍是代理，论文以词表缺失衡量的“隐式”也不能代替逐句的隐含命题或说话者立场金标。 [2]

AUTALIC [6]把这一问题推进到真实社群语境。它以有关自闭症群体的目标句及相邻句为标注对象，评价是否表达歧视性态度，而非把所有句子限定为“隐式仇恨”；某些显性措辞和医学化称谓也在语料中。相较生成语料，真实讨论让引用、回收词汇、群体内部谈话与求助更突出，却同样不能把最终多数票当作可直接观察的作者心理意图。两种数据路径分别加强了可控困难样本和社会语境的覆盖，所回答的问题不同，不能据 AUC 或 F1 横排为同一任务的优劣。 [6][2]

## 5.2 从分类到隐含陈述、对象与解释

如果目标不仅是输出有害/无害标签，还希望说明攻击对象与隐含命题，额外监督必须交代来自哪里。ImpCon [18]利用部分训练样本已有的 implied statements：把有害原文与隐含陈述配对，其他样本则使用词汇增强，再以分类交叉熵和实例对比目标联合训练。其跨数据集实验报告相对普通分类与纯词汇增强的收益。机制假说是让模型表征靠近较稳定的含义层，但并非每条样本都有人工隐含解释；若配对文本不保留原有立场，或对比批次中存在语义相同的“负例”，对齐损失也可能引入噪声。原文一解释向量更接近是训练目标的结果，尚不是解释忠实或真实意图复原的独立验证。 [18]

SMARTER [19]转向低资源解释式分类。作者先利用 HateCOT 等先前解释资源做辅助监督微调，再在目标任务少量带标签样本上生成正误回答与解释，使用 DPO 使模型偏好较合适的标签一解释组合，最后尝试跨模型解释 refinement。DPO 优化的是相对参考策略的回答偏好，不是单独验证每条解释与真实推理路径一致；“只用部分目标任务数据”也不等于前期解释资源、生成计算与模型权重都被省去。论文 Table 1、Fig. 3 和 Table 5 记录不同样本预算下的分类及消融，支持其特定协议的低资源效果，但模型之间的交换收益并不对称，也不能将宏 F1 的改善全部归因于 DPO 或解释质量。 [19]

RV-HATE [20]采取不同思路：簇代表对比训练、NER/语言模型辅助的目标标记、离群样本处理与困难负例构成四个分类模块，最后用 PPO 在每个数据集上寻找四组固定 logit 权重。目标标记可帮助模型关注潜在群体，但被 NER 找出的实体未必就是被攻击者；删除簇内远点也可能删除少见而真实的隐晦样本。论文 Table 1–3 的分类结果支持所报设置下模块组合的总体效果，并未把“识别对象”“恢复隐含命题”“解释忠实”逐一独立测量。本轮在附录A：固定公开源码已固定所审公开`ppo_eval.py`：该入口用test_data构造包含标签的PPO环境并以同一test_data评价优化权重。**这只证明特定公开源码路径存在验证隔离风险，不证明论文正式结果由该入口或该commit生成**；因此不能据此否定作者正式所有结果。[20]

三类方法分别增加人工隐含陈述、模型生成解释和目标标记/模块集成，其额外信息预算及训练目标差异大于名称表面相似性。真正要比较“分类到解释”的进展，至少应在同一语料上分开给出危害、目标、立场和隐含陈述的标注，并检验在删除或置换解释时预测是否合理变化。后一个要求属于综述提出的评测建议；现有跨数据集宏 F1 不能替代它。 [18][19][20]

**解释优化需要扣除金标与教师知识的贡献**。 SMARTER（ACL 2026 Main，CCF-A）先进行HateCOT解释SFT，再以训练gold类别构造chosen/rejected的标签一解释DPO偏好；即使不读取解释质量，正反样本的标签token也可能不同，因此其分类提升不能独立归因于解释更忠实，尚需同token的label-only

享一个“多模态理解”金标。检测隐喻有无属于 T1，恢复源域与目标域、判断图文主张的蕴含关系属于 T2，识别反讽对象或交际目的更接近 T3；即使某数据另附“冒犯”属性，也不能据此把所有非字面样本改称隐晦有害内容。 [15][22][33][34]

模态的组合至少有两种情形：一个模态已经给出可识别线索，另一个模态只补充或重复；或者候选意义必须借助两者的关系才能作出。后一种“不可替代性”是具体样本和实验协议的属性，不是图文模型结构的固有性质。例如 OCR 把图片内文字转录到文本输入后，所谓“只看文本”实际上已获得一部分视觉载体的信息。音视频反讽中语音转写也会改变文本端的信息预算。因而，图文、音视频与多图研究可以共享模态依赖的审计问题，却不能共用一组去图分数来证明同一种机制。 [15][34][30]

## 6.2 数据集与细粒度语义标签

早期的二元修辞检测无法回答“什么映射到了什么”以及“谁是反讽对象”。MultiMM [15]收集中英文广告图文，论文 §3、Table 1 报告 8,461 对样本，并分别标记隐喻有无、源域、目标域与正／中／负情感。标注结构允许将跨文化隐喻检测与概念解释区分开；然而中文和英文的采集来源、题材及词汇分布同时不同，模型差异不能单独归因为文化因素。广告中的 OCR 文字也是输入的一部分，不能把语义来源简单写成“原始配文加图片”。 [15]

V-FLUTE [22]将隐喻、明喻、习语、反讽及幽默统一到可解释视觉蕴含：模型接收图片和文字主张，输出 Entailment／Contradiction 与自然语言解释。论文 §3、Table 1 给出 6,027 个实例，部分候选主张和解释由模型生成，再经专家审修；全量并非每条都由三名专家独立投票。此处的金标是图文主张关系及参考解释，既不是“作者真实心理意图”，也不是安全政策下的有害标签。其不同来源采用不同正负例构造规则，因此按来源检查数据和模型错误，与报告一个全局 F1 同样必要。 [22]

M3UCD [33]把任务粒度进一步扩至隐喻类型、源／目标概念及其模态、情绪、冒犯度、意图和其他修辞。论文 §3、Tables 1–3 报告 15,345 个实例，若干分类属性由受训标注者讨论或投票确定；概念生成却不能直接借分类标签的一致性数字证明可靠。其“Complementary”约占作者报告的58.36%，但这只是**人审模态归属类别**，而非在同样本同模型上移除任一模态后必然预测失效的行为证据。MGMCF [32]沿用 MET-MEME 的隐喻、情绪、意图和冒犯四种分类标签；它以源／目标域概念作为额外输入，和以域概念为预测目标的 M3UCD 不在同一输入条件。四项标签反映不同语义或评价维度，冒犯度尤其不能替代第七章的人审联合风险真值。 [33][32]

表5：多模态非字面理解的输入预算与辅助标签逐项区分原始模态、测试时金标辅助字段、预测目标与证据边界。

**表5｜多模态非字面理解：原始输入、辅助监督与可证机制**

| 论文 | X_raw、Y与模态 | 训练/测试额外信息（注意区分） | 人审GT、正面结果与尚不可归因之处 |
|---|---|---|---|
| MultiMM [15] | 广告**图文**；隐喻/情绪等 | P：作者情绪辅助配置；S：**所审公开检测路径已固定commit与行号**（正文附录A A3），test读取CSV情绪列；正式论文run、情绪列有效来源及OCR预算对应仍O | 作者报告隐喻预测提升；同预算“模型预测情绪 vs gold情绪”仍待核 |
| V-FLUTE [22] | **图文**；视觉蕴含类别和自然语言解释 | 训练白图模型属输入对照，非等信息的语义单因素干预 | 作者有图F1@0 72.78 vs白图64.77（特定设定）；白图残余表现与来源类别先验说明不能认定视觉因果必要；解释F1阈值不等于忠实性 |

| 论文 | X_raw、Y与模态 | 训练/测试额外信息（注意区分） | 人审GT、正面结果与尚不可归因之处 |
|---|---|---|---|
| M3UCD [33] | **图文**；隐喻、源/目标、意图等 | OCR/多任务属性监督；共享LoRA | 作者报告15,345图文例、Complementary 58.36%**是现象人工贡献类别**，不是同模型去图因果证据；个别任务有负迁移 |
| MGMCF [32] | **图文**；隐喻/情绪/意图/冒犯分类 | 论文定义源/目标概念辅助文本；所审公开loader已固定commit与行号（正文附录A A4），预计算pkl字段的**gold／预测来源未独立确认** | 作者报告对象、全局-局部与双语义模块的结构消融；同信息预算和源码损失对齐仍O |
| **DOSE** [23] | **新闻图像＋文章文本**；多目标反讽MCQ | 任务提示、共享/私有LoRA专家与投影正交；官方五类主要任务，所审代码有第六种变体 | 作者1%数据预算下五任务均值78.90 vs同底座LoRA77.70（作者协议）；“文本主导61.9%/等贡献22.5%/图像主导15.6%”是标注解释类别，不是因果去模态 |
| MCIB [34] | **文本＋音频＋视频**；反讽二分类 | MUStARD++R标签协议、三配对条件瓶颈/KL与条件预测辅助训练 | 作者weighted-F1 75.64；去细粒度71.19、Transformer→MLP74.32为结构对照，不是独立“no KL/no conditional”证明；所审公开路径已固定commit与行号（正文附录A A5）；真实batch shape和正式run对应仍O |
| MMSD3.0 [30] | **多图＋文本**；反讽 | 正式CVPR2026 Main（CCF-A）论文有CIRM关系推理 | **截至当前只核正式出版页/摘要**，可确认基准和方法存在，未据全文表格宣称模块独立收益或严格多图因果依赖 |

**表注。** 人审模态贡献归属≠同模型`text-only/image-only/joint`的预测变化≠人工复标单因素反事实；这三类证据不可互换。比较前必须给`X_raw/X_train_aux/X_test_gold_or_predicted`，MultiMM/MGMCF/MCIB所列公开源码已固定；字段有效来源、真实batch与正式run对应仍需证据，S不等于正式论文实验。原始源码permalink已直接收入正文附录A，外审无需读取私人审计索引。

## 6.3 跨模态融合与多任务优化

方法从整图和整句的简单拼接，逐步转向对象线索、任务共享与任务分离。MGMCF 的输入是图像、Meme 文字及源／目标域辅助文本：文本编码、整图表示和对象区域特征经 Global–Local 双向交互更新，再把融合、文本和图像预测分支用于四项分类；训练损失包含各任务交叉熵与 Dual-Semantic 项。其英文 MET-MEME 实验的 Table 2 显示移除对象、Global–Local 或辅助损失后部分分类指标下降。这支持完整配置在特定数据和输入字段下的经验收益，却不等于对象分支已准确定位非字面映射，更不等于删除一个分支就完成了“只看单模态”的严格对照。 [32]

M3UCD 的 MCLF 让同一图文样本配合不同任务指令，冻结多模态基座并共享 LoRA 增量，以各任务标签的训练损失优化预测。情绪、意图和概念在这里是并列监督，不存在已证实的“先识别情绪，再恢复隐喻”的必经计算路径。论文 Table 4 中，同一 Qwen2.5-VL-7B 设置的源／目标模态分类 macro-F1 有所增加，而情绪及隐喻检测 macro-F1 下降；正负迁移并存，故不能用总体多任务优势掩盖任务级代价。公平比较还需匹配总训练样本、token、更新步数和参数预算。 [33]

DOSE [23]把反讽检测扩展到机制、描述、对象和意图等选择任务。输入为新闻图文及任务指令，输出相应类别或多选答案；训练数据的候选解释和难负例含生成辅助与人工审校。方法为每个低秩专家设置 shared／private 两组参数，以样本内容和任务身份混合路由，并惩罚两组输出投影的几何重叠。论文 Table 3在Qwen3-VL-8B的1%训练预算下报告五主任务等权Accuracy为78.90，LoRA为77.70；Table 4去正交项的总体成绩下降，Target单项却高于完整模型。作者对反讽正例的模态贡献标注还报告文本主导约61.9%、图文相当约22.5%、图像主导约15.6%，这些是**人工归属类别，不是同模型去图去文的实际准确率**。这说明模块组合有经验价值，并显示任务之间仍可能权衡。参数正交不直接测量不同任务的梯度冲突；选择题准确率也不能改写为自由文本解释忠实率。 [23]

因此不能声称作者正式实验的损失已被复现证明错误。该方向的真正机制独立证据应是同参数同预算的无KL、无条件预测及双无控制，并结合受控模态置换检验决策是否真正依赖互补特征；结构消融和weighted-F1只能支持作者当前完整方法的经验效果。 [34]

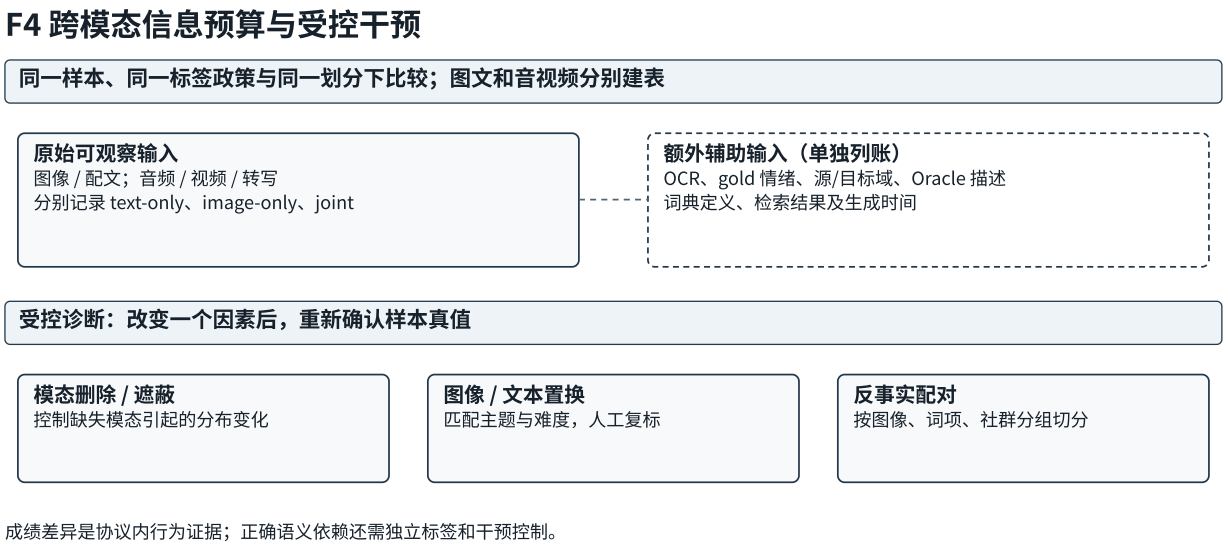



**图4｜跨模态信息预算与受控干预。** 原始模态与 gold 情绪、源目标、OCR 或检索等辅助输入分栏；单模态/联合、置换和配对实验在同一标签政策下比较，并对反事实重新人工确认真值。图示为评价设计，不是现有方法已经证明的因果链。

## 6.6 多图、视频及更广模态的拓展

多图输入可能让反讽对象分散在连续画面之间，音视频则引入时间位置、语调和表情。MCIB（AAAI 2026 Technical，CCF-A）提供文/音/视反讽正式实验，不能与静态图文Meme方法的F1直接排行。MMSD3.0（CVPR 2026 Main，CCF-A）已正式出版多图反讽基准及CIRM模型，官方摘要提到Dual-Stage Bridge与Relevance-Guided Fusion；但本项目目前**仅完成出版页和摘要级核验**，未逐表审计其训练GT、控制实验或独立模块收益，所以本章仅将其作为已有多图任务与方法先例，不以摘要推断跨图因果关系已经被验证。 [34][30]

更广模态的共通难题是“证据是否位于该模态、何时被模型读取”。视频帧抽样或语音转写可能丢失反讽发生的时刻；多图模型即使输出正确类别，也可能只利用其中一张图或文字选项。若要称跨模态组合式理解，应提供同一样本的局部时间／图像干预和新的人工语义判断，而不只是在每个数据集各报一个总体Accuracy。这一实验设计属于综述判断，现有工作尚未共同完成可直接比较的统一协议。 [23][30][34]

## 6.7 从多模态语义到联合风险

本章展示了意义层的多种可测目标：修辞识别、源／目标域、图文蕴含、对象、意图与解释。它们与规范性风险可能有关联，但现有任务并没有证明“正确理解隐喻就会正确判危害”的单向机制。V-FLUTE 的蕴含真值不包含安全政策；M3UCD 和 MGMCF 的冒犯属性也不能自动转化为“单图安全、单文安全、组合危险”的三条件金标。反过来，一个风险分类器输出正确标签，也不说明它准确恢复了反讽对象。[22][33][32]

第七章因此换用规范性输入风险与行为响应作为评价对象，并要求标明单模态和联合输入的各自真值。本章的图4与表5审计语义证据和辅助信息，第七章的图5与表6则审计风险标签、显式预测及安全输出。两章共享模态依赖问题，不能共享未定义的“理解正确率”。

VLSU的Safety Understanding要求显式风险标签，而Safety Alignment自由生成回答后评审拒答与帮助性。其Table1为兼容旧基准采用独立二**分类提示**并把Borderline→Safe，不能与正式三分类F1直接换算。正式论文第8页Figure5的图内标题明确为**Qwen2.5-VL-32B**；33.8%是**该模型joint三分类已经预测错误的集合**中image-only与text-only均预测正确的占比。图注说明其按错误类型拆分联合错误，正文§5亦以全部joint错误作为分母；不是17个模型汇总，也非全库8187/8159或严格S-S-U的37/35条。附录E.3在第38页引出扩展分析，第39页Figure18按模型分别画图，不能把示例33.8%读成全部模型统一百分比；该现象是预测条件统计，不能单凭它定位内部推理的因果缺陷。所查公开CSV另有141条image_grade=not_sure，在三条件组合模式统计时需说明排除/映射，不意味着仅评joint时所有这些记录均被丢弃。 [36]

Multimodal Situational Safety [37]把活动请求放入视觉环境，MSSBench 论文报告 1,960 个图文对，区分显式安全判断诊断和是否遵循／拒绝的行为评估。同一句请求配不同场景图的 Chat 部分适合讨论视觉条件；Embodied 部分不一定严格只改图像。其 IF Judge 对回答模式评分，并非直接读取模型内部风险分类；给模型 Oracle 环境状态也提高了可用信息预算。SIUO [26]观察表面安全的跨模态输入引发不安全输出，主要是行为对齐挑战，不能并入 VLSU 的人工输入三等级真值。 [37][26]

表6：多模态风险真值、响应行为与指标将输入真值、显式判断、实际响应与输出评价分别列账，并保留 VLSU 的论文/公开文件版本差异。

**表6｜多模态风险：输入真值、显式预测、响应行为与指标分母**

| 论文 | $G_{in}$：输入风险GT、标注/版本 | $P_{in}$：显式分类 | $R_{beh}$ / $Q_{out}$：回应评价 | 分母、Judge与不得混同之处 |
|---|---|---|---|---|
| Hateful Memes [39] | 图文仇恨二分类；非天然三条件标签 | 研究重点为分类 | 无强制回应任务 | 不能将所有图文难例当S-S-U |
| VLSBench [25] | VSIL视觉信息泄漏：比较风险Judge看图文与仅文本；样本偏风险侧 | 非统一三条件GT分类 | Safe Rate=Refusal+Warning，另报Unsafe | Qwen2-VL-7B特定200例：text 29.5%、text+图像描述22.5%、图文16.0%，是**回应比例**而非输入分类准确 |
| MMSafeAware [27] | 作者论文Unsafe1000/Over-Safe500，三向人审筛选；发布版文件／图像差异本轮未固定，只记O并撤去精细计数 | 联合Safe/Unsafe二分类 | 非主要生成回应 | 类比2:1，恒判Unsafe总Acc=66.67%；需报Unsafe召回+Safe召回；未固定发布版不用于断言正式样本或图像数量 |
| VLSU [36] | 人审图/文/联合三条件Safe/Borderline/Unsafe；正式PDF**8187**、公开CSV**8159**；严格S-S-U PDF**37**、CSV**35** | 三级风险；Table1兼容他基准的二分类把Borderline当Safe | Harmless/Helpful行为prompt下拒答与帮助性另测 | 正式PDF第8页Figure5图内标题为**Qwen2.5-VL-32B**，33.8%：分母为该模型**joint三分类已错集合**，其中I/T均正确；非17模型汇总，扩展模型见正式PDF第38页E.3及第39页Figure18；本轮已直接核图内模型名、图注和分母；公开image_grade含141个not_sure；图像单条件作者单人评、文本/联合多评审；论文PDF17模型/摘要11 |
| MSSBench [37] | 论文1960视觉情境请求；Chat/Embodied控制程度不同 | 有部分显式安全诊断 | IF Judge评情境行动/回答 | Oracle环境事实应与原图输入分开 |
| MOSSBench [38] | 300作者目标安全图文请求，约9%人审对能否安全作答有争议；contrast逐ID映射／发布版数量未固定，不保留精确数 | 不提供统一三等级输入分类 | 安全主集上ARR=拒答比例；危险对照可另测拒答 | 安全误拒不是输入分类FPR；不是全300严格单因素配对；发布版证据为S/O |

| 论文 | $G_{in}$：输入风险GT、标注/版本 | $P_{in}$：显式分类 | $R_{beh}$ / $Q_{out}$：回应评价 | 分母、Judge与不得混同之处 |
|---|---|---|---|---|
| **SIUO** [26] | 图文表面安全但可能引出危险回复；不提供VLSU式三条件风险人审GT | 非主要的独立输入分类任务 | 输出Safe Rate/攻击成功率；包含参考安全警示与Judge | NAACL2025 **Findings**（举办会议CCF-B，**非主会**）；须注明人工与AI辅助构造子集及judge参考信息 |
| Cross Guard [24] | 1616 Guard混合训练，joint类占约12.5%≈202；ImpForge另有**1390红队样本**，尚未核逐例映射 | LoRA/SFT训练输入Safe/Unsafe Guard | 红队攻击ASR↑、Guard漏检ASR↓与生成模型危险回应ASR↓各异 | Fig4 SIUO 60.33→5.39%，FigStep0.12→0.21%；不同在线模板、离线GPT judge、Guard标签输出的定义**不可直接当同一ASR** |
| ThinkingGuard [41] | 作者称TriggerBench 2800 Safe +2800 Unsafe成对；图片分别生成，严格只动Trigger未逐对证实 | 风险标签/类别+逐步分析 | 离线SA-MCTS与DPO轨迹训练，非直接安全回复 | 作者接收ACM MM2026（会议CCF-A），最终出版社实际Track仍O；Step-DPO同预算独立性未证 |
| Meerkat-VL [35] | 带风险说明等的隐含风险训练材料（非无争议三条件输入金标） | 有风险感知监督，不是独立部署分类器的统一评测 | 安全/帮助性生成，自Actor自评奖励+GRPO | 训练评分读规范risk文本但不重新读原图；不等于独立视觉验证，模型Judge与帮助性需分列 |

**表注**。$G_{in}$=政策/人审输入真值，$P_{in}$=显式输入判断，$R_{beh}$=拒答/警示/执行，$Q_{out}$=安全与合法帮助质量；**同名ASR可能是攻击得逞、Guard漏检或生成危险回复，必须给主体+Judge+分母**。VLSU 33.8%只指Figure5示例模型的joint分类错误子集，严格S-S-U并非整个联合风险升高类。图片重复、发布数据文件差异、代码脚本观察需保留版本限制。

**版本定位**。VLSU公开CSV固定commit `b7c1780d2d578a82fc5f11a070d93bcd50cb9e45`／blob `09421adeb2e68eac1d5e829dcbd48848f21a0be6`，本轮重读重计8159/35/141，公开链接与计数方法见正文附录A；Figure5与Figure18本轮已直接核ICLR2026正式PDF，分别位于第8／39页；44页文件SHA-256为 `b38dc2e84d20899132125338b3ef8d31f54873660c2562c281c4d992c1f96aa8`。这只补齐正式图表核验，不表示重算原模型预测。

## 7.3 检测器、触发归因与反事实训练

在明确输入风险标签之后，方法研究才可分析哪种图文关系触发风险。CrossGuard [24]包含两种不同学习对象：ImpForge固定视觉场景，使用PPO改写有害请求以生成**红队攻击图文**；随后CrossGuard使用LLaVA基座及LoRA/SFT从混合Safe/Unsafe数据训练**输入Guard**。论文Figure6的ImpForge **1390条**属于生成攻击评测集，Figure7的**1616条**是Guard混合训练集，其中联合隐含恶意类占约**12.5%≈202条**（比例近似推算，不是作者公布精确202条ID）。当前无逐样本索引证据证明这约202条究竟是1390中的哪部分，也不能说1390条全部进入1616训练集。

作者Figure4将有无ImpForge联合类训练数据对照：SIUO防护ASR **60.33→5.39%**、MM-SafetyBench **10.20→0.38%**，但FigStep **0.12→0.21%**小幅变差，因而可说部分联合隐含防护基准显著改善，不能说所有基准都单调改善。新增数据数量/类别比例也变了，不能将全部收益归因于PPO本身或新检测架构。该文在线被测MLLM可能依据拒答模板判危险输出，离线生成模型用GPT裁判，Guard则由输入Safe/Unsafe漏判计算指标；**攻击生成的ASR、Guard的输入漏检以及回应的危险输出ASR不是同一统计对象**，不能不注明分母与Judge便做直接性能排名。 [24]

代表分数吻合，不能保证视觉事实或规范判断正确。作者报告综合回复安全/帮助改善，但本项目没有独立核完正式ICML论文的逐项基线/消融数字；因此只能把独立NPSV、DPCA与额外风险知识的贡献列为待同预算对照，不冒称自验证是独立重新看图。 [35]

VLSU（ICLR 2026，CCF-A）的同模型行为提示提供具体**安全—帮助性双侧权衡**：对Gemini-1.5仅把推理时提示从Harmless换到Helpful，Borderline输入上的拒答率由62.4%降至10.4%，但Unsafe输入拒答率也由90.8%降至53.9%。这不是SFT/PPO重训练，也不是风险分类F1变化；前者提示过度拒绝可能降低，后者提醒危险请求的拒绝同样下降，不能只挑有利一侧解读。与MOSSBench的正常请求误拒和Meerkat-VL的训练后回应一起看，研究问题应是能否在相同模型/政策/Judge下改善两侧，而不能把异构数据集拼成统一Pareto曲线。 [36][38][35]

VLSU 的拒答／帮助性实验、MSSBench 的情境行动、MOSSBench 的正常请求误拒和 Meerkat-VL 的安全回应，分别对响应链的不同层施压。SIUO 的攻击成功率关注危险输出，MMSafeAware 的危险召回关注输入判别。即使数字看似都以百分比报告，拒答率、ASR、分类 F1 和安全回复率也不能换算为同一个“安全性能”。尤其不能把高拒答率视作模型已经识别图文组合的风险来源。 [36][37][38][27][35][26]

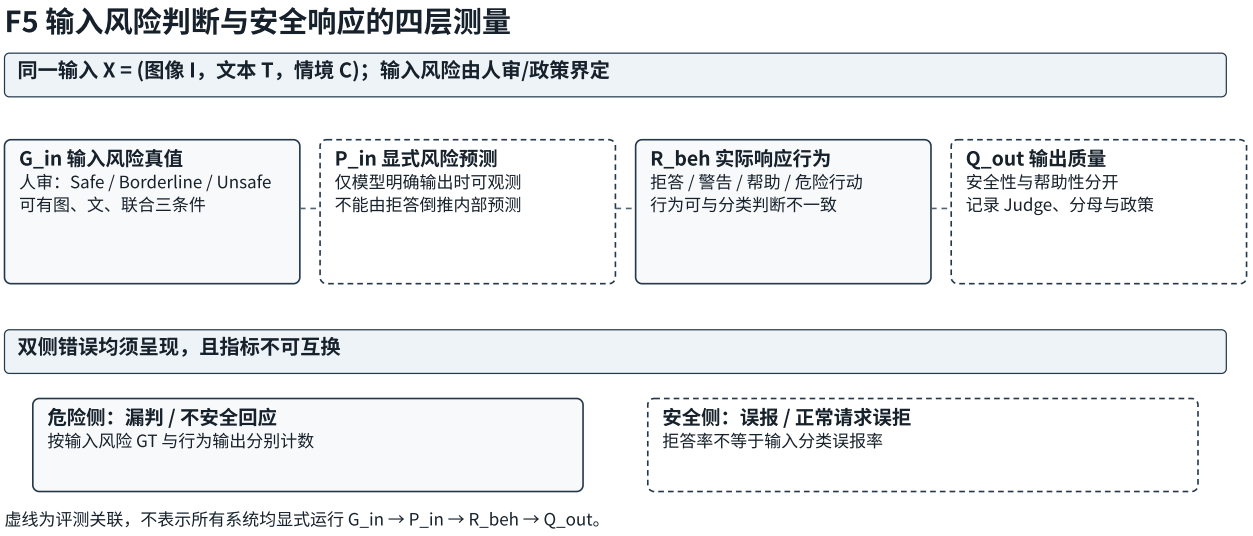



**图5｜输入风险判断与安全响应的四层测量。** $G_{in}$ 是人审/政策输入真值，$P_{in}$ 仅在模型显式报告时可观测，$R_{beh}$ 是实际行为，$Q_{out}$ 是安全性与帮助性评价；危险侧漏检和正常请求误拒分别计量。虚线不表示可从回应倒推出内部判断。

## 7.5 正负两侧评价与失败归因

安全系统的失败有两面。在输入分类协议中，危险样本被判 Safe 是漏检，安全样本被判 Unsafe 是误报；在回应协议中，危险请求收到可执行有害帮助与正常请求被拒绝是不同错误。前两者依赖 $G_{in}$ 与显式 $P_{in}$，后两者依赖 $R_{beh}$、$Q_{out}$ 和相应人工或评审器标准。一个方法可降低危险侧漏检，却扩大安全侧误拒；若只报总 Accuracy 或总拒答率，这种代价会被类别比例遮盖。MMSafeAware 的 2:1 设计、MOSSBench 的安全主集和 VLSU 对 Safe／Borderline／Unsafe 的分组，正好说明需要同时呈现条件分母、两侧召回与策略质量。 [27][38][36]

失败归因也须受控。文本单独模型的错误不必然意味着图像“不可替代”，因为图片可能含 OCR 或模型未被训练处理白图；图像置换后的标签如果未经人工复标，沿用原联合金标会把无效反事实当成模型错误。VLSBench 的视觉泄漏诊断、VLSU 的单模态与联合标注、ThinkingGuard 的配对触发、MSSBench 的同请求换场景图，分别提供了可借鉴的控制环节，却各有数据构造和指标限制。测试图像缺失、近重复、生成模板、评审器提示词和不确定标注也应随分数一并公开。 [25][36][41][37]

## 表7｜横跨语用、隐晦检测与安全回应的方法族：优化对象、先验与独立证据

| 方法/正式出处 | Y与训练更新目标（不可跨任务排分） | 额外可用先验、训练/测试信息 | 作者报告的正面作用（P） | 边界与独立贡献尚未证实之处（P/S/O/H） |
|---|---|---|---|---|
| $(RSA)^2$ [3]（ACL 2025 Main, CCF-A） | 给定候选意义的概率；**C1/C3** | 修辞策略、候选空间、意义先验；不新增类别微调 | 普通L0→hard策略L0整体0.73→0.85，反讽0.48→>>0.8；hard L1先验均匀0.84→0.51 | 字面子群0.95→0.77；概率非Acc。ACL正式论文Tables 2–3／Figure 4 |
| Silent Signals [4]（ACL 2024 Main，CCF-A） | 已知词的实例编码义消歧 | 已知社群词条及编码释义、模型生成的筛样数据 | 在定义给定情形可做人审抽样Precision检查 | 主集模型筛阳，无法从中声称开放未来词或全量人审 |
| FETCH! [5]（ACL 2025 Main, CCF-A） | **词项type/root回收；C1**，非实例消歧 | 参考词典约20%种子＋社群语料；近邻提取／过滤 | Balanced Table4 PREDICT P/DPR/F0.5=14.81/1.65/5.70%；Table5 DIRECT Llama2-13B=2.97/13.58/3.52% | 精度与覆盖取舍，两模型／输出预算不同；留出词典≠时间外新义；P与DPR分母见表3 |
| FA-Net [31]（AAAI 2024 Technical，CCF-A） | **固定候选目标义分类**，Acc@k | 源域标签＋目标域无标文本、已定位委婉位置／类别 | 作者Table3/5报告候选义分类改善；本轮不新增未核具体分数 | 目标域可见非零样本；相似伪正对无逐对金标核验；不同于FETCH的type回收 |
| SeTox [16]（ACL 2026 Main, CCF-A） | 搜索辅助的输入新词毒性标签 | 检索时点、语料来源；工具轨迹SFT | 作者的有／无搜索协议下毒性判别得到改善 | 风险分类非准确恢复词义，也不能从闭集Acc声称时间外词项发现 |
| ImpCon [18]（COLING 2022 Main，会议CCF-B） | **隐含危害分类**，对比学习 | implied statement正对／增强表达＋危害类监督 | 作者报告分类泛化提升；本轮不把它当解释DPO实验 | 正对额外语义监督；无证据据表示距离认定解释忠实 |
| SMARTER [19]（ACL 2026 Main，CCF-A） | **标签—解释成对DPO**，最终毒性分类；C2的监督对照 | HateCOT前序解释SFT＋目标少量标签；gold类别条件chosen/rejected | 作者报告目标少样本分类提升；本轮不新增未核消融分数 | 类别token与解释同时变，监督和token未独立匹配；不是ImpCon对比学习，也不是纯测试CoT |
| DRInQ [8]（ACL 2026 Main, CCF-A） | **五选一会话含意；C2**；冻结模型提示 | 3个in-context例；同400困难题加生成解释指令 | Table2 GPT-5-Mini .56→.62；GPT-4o .62→.63 | Sonnet-4.5 .65→.62、o3 .67→.67；均Accuracy，3次抽样，非全819题；不等token |
| VAGUE [29]（ICCV 2025 Main，CCF-A） | **四选一行动意图；C2**；冻结模型CoT | 原图＋间接表达＋候选；无需测试gold direct/solution | 作者v3 Table3 GPT-4o原图64.6→66.4%，Gemini-1.5-Pro60.6→64.4% | ICCV正式补充材料Table G4 Qwen72B原图72.8→69.9%；作者v3 HTML编号G6；长度／格式混杂仍O |
| **ExPO-HM** [47]（ICLR 2026 Main，CCF-A） | **解释后进行Hateful Meme二分类及细粒度标签**，policy SFT后课程GRPO+CDE奖励 | 政策手册、细粒度标签/训练数据、答案位置概率近似 | HatefulMemes binary macro-F1 naive GRPO 74.5→完整ExPO 81.1；相对RA-HMD直接方法80.2约+0.9pp | C2：训练课程与reward共同变化；CDE低/解释judge高不自动证明解释因果忠实；不等于严格S-S-U GT |
| DOSE [23]（ACL 2026 Main, CCF-A） | 新闻图文的五种反讽理解MCQ | 任务标签／提示、共享与私有LoRA专家 | 作者Table3同底座1%训练五任务均值78.90 vs LoRA77.70 | 同比例原始样本不自动等有效任务数／token；人工模态主导标签不是因果去模态结果 |

| 方法/正式出处 | Y与训练更新目标（不可跨任务排分） | 额外可用先验、训练/测试信息 | 作者报告的正面作用（P） | 边界与独立贡献尚未证实之处（P/S/O/H） |
|---|---|---|---|---|
| MGMCF [32]（AAAI 2025 Technical，CCF-A） | 图文隐喻／情绪／意图／冒犯分类 | 预计算source/target等概念输入；公开loader已固定（附录A A4） | 作者报告对象、全局—局部和双语义结构消融收益 | pkl的gold／预测来源、基线预算、正式run对应仍O |
| M3UCD [33]（AAAI 2026 Technical，CCF-A） | 隐喻／源目标／意图等多任务输出 | OCR、细粒度属性监督、共享LoRA | 作者报告部分任务正迁移；本轮不新增未核分数 | 亦有负迁移；新增监督量非纯架构效应，Complementary人工类别非模型去模态证据 |
| MultiMM [15]（ACL 2025 Main，CCF-A） | 情绪辅助图文隐喻检测 | 所审公开路径已固定（附录A A3），测试读CSV情绪列 | 作者论文报告情绪辅助配置收益；P与下一列S分开 | 正式run、情绪列有效来源、OCR及baseline预算对应O，不泛称源码尚未固定 |
| MCIB [34]（AAAI 2026 Technical，CCF-A） | 文/音/视反讽分类／代理信息压缩目标 | KL/条件预测、数据集修订协议 | 作者报告weighted-F1=75.64，去细粒度结构为71.19 | 同参数去KL/去条件预测受控消融缺失，尚不能声称瓶颈独立消除捷径；公开路径已固定（附录A A5），真实batch shape／论文run仍O |
| **攻击样本生成** ImpForge [24]（ACL 2026 Main，CCF-A） | **生成隐晦联合攻击图文**，PPO优化文本改写器 | 原风险请求、安全/语义/重叠奖励和生成图像 | 作者报告改写攻击更能让被测模型不安全回答 | PPO必要性缺同预算检索/Best-of-N等控制，攻击ASR↑不等于Guard检测能力↑ |
| VLSU冻结回应评测 [36]（ICLR 2026，CCF-A） | **安全／有用回应；C3**，不更新参数 | 同一请求、同一模型，Harmless→Helpful指令 | Gemini-1.5 Borderline拒答62.4→10.4%；安全边界侧受益 | Unsafe拒答90.8→53.9%；QwenVL32B Borderline反23.4→30.7%；非$P_{\text{in}}$分类，不能建立跨模型统一曲线 |
| **输入Guard** CrossGuard [24]（ACL 2026 Main，CCF-A） | **图文输入Safe/Unsafe**，LoRA/SFT更新Guard | 混合训练来源含约12.5%联合风险样本 | SIUO中加入ImpForge后Guard ASR60.33→5.39 | FigStep0.12→0.21；改进还含训练数据量和类别组成差，非新分类架构本身唯一原因 |
| **逐步风险归因** ThinkingGuard [41]（作者ACM MM 2026录用；会议CCF-A，正式Track待核） | 输入风险标签/五步解释；SA-MCTS**离线**搜轨迹→Trajectory+Step-DPO更新VLM | 生成时Key/Trigger教师元素、偏好轨迹，Step偏好主要来自Unsafe | 作者Table3完整Unsafe F1 .810 vs去Step .779 | 配对图片不保证只变Trigger；额外Unsafe监督/token预算与解释忠实性未独立控制 |
| **安全有用回应** Meerkat-VL [35]（ICML 2026 Main，CCF-A） | 生成安全且有帮助回应；Cold-start SFT→同Actor NPSV评分→一致性惩罚DPCA→GRPO | 训练时user_intent/harmful_intent/safety_warning规范风险说明；评分不重看图 | 作者报告综合响应质量改善（正式具体消融尚待逐表复核） | NPSV额外答案级风险信息、同Actor自评与DPCA模块独立贡献未匹配同预算；回应Judge不等于$P_{\text{in}}$ GT |

**表注**。 表内数值都是各论文作者不同Y/G/E下的**同论文协议内对比**，不得横排绝对F1/ASR获得统一SOTA。六组S级代码固定commit与行号见正文附录A；正式run对应仍O。C1–C3与§8.1.1逐行对应；作者版本与正式出版分开，未重跑作者模型。正面结果、负迁移、额外监督和所缺独立对照必须一起读。