

图1｜广义隐晦信息的研究框架。 本文从意义形成机制、研究任务与评价依据组织广义隐晦信息研究。语用推断、修辞表达与社群编码可以相互交叉；跨模态组合则描述不同信息来源之间的关系。T1–T3关注表达和意义，T4/T5关注危害判断，T6关注安全回应。实验比较应核对输入信息、标注依据与评价方式，图中分组不表示固定处理流程。

已有研究从多个独立方向推进这些问题。隐式有害内容方面，[2]等数据集将缺乏显性攻击性词汇的仇恨表达作为独立检测难点；语用与修辞方面，[3]研究修辞策略条件下的概率语用推断；编码语言方面，[4]与[5]分别研究已知狗哨表达的实例义消歧与词项发现；跨模态方面，[39]与[36]从不同侧面推动了图文关系和联合风险的可测评价。这些工作并不组成一个可直接比较排行榜的统一任务，却在“何种证据足以支持某一解释或判断”的问题上逐渐形成交叉。

近年来，LLM与MLLM的出现进一步拓展了可操作的研究形式：提示与检索能够引入动态知识，多任务训练可以同时预测现象、目标及辅助属性，偏好优化与强化学习则可将风险判断和模型回复策略纳入训练。然而，模型规模、推理链长度或融合层数的增加，并不直接说明模型已使用正确的语境与模态证据。以多模态反讽为例，[34]研究角色、笑声和辅助情绪标记等数据捷径，并以条件信息瓶颈构造融合机制；该方向说明可靠性已成为显式研究议题，但其中对信息瓶颈模块独立贡献的证据仍须按原论文消融和实现协议作限定。对有害内容判断而言，[6]还展示了社群内部使用、引用和反用等真实话语环境下的标注分歧。因而，本综述不仅关心模型在既定测试集上的预测正确率，也关注Ground Truth究竟刻画了何种意义、哪些输入信息在测试时可用，以及预测错误能否被可靠地归因。

1.2 综述范围与相关研究的关系

本文使用“广义隐晦信息”作为一个**操作性综述范畴**，指语言或多模态交际中，目标意义、立场或交际作用不能仅由显式字面内容充分确定，而需结合语境、修辞映射、社群约定、编码形式或模态间关系来推断的信息。该定义旨在跨任务组织文献，**并不声称“广义隐晦信息研究”已是各子学科公认的统一研究名称**。隐含（implicit）强调意义或意图未被直接表达，而不易察觉（subtle）强调相关线索不够明显，二者并不等同；编码（coded）不等于必然恶意隐藏；语境依赖不必然产生非字面意义；有害性判断还涉及目标、规范及评价政策。具体的包含关系与反例在第2章给出。

以一句表面疑问“你能把窗户关上吗？”为例，系统可以识别其疑问句形式，亦可以在具体生活情境中将其解释为间接请求。前者是句法/字面层的识别，后者涉及言语行为。再如“真是准时啊”在迟到的会话语境中可能表达反讽，而在实际准点的语境中也可能是真诚评价。同一表达在不同语境中可能具有不同的交际意义，因此对说话者意图的判断应建立在具体的交际情境和可获得的证据之上。

工作性定义与概念边界

本文采用以下工作性定义：**广义隐晦信息是指在语言或多模态交际中，其研究关注的意义、评价立场或交际功能不能仅由直接字面表达充分确定，因而需要额外的语境、语用推理、修辞映射、社群约定、编码形式或模态间关系才能获得可信解释的信息。**该定义旨在组织不同研究谱系的任务边界，不是主张这些文献已经采用共同的“隐晦信息”官方标签体系。

必须区分的概念如下：

为避免把意义现象、表达形式、语境条件和规范性判断混为同一层级，表1：概念与任务边界区分相关概念的适用范围与证据边界。

表1｜广义隐晦信息相关概念的层级与边界

层次	概念	核心判断问题	主要证据	不能直接推出的结论
综述范畴	广义隐晦信息	目标意义、立场或交际功能能否仅由显式字面内容充分确定?	语境、语用推理、修辞映射、社群约定、编码形式或模态关系	本文的工作性组织范畴，不是各子领域共同采用的正式标签；不预设内容有害
意义现象	隐含意义	是否需要推断未被直接表达的命题、行动或立场?	会话上下文、共同知识、言语行为及表达选择	不必是非字面表达，也不必意味着说话者有意隐藏
意义现象	修辞／非字面意义	字面形式是否通过映射、反差等方式传达其他含义?	源域—目标域映射、语境反差及修辞结构	不自动意味着欺骗、隐藏意图或有害
社群约定	编码语言	某种表达是否依据社群约定承载特定的次级意义?	社群用法、跨语境实例、社群与时间信息	生僻词或形式变体不必然具有编码义；编码不自动有害
社群约定（子类）	狗哨语言	同一表面表达是否面向不同受众保留普通义与社群特定的次级义?	受众知识差异、具体语境中的编码义实例及社群证据	狗哨是编码语言中的特定现象，不是所有暗语的同义词；不能仅凭词项确认使用者恶意
表达显著性	不易察觉的表达	相关线索是否强度较低、不显著或不易察觉?	线索显著性、表达强度及具体语境	细微不等于隐含；直接表达也可能很细微
表达形式	形音变体	是否通过读音、拼写、字形或符号变化形成替代表达?	变体与原表达之间的语音、字形或符号关系	形式变化不自动意味着规避审核或隐藏语义
解释条件	语境依赖	解释是否随场景、会话、社群或时间变化?	对照语境、会话轮次、社群知识及时间信息	语境依赖是解释条件，不是独立修辞类型；普通指称消歧不自动属于核心任务
规范判断	有害性	在指定政策、目标和受众条件下，内容是否构成伤害?	攻击对象、说话者立场、话语功能、社会语境及适用政策	有害内容可以显性或隐晦表达；不能由隐喻、反讽或编码标签直接推出

表注。 各行属于不同分析层级，允许在同一实例中交叉出现，并非互斥类别。本文所说的“广义隐晦信息”是用于组织相关研究的工作性范畴；表达机制、语境条件与规范性危害判断应分别分析。术语与语用任务参见 [1][7][4][5]。

“Dog Whistle”在本文中属于具有受众知识差异或多重受众解释机制的重要编码现象，但**不是所有编码语言的同义词**；是否存在有意双层沟通需看具体研究证据。[4]研究已知狗哨编码义的语境使用判定，而[5]研究词项发现，两者即使包含相似词汇也不具有相同预测标签。[7]则展示了中文编码策略和应用任务的关联，但出现编码并不自动代表仇恨或违规。

这些概念**可以相交但不能互为定义**。一段表达可能既是反讽又具有编码社群义，但无害；也可能没有任何隐喻或暗语，却借上下文表达隐含的群体偏见。另一方面，单纯视觉不完整或文本指代歧义，如果没有明确的隐含/非字面/编码/风险研究目标，应作为相邻语境理解而不是核心收录对象。

包含与排除的四个判定例。 无害隐喻若研究源目标映射，仍是T1/T2核心；只把谐音字符还原为常用字而不涉及社群编码义的任务是邻接信息处理；普通图文有害Meme可以属于T4，却不自动具备T5严格图、文单独Safe而组合Unsafe的标签；纯显式危险请求的泛化RLHF不作为隐晦意义核心方法，但直接研究组合风险后的误拒与帮助性时可作为相邻T6。纳入的判断对象是**预测目标、语义机制及其真值**，而非数据中是否出现“图像”“情绪”或“安全”一词。

2.2 五轴任务与证据记录框架



图2｜研究任务与实验协议的双层描述。 本文分别从意义机制、研究任务、模态与语境、辅助信息、标注与评价五个维度描述研究设置，再以Task = (X, Y, G, E)记录一项实验的输入、预测目标、标注依据和评价方式。两种描述互为补充，不构成模型的推理流程；同一评价指标下的实验结果仍须结合任务条件和标签定义理解。

若以“隐喻、仇恨、VLM、DPO”并列为一级类别，会把表达机制、风险类别、模型类型和训练方法混在同一个层次。为避免此问题，本文以五个**分析上应分离、但经验上可能相互影响**的维度（图2）记录具体实验协议，并将其作为后文比较论文的共同依据。它们不是数学意义上必须统计独立的变量。

A. 表达与意义机制。记录实例涉及会话含意、间接言语行为、隐喻/反讽/委婉语、编码/狗哨、形式伪装或跨模态组合关系。它描述*为什么需要超出字面的语义证据*；群体立场是T3可能判断的语用属性，歧视/危害为T4的规范性评价对象，安全回应属T6，**不把三者冒充语言意义机制**。

B. 研究预测目标。记录模型究竟在判定现象存在、生成/选择解释、判断交际功能、给出有害性类别，还是生成安全回应；同一个机制可对应多个不同任务，同一任务也可能利用不同机制。

具体协议／证据	X_raw	X_train_aux	X_test_aux	Y与G来源	E及分母	同预算对照及未知项
DOSE五任务（P；ACL 2026 Main，CCF-A）	新闻图像＋文章文本	五类任务标签、共享／私有专家训练；统一MCQ目标CE	对应任务提示＋候选；标签为评分目标，非默认额外gold输入	检测／机制／描述／对象／意图；基于原DocMSU，模型生成扩展并人审	作者1%训练、其余评价；各任务Accuracy后取均值，非按有效MCQ总数加权	Qwen3-VL-8B DOSE/LoRA同1%原始数据；有效任务数／token／训练参数并未因同百分比自动相同。正式§3、§5/Table3
VLSU Understanding（P；ICLR 2026，CCF-A）	image-only／text-only／joint三条件	冻结评测，无本轮任务训练	安全等级定义与分类提示，不提供人审目标标签	单图经验作者；文本／联合多评审；Safe/Borderline/Unsafe	各条件三级Acc/F1；Table1二分类另将Borderline→Safe；Figure5仅指定模型joint错误集合	同模型三条件对照；去模态信息不等，不能称同信息因果对照；正式PDF8187与固定CSV8159分开
VLSU Alignment（P；同上）	同一图文请求	冻结模型	Harmless或Helpful行为提示	G_{in} 按输入风险分组；回应Judge评分并非新的P_{in}金标	各严重度组的拒答／帮助性；Table3、附录E.4，不与分类F1互算	同模型同样本变提示；Judge、生成长度等固定细节以作者版本附录D为准，跨模型不默认同预算。作者v2

2.3 计算语用与操作性Ground Truth

计算语用研究为上述问题提供了可检验的建模和评价方式。概率语用模型通常通过说话者—听者之间对表达选择及潜在意义的假设进行推断，但模型中的先验、候选空间与语境构造会直接决定其适用边界。[3]进一步将修辞策略纳入RSA式语用推断；其研究目标是策略条件下的意义判断而非有害内容分类。[8]通过固定问句、改变语境的选择任务评价会话含意；[29]利用视觉情境及候选行动评价间接表达的适宜解释。这些研究提供的是**在特定构造任务和候选空间中的模型行为证据**，不应被解释为真实说话者内心意图已被直接观察或完全恢复。

上述任务虽然都与“语用”有关，却没有共同的心理意图金标。DRInQ在给定五个候选含意时评估语境化选择，并以人类共识构造测试答案；VAGUE在视觉语境和四个候选行动中评估模型的适宜判断；$(RSA)^2$依赖定义好的策略、先验与候选意义空间。其Accuracy或候选概率只支撑**各自协议下的选择或拟合表现**，不能据此判定真实发话者意图已被完整恢复，或直接与开放式意义解释的准确率合并。

2.4 T1–T6与Task = (X, Y, G, E)：任务目标与可观测标签

为比较不同研究要求模型识别何种现象、恢复何种意义或作出何种风险判断，表2：T1–T6 的输入、输出与 Ground Truth归纳预测目标、输入条件与标注依据。

表2｜T1–T6：研究任务、标注依据与评价方式

任务	模型需要回答的问题	输入与正确答案依据	主要评价方式	关系与解释边界
T1 表达识别	是否出现隐喻、反讽、编码表达等现象？相关片段在哪里？	文本或图文输入；人工现象标签或片段标注	分类Macro-F1、Span-F1等	识别出表达形式，不等于恢复了实例含义。代表研究：[7]
T2 意义解释	该表达在当前语境中传递什么含义？图文主张是否成立？	上下文、图文关系；可包含预先给定的候选意义或源／目标概念；GT可为人工审定释义、候选选择或图文关系标签	候选准确率、蕴含分类指标、解释文本的人评或匹配指标	候选空间会限制可测范围；参考解释匹配不等于恢复说话者真实心理意图。代表研究：[3][22]

任务	模型需要回答的问题	输入与正确答案依据	主要评价方式	关系与解释边界
T3 交际功能推断	表达在当前场景中起什么作用？是请求、含意、立场还是某种行动?	对话轮次或视觉场景；GT可能来自人类共识，也可能来自人工筛选的构造行动选项	多选题Accuracy、人评及标注一致性	DRInQ的人类共识与VAGUE的构造行动选项不是同一种GT；必须说明候选集合与负项难度。代表研究：[8][29]
T4 规范性危害判断	内容在指定政策下是否有害？针对谁？属于何种类别或程度?	文本或多模态内容，以及必要的目标、立场和社会语境；GT来自人工规范判断或明确说明的代理标签	Macro-F1、类别召回、混淆矩阵及两侧错误	修辞识别或编码词识别不能自动推出危害。代表研究：[2][6]
T5 联合模态风险判断	图像、文字分别输入与联合输入时，风险判断是否发生变化?	图像、文字及联合输入；若声称严格S-S-U，必须有同一政策下图像Safe、文本Safe、联合Unsafe的可比GT	分条件分类指标、联合错误分析及经人工复核的反事实对照	T5是T4的特定联合模态设定；图文并置不等于S-S-U。代表研究：[36][24]
T6 安全回应	模型应该拒答、警示、提供帮助还是采取其他回应？实际输出是否安全且有用?	风险请求、回应政策和模型输出；GT由人工或独立Judge评价输出安全性与帮助性	危险请求上的不安全帮助、正常请求上的不必要拒答及帮助性分别报告	T6评价回应行为，不是T4输入风险GT；拒答不能反推出模型内部一定完成了显式风险分类。代表研究：[38][35]

表注。 T1–T6是不同预测目标，不是模型必须依次执行的算法流水线。T5是T4在联合模态条件下的特定设定，T6是相邻的回应行为评价。具体实验仍需分别记录原始输入、训练辅助信息、测试辅助信息、预测目标、标注来源、评价分母和Judge；这些信息共同构成Task = (X, Y, G, E)的记录方式。不同任务的F1、Accuracy和ASR不能组成统一排行榜。

T1–T6不是必须逐级运行的算法流水线。例如，有害性分类器可能直接从原始内容估计T4标签，未显式输出T2或T3解释；而纯反讽研究可能只解决T1/T2，无需转向风险判断。任务之间存在概念联系，但只有同时给出独立中间标签和控制实验，才能进一步声称某种中间语义表征**因果促进**了有害性判断。

这里还需注意T5的特殊地位。对于一对模态 I, T 和语境 C，可用 $G(I, T \mid C)$ 表示在指定政策下的**联合输入风险标签**；$G(I, \varnothing \mid C)$ 与 $G(\varnothing, T \mid C)$ 表示在人类标注协议允许时的单模态条件判断。研究可讨论具有不同形式的联合关系风险，但**严格证明某项危险判断必须依赖两种模态**，还需人审的单模态/联合风险标签、对照或精心控制的配对干预；单纯去掉图片后分数降低不足以证明模型掌握了正确关系。双方单独安全、组合危险（S-S-U）是尤其明确的联合协同模式，却只是T5的更窄子类，且并非所有数据都拥有同协议的三条件人工GT。普通Hateful Meme图文分类器即使同时读取图与文，也不自动意味着其数据满足这种严格标签条件。

2.5 纳入/排除示例与解释、危害及响应的不同GT

前文任务的另一个关键界限体现在Ground Truth来源。对同一个被标为含有隐喻的句子，源域标注者可能给出“像洪水一样”的修辞标签；危害评审者则还需判断其中是否出现群体贬低、说话者是在赞同还是批评、语境是否为引用或社群内部自述。修辞检测与有害性判断的Ground Truth并不天然一致。[9]中的人工监督主要针对隐喻源域，而非每条语句的独立“非人化/仇恨成立”标签，因此不宜用其修辞准确率证明模型可靠识别了歧视性意图。

[6]进一步给出了真实社交平台中的规范性评价案例。其研究对象既包含可能的隐式歧视也包含显性讨论，并未为每条实例提供独立显性/隐性标签；9位受过专门培训的高年级本科研究志愿者参与标注，每条目标句由3人参考邻近语境作出判断；作者报告Fleiss's κ为0.25。论文提供社群内部求助、反用和引用引发分歧或误报的质性案例，但缺少在同一模型和相同数据划分下比较“目标句单独输入”与“目标句加语

由此进入第4章时，需要先问研究者究竟是在发现一种表达、消歧其一次使用、恢复所指意义，还是评价其危害。反讽、隐喻、委婉和编码都可能承载无害交流；无论形式多隐晦，仅凭形式标签都不能推出交际者有规避审核的目的。编码表达与有害性之间还隔着目标、立场及规范判断，这一层将在第5章讨论。[7][4][31]

4 编码语言、狗哨与动态词义

4.1 编码语言、狗哨与形音变体



图3｜编码语言研究中的四类不同问题。 编码语言研究分别涉及词项发现、实例义项判断、具体含义恢复和有害性判断。四类问题具有不同的预测目标与标注依据，且都受到语境、社群知识和时间变化的影响。识别出编码表达并不等于确认其具体含义，更不能仅凭编码形式认定内容有害。

表3：编码语言研究中的任务与证据比较词项发现、实例义消歧、意义恢复与新词风险判断的先验、单位及评价边界。

表3｜编码语言研究：任务先验、预测单位与评价边界

研究与任务	可用先验与预测单位	作者报告的结果与评价口径	不能据此推出的结论
Silent Signals：已知狗哨词的实例义消歧 [4]	测试时给定目标词及编码义定义；判断具体语境中的一次使用（instance/token）。论文模型筛选主集16,550条，另有400个筛选正例接受人工审查。	抽样人工审查Precision约85.3%；按作者较宽的可接受编码义口径约89.4%。两者均是抽样审查结果。	不是开放词项发现；400条抽审不能等同于16,550条全部人工核验，也不能据此报告整体Recall。
FETCH!：已知词典中的候选词项回收 [5]	约20%的参考词典作为种子，结合社群语料发现其余已收录词项；输出单位是词项类型（type/root），不是句中实例。	正式Table 4 Balanced PREDICT：P=14.81%、DPR=1.65%、F0.5=5.70%；Table 5同场景DIRECT Llama2-13B：P=2.97%、DPR=13.58%、F0.5=3.52%。P按输出候选词项计，DPR按语料中出现的留出参考根词计并按根词去重。	两条管线的模型和输出预算不同，不能把三项指标压成单一优劣结论；词典留出不等于现实时间外新词发现。

研究与任务	可用先验与预测单位	作者报告的结果与评价口径	不能据此推出的结论
FA-Net：固定候选目标义分类 [31]	源域有标签，目标域无标签文本可参与适应；测试时已定位委婉表达位置，并给定Drug、Weapon、Sexuality等候选目标类别。	作者报告固定候选分类的Acc@k改善；具体结果应按原论文相应任务和候选空间解读。	目标域并非完全不可见，不是零样本目标域迁移，也不是开放式新义生成；跨域伪正对未逐对获得独立人工同义核验。
CodedLang：中文评论中的编码表达 [7]	中文在线评论；通过种子、词典匹配和人工扩展构造样本；分别预测编码片段、编码策略及评论级属性。	7,744条评论中标注900条含编码表达；片段检测、策略分类和评论星级预测是不同任务。	星级是平台字段，不是编码义或有害性GT；构造样本的正例比例和策略分布不能代表整个中文互联网的自然发生率。
SeTox：检索辅助的新词毒性判断 [16]	推理时可在线检索；训练时使用工具调用轨迹SFT。624条测试样本按风险标签分为Unsafe 490、Safe 134；按相对指定基础模型的词义认知分为known 319、model-unknown 305。	DR/KDR/UDR按Unsafe子集报告检测率；Accuracy/F1则覆盖相应分类样本。作者报告检索设置改善其定义下的新词毒性判断。	model-unknown不等于严格时间外新词或词典外新义；毒性分类不等于恢复词义、受众或真实交际意图；在线检索还需报告语料快照与查询时间。

表注。 词项发现、实例义消歧、固定候选义分类和毒性判断是不同预测任务，不构成五篇论文共同验证的端到端系统。FETCH!中的P为Precision，DPR为Discovery Proportion Rate，F0.5偏重Precision；其计分单位是词项而非帖子或句子。SeTox的known/model-unknown是相对于指定基础模型的分组，不应解释为真实时间先后。不同任务的指标不能直接横向排名。

编码语言的计算问题不能由“含有生僻词”概括。表达者可能改变读音、字形、语言或符号组合，使表面形式与交际中预期的意义之间出现需要逆向恢复的距离；这种转换也可能借助社群习惯而非纯形式规则。CodedLang [7]以中文在线评论为对象，在 7,744 条评论中标注编码片段，其中 900 条被判有编码表达。其七类主要策略包括两类谐音、拼音等语音替代、表情符号、字形替代、跨语言语音编码及密码式表达。分类法描述“怎样被编码”，并不自动回答“为何编码”或“是否有害”。作者由种子、词典匹配和人工扩展收集低频样例，因而构造语料的正类比例与七类分布都不能当作整个中文互联网的自然发生率。[7]

狗哨语言在编码表达中强调受众差异：同一表面词对一般读者可保持普通解释，对熟悉特定社群约定者可能传递次级意义。Silent Signals [4]研究的正是这种已知表达在具体句子中的普通义/编码义消歧。这里“狗哨”作为研究对象并不要求每个实际使用者都可被确认有恶意；对个别语句的说话者意图仍需语境与独立证据。形音变体与狗哨也不是同义：前者可仅为表面变换，后者的关键在于受众共享的第二解释。有些无害的评论编码只是绕开直白评价或营造幽默，有些政治或歧视性表达则可能同时具备编码和社会风险。综述据此把形式机制、受众条件与有害判断分别记录。 [4][7]

P023 的评测进一步展示这一区分。论文 Table 2 考察是否存在编码表达，Table 3 考察评论级策略多标签，Table 4 用原始、遮蔽和词典解码后的评论预测商家星级。识别出某类策略不保证恢复其具体评价意义；星级也只是平台原始字段，既非逐例“解码正确”真值，更非危害标签。作者在同批已编码评论上比较遮蔽与解码，能够诊断形式变化对下游任务的影响，但不同编码与非编码评论的性能差异还混有话题、评论长度和星级分布。 [7]

4.2 已知编码词的实例消歧

给定词典条目时，研究问题不再是“找到这个词”，而是“本次出现是否用了词典给出的编码义”。Silent Signals 输入目标词、编码义定义及上下文，让模型在几种问法与定义下重复判断，再用输出一致性筛选高置信实例。方法实质上把社群先验作为显式输入，利用语言模型的语境判断扩充可用语料；它没有训练一个从零发明狗哨含义的解码器。作者既构建人工小评测集，也给出大规模模型筛选的正例主集；两者的

因此，编码系统的错误需要按层定位。词项型检测容易漏掉真正新形式，也可能把普通义词项误报为狗哨；固定候选解码可能排除真实新义；搜索增强系统可能得到过时或不可靠的证据；即便前三层都正确，引用他人说法、批评歧视或社群内部自述仍可能改变危害判断。第5章由此把目标群体、说话者立场、话语功能和规范性 Ground Truth 置于中心，讨论隐晦有害内容，而不把“编码”作为有害性的替代标签。 [4][31][16][6]

5 语境化隐晦有害内容检测

5.1 隐式仇恨、隐性毒性、刻板印象与非人化

不同有害内容数据集的实际标注目标并不相同，表4：语境化有害内容的 Ground Truth比较其标注对象、标签来源与可以支持的结论。

表4｜语境化有害内容研究：标注对象、GT来源与规范边界

研究与数据	实际标注对象	标注协议或样本构造	结论能够支持的范围
Latent Hatred [17]	研究对象涉及隐式仇恨及针对性类别；本项目目前只有正式出版信息和索引级材料。	原始标注者构成、具体标签协议和完整实验细节尚未在本项目取得足够原始证据。	可作为隐式仇恨研究的基础先例；不据题名或摘要补写未核实的标注细节、训练损失和实验数字。
ToxiGen [2]	约27.4万条机器生成的群体相关文本，包含有害与无害构造条件。	按目标群体及有害/无害提示组织生成；另以人工子集和人写外部测试评估数据与模型。	支持受控生成难例用于压力测试；生成提示所设定的标签不等于逐条人工确认的隐含命题、说话者立场或真实意图。
When People Are Floods [9]	移民话语中的隐喻源域是否出现；GT针对隐喻源域。	人工标注源域表达及其出现程度，并结合文档级分析。	支持对特定隐喻源域的研究；不能把隐喻标注改写成每条样本均有独立“非人化”或“仇恨”标签。
Sheep’s Skin, Wolf’s Deeds [21]	将显性有害表达改写为隐喻后，是否保持原有有害意图。	从显性有害请求构造隐喻改写，并由人工审核意图保持；在特定检测与回应提示协议下测试。	支持特定合成改写条件下可能出现漏检；正例改写不能代替真实语境中的负例控制，也不能据此估计一般分布上的误报率。
AUTALIC [6]	目标句在邻近真实社群语境中是否表达歧视性态度。	9名受训的高年级本科研究志愿者参与，每例3人标注；原始标签为-1/0/1，其中-1（不相关/上下文仍不足）先并入0，再多数投票。	作者报告Fleiss κ=0.25；总量2,400与正负分项242+2,160=2,402相差2条，原始CSV尚未核清。多数票不等于真实作者意图，也不能用κ单独判定标注者“不可靠”。

表注。 本表按Ground Truth的标注对象选取代表研究，不是第5章全部方法清单；ImpCon、SMARTER、RV-HATE和CADET见正文§5.2–§5.5。AUTALIC的数据使用须符合作者授权条件，商业用途及自动内容审核工具开发/部署有额外许可要求；在原始CSV及授权条件核实前，不自行修正论文统计。

“隐式有害”首先是标注目标的问题，而非缺少禁忌词的纯形式问题。某句可在没有粗口时传播群体刻板印象或非人化比拟；另一句含有污名化词语，却可能是受害者自述、引述后反驳或求助。隐式仇恨、广义毒性、歧视性措辞、刻板印象和非人化并非一套可互换的金标：它们在攻击对象、所需上下文、规范阈值与允许的“不确定”状态上均可能不同。以“无显性辱词”筛样，是有用的困难例代理条件，却不是每条样本都存在复杂语用含意的证明。 [2][17][6]

较早的 Latent Hatred [17]把隐式仇恨的形式类别与隐含陈述纳入基准讨论，为“分类标签以外还需解释攻击何在”提供基础研究背景；本项目对该篇目前只有官方出版信息及索引级材料，故不从其题名推写具体训练损失或实验数值。ToxiGen [2]则从数据稀缺与虚假相关出发：按目标群体与有害/无害提示组织生成示例，并在解码阶段把语言流畅度与现有分类器的错误方向结合，形成对抗难例。论文报告约 27.4 万条机器生成文本，且通过人工子集、人写外部测试及微调前后对照检验效用（§3–5、Tables 2/4）。这支持“受控生成可以丰富指定检测器的压力测试，并在所测外部数据上改善 AUC”；生成时的提示标签仍是代理，论文以词表缺失衡量的“隐式”也不能代替逐句的隐含命题或说话者立场金标。 [2]

AUTALIC [6]把这一问题推进到真实社群语境。它以有关自闭症群体的目标句及相邻句为标注对象，评价是否表达歧视性态度，而非把所有句子限定为“隐式仇恨”；某些显性措辞和医学化称谓也在语料中。相较生成语料，真实讨论让引用、回收词汇、群体内部谈话与求助更突出，却同样不能把最终多数票当作可直接观察的作者心理意图。两种数据路径分别加强了可控困难样本和社会语境的覆盖，所回答的问题不同，不能据 AUC 或 F1 横排为同一任务的优劣。 [6][2]

5.2 从分类到隐含陈述、对象与解释

如果目标不仅是输出有害/无害标签，还希望说明攻击对象与隐含命题，额外监督必须交代来自哪里。ImpCon [18]利用部分训练样本已有的 implied statements：把有害原文与隐含陈述配对，其他样本则使用词汇增强，再以分类交叉熵和实例对比目标联合训练。其跨数据集实验报告相对普通分类与纯词汇增强的收益。机制假说是让模型表征靠近较稳定的含义层，但并非每条样本都有人工隐含解释；若配对文本不保留原有立场，或对比批次中存在语义相同的“负例”，对齐损失也可能引入噪声。原文一解释向量更接近是训练目标的结果，尚不是解释忠实或真实意图复原的独立验证。 [18]

SMARTER [19]转向低资源解释式分类。作者先利用 HateCOT 等先前解释资源做辅助监督微调，再在目标任务少量带标签样本上生成正误回答与解释，使用 DPO 使模型偏好较合适的标签一解释组合，最后尝试跨模型解释 refinement。DPO 优化的是相对参考策略的回答偏好，不是单独验证每条解释与真实推理路径一致；“只用部分目标任务数据”也不等于前期解释资源、生成计算与模型权重都被省去。论文 Table 1、Fig. 3 和 Table 5 记录不同样本预算下的分类及消融，支持其特定协议的低资源效果，但模型之间的交换收益并不对称，也不能将宏 F1 的改善全部归因于 DPO 或解释质量。 [19]

RV-HATE [20]采取不同思路：簇代表对比训练、NER/语言模型辅助的目标标记、离群样本处理与困难负例构成四个分类模块，最后用 PPO 在每个数据集上寻找四组固定 logit 权重。目标标记可帮助模型关注潜在群体，但被 NER 找出的实体未必就是被攻击者；删除簇内远点也可能删除少见而真实的隐晦样本。论文 Table 1–3 的分类结果支持所报设置下模块组合的总体效果，并未把“识别对象”“恢复隐含命题”“解释忠实”逐一独立测量。本轮在附录A：固定公开源码已固定所审公开`ppo_eval.py`：该入口用test_data构造包含标签的PPO环境并以同一test_data评价优化权重。**这只证明特定公开源码路径存在验证隔离风险，不证明论文正式结果由该入口或该commit生成**；因此不能据此否定作者正式所有结果。[20]

三类方法分别增加人工隐含陈述、模型生成解释和目标标记/模块集成，其额外信息预算及训练目标差异大于名称表面相似性。真正要比较“分类到解释”的进展，至少应在同一语料上分开给出危害、目标、立场和隐含陈述的标注，并检验在删除或置换解释时预测是否合理变化。后一个要求属于综述提出的评测建议；现有跨数据集宏 F1 不能替代它。 [18][19][20]

解释优化需要扣除金标与教师知识的贡献。 SMARTER（ACL 2026 Main，CCF-A）先进行HateCOT解释SFT，再以训练gold类别构造chosen/rejected的标签一解释DPO偏好；即使不读取解释质量，正反样本的标签token也可能不同，因此其分类提升不能独立归因于解释更忠实，尚需同token的label-only

表5｜多模态非字面意义研究：任务、辅助信息与证据边界

研究与模态	任务与Ground Truth	辅助信息或训练设置	作者结果与尚未证明的事项
MultiMM [15]	中英文广告图文，8,461对；标注隐喻有无、源域、目标域及情绪极性。	作者研究情绪辅助配置；所审公开路径的测试数据会读取CSV情绪字段，但正式论文主结果与该代码路径的对应关系仍待核。	作者报告英文/中文隐喻F1分别为80.16/77.79，情绪辅助配置有收益；仍需同预算比较模型预测情绪与人工金标情绪，不能把公开路径静态观察直接说成正式实验已泄漏。
V-FLUTE [22]	6,027个图文主张实例；输出蕴含/矛盾关系及自然语言解释。部分主张和解释由模型生成后经专家审修，并非全量三名专家独立投票。	白图模型作为视觉输入对照；其余输入仍包含文字主张及任务构造信息。	特定设置下图像输入F1@0为72.78，白图为64.77；白图仍有残余表现，不能据此认定视觉信息在所有样本上不可替代；解释匹配分数不等于解释忠实性。
M3UCD [33]	15,345个图文实例；涉及隐喻类型、源/目标概念及模态、情绪、冒犯度、意图等细粒度属性。	多任务标签监督，共享LoRA；部分概念由标注者讨论或投票形成。	作者报告Complementary约58.36%，这是人工模态贡献归属类别，不是同一模型去图后的因果结果；不同任务存在正负迁移。
MGMCF [32]	图文Meme；隐喻、情绪、意图和冒犯度分类。	源域/目标域概念作为辅助文本输入；公开loader已固定，但预计算pkl字段究竟来自人工金标还是模型预测尚未独立确认。	作者报告对象特征、全局—局部交互和双语义模块的结构消融收益；尚不能把这些结果解释为等信息预算下各模块的独立因果贡献。
DOSE [23]	新闻图像与文章文本；五项主要反讽理解多选任务。	任务提示、共享/私有LoRA专家及投影正交；所审代码另有第六种变体，需与正式五项任务区分。	作者报告1%数据预算下五任务均值78.90，对比同底座LoRA的77.70；文本主导61.9%、等贡献22.5%、图像主导15.6%是人工模态归属类别，不是同模型去模态的因果准确率。
MCIB [34]	文本、音频、视频反讽二分类；使用MUStARD++R标签协议。	条件信息瓶颈、KL压缩与条件预测辅助训练；完整模型同时包含多模态表示和文本残差。	作者报告weighted-F1=75.64；去掉细粒度特征为71.19，Transformer换为MLP为74.32。没有同参数、同预算的no-CIB/no-KL/no-conditional对照，不能把完整模型收益独立归因于CIB。
MMSD3.0 [30]	多图与文本反讽基准，提出CIRM关系推理。	正式CVPR 2026 Main（CCF-A）论文已确认出版；本项目目前仅完成正式出版页和摘要级核验。	可作为多图反讽任务与方法存在的证据；未逐表核对GT、控制实验和模块消融，因此不据摘要宣称CIRM的独立收益或严格多图因果依赖。

表注。人工模态贡献归属、同一模型的text-only/image-only/joint预测变化，以及人工复标的单因素反事实，是三种不同证据，不能互相替代。比较前应分别报告原始输入、训练辅助信息和测试时额外信息的来源；公开代码静态观察不等于正式论文实验配置。

MCIB专项证据说明。论文Table 2中，完整模型weighted-F1为75.64；去掉细粒度特征后为71.19，Transformer换为MLP后为74.32，但没有单独移除CIB/KL/条件预测损失的匹配消融。另据本项目的公开代码审计，Transformer路径中预测张量与标签张量可能出现[B,1]和[B]的广播风险；最终分类表示还包含未经瓶颈约束的原始文本残差。这两项是公开实现的静态风险，**不能据此断言正式论文实验一定使用了该路径或正式结果错误**。正式run与该代码路径的对应关系仍待核。详见本轮提供的MCIB专项审计材料。

6.3 跨模态融合与多任务优化

方法从整图和整句的简单拼接，逐步转向对象线索、任务共享与任务分离。MGMCF 的输入是图像、Meme 文字及源／目标域辅助文本：文本编码、整图表示和对象区域特征经 Global–Local 双向交互更新，再把融合、文本和图像预测分支用于四项分类；训练损失包含各任务交叉熵与 Dual-Semantic 项。其英文 MET-MEME 实验的 Table 2 显示移除对象、Global–Local 或辅助损失后部分分类指标下降。这支持完整配置在特定数据和输入字段下的经验收益，却不等于对象分支已准确定位非字面映射，更不等于删除一个分支就完成了“只看单模态”的严格对照。 [32]

M3UCD 的 MCLF 让同一图文样本配合不同任务指令，冻结多模态基座并共享 LoRA 增量，以各任务标签的训练损失优化预测。情绪、意图和概念在这里是并列监督，不存在已证实的“先识别情绪，再恢复隐喻”的必经计算路径。论文 Table 4 中，同一 Qwen2.5-VL-7B 设置的源／目标模态分类 macro-F1 有所增加，而情绪及隐喻检测 macro-F1 下降；正负迁移并存，故不能用总体多任务优势掩盖任务级代价。公平比较还需匹配总训练样本、token、更新步数和参数预算。 [33]

DOSE [23]把反讽检测扩展到机制、描述、对象和意图等选择任务。输入为新闻图文及任务指令，输出相应类别或多选答案；训练数据的候选解释和难负例含生成辅助与人工审校。方法为每个低秩专家设置 shared／private 两组参数，以样本内容和任务身份混合路由，并惩罚两组输出投影的几何重叠。论文 Table 3在Qwen3-VL-8B的1%训练预算下报告五主任务等权Accuracy为78.90，LoRA为77.70；Table 4去正交项的总体成绩下降，Target单项却高于完整模型。作者对反讽正例的模态贡献标注还报告文本主导约61.9%、图文相当约22.5%、图像主导约15.6%，这些是**人工归属类别，不是同模型去图去文的实际准确率**。这说明模块组合有经验价值，并显示任务之间仍可能权衡。参数正交不直接测量不同任务的梯度冲突；选择题准确率也不能改写为自由文本解释忠实率。 [23]

三种方法分别优化局部线索交换、共享任务适配和专家参数分离。它们的主表与消融支持各自报告协议中的预测表现，无法在不同金标、基座、辅助字段和训练预算之间排出“语义理解能力”总榜。DOSE 所称双流是参数子空间，而非严格互斥的图像流和文本流；这一点也提醒读者不要把结构命名当成模态必要性实验。 [33][32][23]

6.4 情绪、多义与附加金信息

情绪可能帮助解释同一视觉对象为何对应不同隐喻或反讽，但“情绪是相关线索”与“部署时模型能自行获得情绪线索”是不同命题。MultiMM的SEMD报告英文/中文广告隐喻F1分别为80.16/77.79，作者情绪消融在相应协议下有收益。本轮附录A：固定公开源码固定的MultiMM公开`code_metaphor/data_utils.py`确实对train/val/test按同一规则从CSV字段生成情绪提示，但是否对应正式论文主表训练或测试入口仍O。可以说该公开路径有**额外情绪字段输入**，不能将其不加条件地概括成论文主表测试金标已泄漏或作者实验违规。稳妥结论是：情绪辅助配置可在相应输入条件下取得经验收益，真正部署的纯原图文能力还需分别报告缺失/模型预测/gold情绪三种预算。 [15]

MGMCF的源域和目标域辅助概念字段使输入预算问题更直接：如果任务输出是隐喻或情绪类别，而测试时还提供域概念，模型获得了与解释相关的额外先验。原论文定义了这些输入，附录A：固定公开源码已固定的MGMCF公开`loaddata.py`表明train/val/test从相同加载流程取得预计算source/target特征，但这些pkl究竟来自人工gold、模型预测或外部数据仍未实物溯源。Dual-Semantic损失与论文的实现对照尚未在此固定为可单独复核的执行路径，不能据目前证据断言正式实验失效。与M3UCD将源/目标作为预测对象不同，必须首先在**表5（多模态非字面意义表）**分清输入的概念先验与输出的预测标签。 [32]

意图和对象标签同样属于标注者对文本效果的操作判断。DOSE 的多选题可能受到选项位置、长度或模板线索影响；项目只在公开 1% 训练子集观察到相关风险信号，不能外推为完整测试集偏差已证。比较情绪、源／目标与意图的实际作用，需同时报告无辅助、模型预测辅助、人工金标辅助三种输入，固定基座和预算，并分别测分类与解释；这些是综述提出的验证方案，而非现有论文已全部完成的控制实验。 [23]

6.5 视觉／音视频捷径与条件信息瓶颈

多模态模型的性能增益可能来自真正的互补关系，也可能来自转写文字、数据来源、选项格式或一项强模态。V-FLUTE 将真实图片替换为白图并重新训练，提供了图像有用性的一个诊断；但白图改变输入分布，数据来源与正负例构造仍可能留在文字中。其 F1@0 是蕴含标签 macro-F1，F1@53／60 还按解释与参考文本的相似性阈值将标签计错；该阈值曾在测试抽样的人评子集校准，不能当作严格独立的解释忠实评价。论文 Appendix H 中 GPT-4o 的少样本结果亦说明“最佳微调模型”不等于全篇所有设置的最高值。 [22]

MCIB [34]针对音频、视频和文本反讽检测提出条件信息瓶颈融合。其模型编码三种输入、构建细粒度模态表示，用条件预测与压缩目标约束融合特征，最后输出二元反讽标签；训练仍使用已有反讽金标，推理时不需要人工风险标签。作者在 MUStARD++R 上报告完整配置 weighted F1 为 75.64；正式论文 Table 2 的去细粒度表示为 71.19、以 MLP 替代 Transformer 为 74.32。这些是整体模型及结构替代的证据，不是“只去条件信息瓶颈、其他不变”的独立消融，因此不能把差值全归于瓶颈模块，更不能称其已因果消除捷径。 [34]

本轮附录A：固定公开源码将MCIB公开Transformer实现固定为特定commit：条件loss对标签`squeeze`后直接计算MSE，若输入形状为[B,1]与[B]会发生跨样本广播风险；分类路径还可见融合输出与原文本x相加。**代码行已可外部复核，但真实batch形状、是否激活该路径及其与正式论文训练的对应关系仍O**，因此不能声称作者正式实验的损失已被复现证明错误。该方向的真正机制独立证据应是同参数同预算的无KL、无条件预测及双无控制，并结合受控模态置换检验决策是否真正依赖互补特征；结构消融和weighted-F1只能支持作者当前完整方法的经验效果。 [34]



图4｜跨模态研究：输入信息与验证方式。 应区分原始任务输入、辅助信息及其提供阶段，并分别通过单模态/联合输入对照、额外信息控制和有效反事实验证模态贡献与模型依赖。模态消融只能反映相应协议下的性能差异，正确的跨模态依赖仍需独立真值与受控干预。

表6｜多模态风险与安全回应：输入识别和输出行为分开评价

A. 输入风险真值与显式风险判断

研究与任务	输入真值与标注协议	模型预测或训练目标	证据边界
Hateful Memes [39]	图文仇恨二分类标签；不是图像Safe、文本Safe、联合Unsafe的三条件GT。	研究重点为图文联合分类。	普通图文仇恨分类基准不能被整体称为严格S-S-U数据。
MMSafeAware [27]	作者报告Unsafe 1,000、Over-Safe 500及三向人工筛选；发布版文件和图像差异尚未固定。	联合Safe/Unsafe分类。	2:1比例下恒判Unsafe的总Accuracy已达66.67%；应同时报告Unsafe召回与Safe召回，不能只报总准确率。发布版精细数量仍为待核。
VLSU输入分类 [36]	正式PDF报告8,187条、17个模型；官方摘要写11个模型；所查公开CSV为8,159条；严格S-S-U分别为37/35条。三类标签为Safe、Borderline、Unsafe。	显式三级输入风险分类；Table 1为兼容旧基准另设二分类，并将Borderline并入Safe。	正式PDF、摘要和公开CSV版本口径不同；不能把二分类结果与正式三级结果直接换算。公开CSV另有141条image_grade=not_sure。
CrossGuard输入Guard [24]	1,616条Guard混合训练数据，联合类约占12.5%（约202条为估算）；ImpForge另有1,390条红队样本，尚未逐例映射。	使用LoRA/SFT训练图文Safe/Unsafe Guard。	SIUO中Guard ASR报告60.33→5.39%，但训练数据量与类别构成也发生变化；不能把全部收益归因于新分类架构。FigStep为0.12→0.21，并非所有基准都单调改善。
ThinkingGuard输入风险归因 [41]	作者报告TriggerBench共5,600条，Safe/Unsafe各2,800；图片分别生成，配对不等于只改变Trigger。	风险标签和五步分析；SA-MCTS离线搜索轨迹，Trajectory-DPO与Step-DPO更新模型。	作者Table 3的Unsafe F1由0.779升至0.810，Recall由0.699升至0.749；额外Unsafe监督、训练token和配对图像的单因素有效性尚未独立控制。作者称ACM MM 2026录用，会议CCF-A，正式Track仍待核。

B. 生成式回应、攻击行为与回应质量

研究与任务	输入或触发条件	实际观察的回应与指标	不能混同的内容
VLSBench回应评测 [25]	比较模型面对图文风险、仅文本或附加图像描述时的回应。	Safe Rate按Refusal+Warning统计；Qwen2-VL-7B特定200例中，text为29.5%、text+image description为22.5%、image+text为16.0%。	这些是回应比例，不是输入风险分类准确率；必须说明提示、模型和样本分母。
VLSU安全回应提示 [36]	同一模型和请求，将推理提示从Harmless改为Helpful。	Gemini-1.5的Borderline拒答62.4%→10.4%，Unsafe拒答90.8%→53.9%；QwenVL-32B的Borderline拒答23.4%→30.7%，Unsafe拒答71.2%→57.5%。	这是回应策略变化，不是显式输入分类P_{in}的变化；模型间趋势并不一致。
MSSBench情境回应 [37]	1,960个图文情境请求；Chat与Embodied设置的行动能力不同。	IF Judge评价情境行动或回答；部分设置可额外提供Oracle环境状态。	Oracle环境事实改变了信息预算；Judge评分不是模型内部风险分类标签。
MOSSBench过度拒答 [38]	作者目标安全图文请求300条；约9%的人工判断对能否安全作答存在争议。	安全主集上的ARR为拒答比例；危险对照可另行测量。	安全侧误拒不是输入分类FPR；发布版contrast配对和ID映射未完全固定，不能把全部样本称为严格单因素配对。
SIUO攻击回应 [26]	表面安全的跨模态输入可能诱导模型给出危险回复；不提供VLSU式三条件人审输入GT。	输出Safe Rate或攻击成功率，包含人工与AI辅助构造子集及Judge参考信息；NAACL 2025 Findings，会议CCF-B，非Main。	行为攻击评测不能并入输入风险三分类准确率；Judge、参考安全警示及样本构造方式必须单独说明。
ImpForge红队生成 [24]	生成隐晦联合攻击图文，PPO优化文本改写器并结合图像生成。	观察被测模型是否产生不安全回应，即攻击成功率。	攻击成功率不是Guard漏检率；PPO必要性仍需与同预算检索、Best-of-N等控制比较。
Meerkat-VL安全有用回应 [35]	训练材料包含user_intent、harmful_intent和safety_warning等规范风险说明。	Cold-start SFT、同Actor NPSV评分、一致性惩罚DPCA及GRPO优化安全且有帮助的回答。	训练评分使用风险文本，但不重新读取原图；不等于独立视觉验证。模型Judge与帮助性评价应分别报告。

表注。 输入风险真值、显式风险分类、实际回应行为和输出安全/帮助性质量是不同评价对象。危险输入上的漏判、安全输入上的误报、不安全帮助和正常请求误拒应分别报告。不同论文中的ASR可能分别指攻击得逞、Guard漏检或生成危险回复，必须同时给出主体、Judge和分母。S-S-U只是严格联合风险的一个子类。

7.3 检测器、触发归因与反事实训练

在明确输入风险标签之后，方法研究才可分析哪种图文关系触发风险。CrossGuard [24]包含两种不同学习对象：ImpForge固定视觉场景，使用PPO改写有害请求以生成**红队攻击图文**；随后CrossGuard使用LLaVA基座及LoRA/SFT从混合Safe/Unsafe数据训练**输入Guard**。论文Figure6的ImpForge **1390条**属于生成攻击评测集，Figure7的**1616条**是Guard混合训练集，其中联合隐含恶意类占约**12.5%≈202条**（比例近似推算，不是作者公布精确202条ID）。当前无逐样本索引证据证明这约202条究竟是1390中的哪部分，也不能说1390条全部进入1616训练集。

作者Figure4将有无ImpForge联合类训练数据对照：SIUO防护ASR **60.33→5.39%**、MM-SafetyBench **10.20→0.38%**，但FigStep **0.12→0.21%**小幅变差，因而可说部分联合隐含防护基准显著改善，不能说所有基准都单调改善。新增数据数量/类别比例也变了，不能将全部收益归因于PPO本

仍O。DPCA把分析与回答的安全/帮助评分差异作为一致性惩罚，最终通过GRPO更新；一致性值为零只代表分数吻合，不能保证视觉事实或规范判断正确。作者报告综合回复安全/帮助改善，但本项目没有独立核完正式ICML论文的逐项基线/消融数字；因此只能把独立NPSV、DPCA与额外风险知识的贡献列为待同预算对照，不冒称自验证是独立重新看图。 [35]

VLSU（ICLR 2026，CCF-A）的同模型行为提示提供具体**安全—帮助性双侧权衡**：对Gemini-1.5仅把推理时提示从Harmless换到Helpful，Borderline输入上的拒答率由62.4%降至10.4%，但Unsafe输入拒答率也由90.8%降至53.9%。这不是SFT/PPO重训练，也不是风险分类F1变化；前者提示过度拒绝可能降低，后者提醒危险请求的拒绝同样下降，不能只挑有利一侧解读。与MOSSBench的正常请求误拒和Meerkat-VL的训练后回应一起看，研究问题应是能否在相同模型/政策/Judge下改善两侧，而不能把异构数据集拼成统一Pareto曲线。 [36][38][35]

VLSU 的拒答／帮助性实验、MSSBench 的情境行动、MOSSBench 的正常请求误拒和 Meerkat-VL 的安全回应，分别对响应链的不同层施压。SIUO 的攻击成功率关注危险输出，MMSafeAware 的危险召回关注输入判别。即使数字看似都以百分比报告，拒答率、ASR、分类 F1 和安全回复率也不能换算为同一个“安全性能”。尤其不能把高拒答率视作模型已经识别图文组合的风险来源。 [36][37][38][27][35][26]



图5｜多模态安全评价：风险判断与回应行为。 输入风险分类依据外部风险真值评价模型显式预测；生成式安全回应则考察实际行为及输出的安全性与帮助性。危险请求的风险漏判和不安全帮助、正常请求的分类误报和不必要拒答应分别报告，不能通过拒答与否倒推模型的内部风险判断。

7.5 正负两侧评价与失败归因

安全系统的失败有两面。在输入分类协议中，危险样本被判 Safe 是漏检，安全样本被判 Unsafe 是误报；在回应协议中，危险请求收到可执行有害帮助与正常请求被拒绝是不同错误。前两者依赖 G_{in} 与显式 P_{in}，后两者依赖 R_{beh}、Q_{out} 和相应人工或评审器标准。一个方法可降低危险侧漏检，却扩大安全侧误拒；若只报总 Accuracy 或总拒答率，这种代价会被类别比例遮盖。MMSafeAware 的 2:1 设计、MOSSBench 的安全主集和 VLSU 对 Safe／Borderline／Unsafe 的分组，正好说明需要同时呈现条件分母、两侧召回与策略质量。 [27][38][36]

表7｜跨子域方法族：优化对象、直接证据与未闭合问题

方法族	代表研究（正式出处与CCF等级）	方法实际改变什么	现有证据与关键边界
概率语用推断	$(RSA)^2$（ACL 2025 Main，CCF-A）	在给定候选意义、语境和修辞策略下，建模说话者/听者的概率推断；不依赖新增类别微调。	正式实验显示修辞策略和意义先验会改变候选意义概率；这支持候选空间内的概率推断，不等于开放式释义或真实心理意图读取。
提示式含意与行动选择	DRInQ（ACL 2026 Main，CCF-A）；VAGUE（ICCV 2025 Main，CCF-A）	冻结LLM/MLLM，通过上下文示例、解释提示或CoT完成候选含意/行动选择。	部分模型因解释提示而提升，另一些模型下降或不变；提示收益不具有跨模型单调性，也不证明解释忠实。
编码词项与检索辅助	Silent Signals（ACL 2024 Main，CCF-A）；FETCH!（ACL 2025 Main，CCF-A）；FA-Net（AAAI 2024 Technical，CCF-A）；SeTox（ACL 2026 Main，CCF-A）	分别使用已知编码义、种子词典、固定目标类别或在线检索；其预测单位包括实例义、词项类型、候选目标义和毒性标签。	证明不同先验可支持各自定义任务；不能把它们合称为统一开放词义发现，也不能横排Precision、Acc@k和毒性F1。
监督表示学习与多模态融合	ImpCon（COLING 2022 Main，会议CCF-B）；MGMCF（AAAI 2025 Technical，CCF-A）；M3UCD（AAAI 2026 Technical，CCF-A）；MultiMM（ACL 2025 Main，CCF-A）；DOSE（ACL 2026 Main，CCF-A）	使用对比学习、多任务标签、源/目标概念、情绪辅助、共享/私有LoRA或任务专家，改变表示和融合方式。	作者报告了各自协议下的性能收益，也有负迁移和额外监督；结构消融或人工模态归属不能单独证明因果机制或模态必要性。
信息瓶颈与条件压缩	MCIB（AAAI 2026 Technical，CCF-A）	将条件预测、KL压缩与多模态表示结合，用于音视频文本反讽分类。	完整配置报告weighted-F1=75.64；现有消融未单独隔离CIB损失。公开Transformer实现还存在潜在维度广播风险及原始文本残差路径，正式run对应关系仍未核实。
解释与轨迹偏好优化	SMARTER（ACL 2026 Main，CCF-A）；ExPO-HM（ICLR 2026，CCF-A）；ThinkingGuard（ACM MM 2026，会议CCF-A，正式Track待核）	分别使用标签—解释DPO、政策SFT+课程GRPO+CDE，以及离线SA-MCTS轨迹与Step-DPO；优化目标分别是毒性分类、仇恨Meme解释后检测和输入风险归因。	作者报告的性能收益来自不同监督对象与训练协议；额外教师信息、gold标签、Unsafe偏好和token预算尚未完全匹配，不能把收益统一归因于解释或逐步推理。
红队攻击生成与输入Guard	ImpForge/CrossGuard（ACL 2026 Main，CCF-A）	ImpForge用PPO优化隐晦攻击改写；CrossGuard用LoRA/SFT训练图文Safe/Unsafe Guard。	攻击成功率、Guard漏检率和生成模型危险回应率是不同指标；训练数据量与类别组成也会影响结果，不能把全部提升归因于分类架构。
安全回应对齐与行为评价	Meerkat-VL（ICML 2026 Main，CCF-A）；VLSU（ICLR 2026，CCF-A）	Meerkat-VL通过SFT和GRPO优化安全且有帮助的回答；VLSU的Harmless/Helpful提示实验则在冻结模型上比较回应策略，不更新参数。	回应安全性、帮助性和拒答行为可发生不同方向变化；它们不等同于显式输入风险分类，也不能据拒答率反推模型内部风险判断。

表注。 本表按方法实际优化对象归纳，不构成跨任务排行榜。各论文的具体数据、指标和GT见表3–表6；第8.1.1节C1–C3负责跨子域条件性综合，本表不重复其全部数字。CCF等级按项目采用的2026年第七版目录口径；Findings、Technical、Main和作者录用但正式Track未核的状态分别标明，不以会议整体等级替代论文Track信息。