广义隐晦信息的理解与检测：语用、修辞、编码语言及多模态研究综述

摘要： 隐晦信息的理解不仅要求推断字面之外的含义，还可能涉及交际意图、立场及危害判断。会话含意、隐喻、反讽和狗哨、谐音等编码表达依赖语境与社群知识；隐晦有害内容进一步涉及攻击对象和规范性判断，而图文组合可能形成单一模态难以识别的意义或风险。围绕这些问题，相关研究形成了语用与修辞理解、编码语言与动态词义分析、语境化有害内容检测以及多模态意义与安全评估等方向，并发展出概率语用建模、监督与对比学习、检索增强、多模态融合及大模型安全对齐等方法。然而，不同研究的预测目标、标注依据、输入信息和评价指标存在差异，仅凭模型在特定基准上的性能表现，难以判断其是否真正理解隐含意义。本文梳理上述领域的核心任务、数据资源与方法进展，区分表达识别、意义解释、有害判断和安全回应，并重点比较训练与测试阶段的可用信息、标注真值和评价协议。本文归纳三项跨研究方向的认识：词典、候选意义与检索先验限定了开放语义能力的可测范围；解释生成或解释监督带来的性能提升，并不能直接证明模型生成的解释真实反映了其决策依据；调整模型的安全回应策略可能减少对正常请求的过度拒绝，但也可能降低其对危险请求的拒绝程度。最后，本文讨论标注分歧、数据捷径、跨模态依赖和版本差异对研究结论的影响，并提出受控对照、反事实验证与双侧安全评价的后续研究方向。

关键词： 隐晦信息；计算语用；修辞理解；编码语言；隐式有害内容；多模态风险

1 引言

1.1 背景与研究动机

在语言交流中，一段表达所传递的信息并不总能从其字面形式中直接、充分地确定。说话者可能通过间接言语行为、会话含意、隐喻与反讽传递超出字面断言的意思，也可能使用某一社群共享的暗语、谐音或不断变化的词义进行交流。在包含图像、音频或视频的场景中，文字与其他模态之间的语义关系又可能改变解释对象、评价立场乃至风险判断。上述现象并不天然具有恶意：相同的非字面或编码策略既可能服务于幽默、艺术与身份表达，也可能出现在隐晦歧视、攻击性言论或规避内容审核的交际情境中。

这一复杂性为计算模型提出了不同层次的问题。首先，模型需要判断是否出现特定表达现象，例如反讽、隐喻或编码词；其次，模型可能需要推断实例中的候选意义、相关对象和交际作用；最后，在涉及内容安全的应用中，模型还必须根据目标、立场、语境和具体规范判断是否存在伤害。上述层次相互关联，却分别对应不同的预测目标与标注对象。检测到隐喻并不能直接推出某句具有仇恨意图；能够为一句话生成流畅解释，也不能自动证明模型的分类判断确实依赖该解释。作为本领域基础的计算语用学研究亦特别强调，应将被评测的语言现象、任务形式与模型能力区别开来，参见[1]。



图1｜广义隐晦信息的研究框架。 本文从意义形成机制、研究任务与评价依据组织广义隐晦信息研究。语用推断、修辞表达与社群编码可以相互交叉；跨模态组合则描述不同信息来源之间的关系。T1–T3关注表达和意义，T4/T5关注危害判断，T6关注安全回应。实验比较应核对输入信息、标注依据与评价方式，图中分组不表示固定处理流程。

已有研究从多个独立方向推进这些问题。隐式有害内容方面，[2]等数据集将缺乏显性攻击性词汇的仇恨表达作为独立检测难点；语用与修辞方面，[3]研究修辞策略条件下的概率语用推断；编码语言方面，[4]与[5]分别研究已知狗哨表达的实例义消歧与词项发现；跨模态方面，[39]与[36]从不同侧面推动了图文关系和联合风险的可测评价。这些工作并不组成一个可直接比较排行榜的统一任务，却在“何种证据足以支持某一解释或判断”的问题上逐渐形成交叉。

近年来，LLM与MLLM的出现进一步拓展了可操作的研究形式：提示与检索能够引入动态知识，多任务训练可以同时预测现象、目标及辅助属性，偏好优化与强化学习则可将风险判断和模型回复策略纳入训练。然而，模型规模、推理链长度或融合层数的增加，并不直接说明模型已使用正确的语境与模态证据。以多模态反讽为例，[34]研究角色、笑声和辅助情绪标记等数据捷径，并以条件信息瓶颈构造融合机制；该方向说明可靠性已成为显式研究议题，但其中对信息瓶颈模块独立贡献的证据仍须按原论文消融和实现协议作限定。对有害内容判断而言，[6]还展示了社群内部使用、引用和反用等真实话语环境下的标注分歧。因而，本综述不仅关心模型在既定测试集上的预测正确率，也关注Ground Truth究竟刻画了何种意义、哪些输入信息在测试时可用，以及预测错误能否被可靠地归因。

1.2 综述范围与相关研究的关系

本文使用“广义隐晦信息”作为一个**操作性综述范畴**，指语言或多模态交际中，目标意义、立场或交际作用不能仅由显式字面内容充分确定，而需结合语境、修辞映射、社群约定、编码形式或模态间关系来推断的信息。该定义旨在跨任务组织文献，**并不声称“广义隐晦信息研究”已是各子学科公认的统一研究名称**。隐含（implicit）强调意义或意图未被直接表达，而不易察觉（subtle）强调相关线索不够明显，二者并不等同；编码（coded）不等于必然恶意隐藏；语境依赖不必然产生非字面意义；有害性判断还涉及目标、规范及评价政策。具体的包含关系与反例在第2章给出。

与侧重某一修辞现象、语用能力或有害内容种类的现有综述相比，本文采用交叉问题驱动的编排方式。已有[1]系统总结语用能力的数据与评价问题，Mao等的正式语用处理综述及相关的隐式仇恨、中文毒性、多模态仇恨和反讽综述亦各有其纳入边界 [50]。本文的差异不在于宣称这些方向“此前没有综述”，而是在同一框架中分别定位表达机制、预测任务、模态条件和证据可靠性，避免把非有害修辞直接视为隐式仇恨的一个子类。

研究范围包括四组核心材料。第一组讨论会话含意、间接言语行为与修辞表达的识别和意义解释；第二组涉及社群编码、狗哨、音形变体及动态词义；第三组讨论隐式有害内容的目标、立场与规范性标签；第四组研究图文、音视频与多图中的非字面意义及**需要联合模态证据的风险判断**。其中，单一图像或文字各自安全、组合后有害（S-S-U）只是更严格的联合条件子类，不能代表全部多模态风险研究。安全响应研究仅在与隐含风险识别、过度拒答或安全一帮助性评价直接相关时纳入。一般的显式毒性分类、任意上下文指称消歧、传统隐写、通用RLHF和普通视觉识别不因“输入含语境”或“输出分类标签”而自动成为本文核心研究。

已有综述已经分析任务、数据、标注与评价，本文不把这些维度本身作为首创。下表在同一“研究／评价单位”上说明重叠，并指向本稿新增的条件比较产物；增量是重新组织原论文证据后得到的H级结论，不是先行综述未曾讨论任何类似问题的证明。

先行综述／发表信息	已有研究／评价单位与实证覆盖	本稿新增的跨子域比较产物及可回答的问题
Ma等 [1]；ACL 2025 Main，CCF-A	以语用现象、数据资源、任务设计、采集与评价为单位；已有数据与GT分析，不能称只做主题罗列。正式全文	将含意选择中的“先解释”与仇恨Meme的解释奖励分开编码：为何更多解释不预测单向收益？§8.1.1 C2同时呈现DRInQ正负变化、ExPO-HM监督收益及混杂。
Farabi等 [43]；IJCAI 2024 Survey Track，会议CCF-B（项目2026目录口径）	2018–2023多模态反讽的模型、模态、数据集与评测；已有跨模态方法比较。正式全文	将视觉意图的解释提示与文本含意、仇恨分类的解释训练放在同一“监督对象／测试证据”坐标，而非据是否有CoT排名；见C2及协议实例表。
Hee等 [28]；EMNLP 2024 Findings，会议CCF-B，非Main	跨文本／图像／音频的仇恨检测、解释、去偏与反言语，已有检测与响应区分。正式全文	把危害解释训练与无害含意的解释提示对照（C2），并把安全回应中的双侧代价与修辞解释的字面子群代价相连（C3）；不以“首次检测到响应”宣称增量。
Mao等 [50]；*Information Fusion* 114 (2025), 102712，CCF目录未收录（本次检索）	正式综述已综合语用处理的任务与方法；本稿以其为相邻工作，承认既有语用任务／技术体系，不声称首创语用处理综述。出版入口	本稿的新增产物仍限于§8.1.1的跨子域条件比较及相反子群结果；没有把Mao的综述结论当作新实验事实。
Ye等 [49]；arXiv:2502.14881v1，预印本，CCF不适用／正式状态未核	**仅按作者摘要与章节目录确认**：生命周期中的攻击、防御和评估，含Janus-Pro实测；不声称本轮全文／各表审计。作者版本	C3把“Harmless／Helpful改变拒答”与“修辞策略改变候选概率”比较为输出偏好重分配的条件证据；可检验共同结构，不据安全总分推断通用理解。
Kühn等 [42]；ACM Computing Surveys 58(2)，项目登记CCF未收录	少见修辞格定义、数据与检测；已存在修辞体系综述，具体覆盖时间窗未逐项复核。正式出处	C1用有限候选反讽与编码词项回收对照“可测开放度”，C3给字面负例的实测代价；不把修辞标签直接升级为危害GT。

表注。对Ma、Farabi、Hee及Mao的范围判断依据正式出版摘要／既有证据，不伪称完成逐表穷尽比较；Ye只作摘要级竞争背景。本文没有证明其他综述完全缺少这些见解；可核增量是§8.1.1按同一列定义呈现的跨子域正反证据及其可证伪条件，而非“覆盖更宽”或优先权断言。

在编排上，本综述同时保留研究历史和技术机制两种横向视角，但不把它们写成单一的进步代际。例如，词典与概率语用模型、PLM监督学习、检索增强以及多模态融合在不同任务中仍可能持续共存。我们关注的是各方法解决了哪个具体目标、在什么信息和标注条件下报告有效，以及哪些能力尚未由对应实验直接证明。

现有相关综述与本文有实质重叠，不宜只凭跨子域范围较广就宣称首次发现。Ma等（ACL 2025 Main，CCF-A）已系统整理LLM语用任务、数据与评测；Farabi等（IJCAI 2024 Survey Track，会议CCF-B）已讨论多模态反讽；Hee等（EMNLP 2024 Findings，会议CCF-B、非Main）涉及多模态仇恨审核。本文的独特分析对象不是简单增加论文种类，而是把各研究的预测目标、训练/测试信息预算、Ground Truth来源、有效的正面结果与相反实验放在同一证据比较中；第8章给出三条有明确适用条件的跨领域综合结论，不作跨任务绝对分数排名。 [1][43][28]

1.3 研究问题与本文贡献

围绕上述研究范围，本文着重回答五个问题：其一，什么样的表达机制会使字面信息不足，如何区别表达识别、意义恢复与交际意图推断；其二，语境、社群及时间变化如何影响词义判定与泛化；其三，隐含意义与有害性在何种规范和证据条件下相关，又为何不能直接互推；其四，多模态信息何时提供不可替代的语义证据，如何识别文本泄漏和额外信息捷径；其五，如何在同一研究地图中分别衡量输入风险、模型输出行为、解释质量与安全—帮助性的权衡。

本文提供三个可核对的综述分析产物，而非原创训练实验。第一，将语用/修辞/编码等表达机制，与社会规范危害和安全回应分层，采用T1–T6及 Task = (X, Y, G, E) 对齐各自的输入、标签、指标和证据。第二，以真实论文的训练与测试先验、监督对象、正面结果和失败边界为单位，在表3–表7跨领域比较，而不把不同任务的F1、ASR或解释分数排成一个模型排行榜。第三，第8章以正反证据建立三条条件性综合结论：先验限定可测意义空间；解释收益取决于监督对象和推理协议；全局解释／行为偏好可能重新分配互补子群的错误。各结论都是本综述的H级归纳，既不宣称首创相关任务，也不声称本稿完成新的实验复现。

本文采用批判性叙述综述的方法，重点分析与隐晦意义理解、编码语言、有害内容检测及多模态安全相关的代表性研究。文献比较优先依据正式出版论文及可核验的实验结果；本文不以系统检索覆盖率为目标，也不直接比较评价协议不同的模型分数。

本文结构

第2章介绍概念、理论和统一任务体系；第3、4章分别讨论文本修辞/语用意义和编码语言；第5章分析语境化有害判断；第6章研究多模态非字面意义；第7章区分联合输入风险与安全响应；第8章横向比较方法及证据可靠性；第9章总结可证的进展与待验证方向。

2 概念、理论基础与任务体系

2.1 语义、语用与非字面意义：理论和术语边界

在实际语言交际中，话语所传递的意义并不总能由其词汇和句法结构直接确定。除了语言表达的常规意义，听者还需要结合会话语境、交际双方的共同知识以及说话者的交际意图，推断话语中未被直接表达的含义。Grice的会话含意理论从合作原则出发，解释了交际者如何传递和理解超出明示内容的信息 [44]；Searle的言语行为理论及其关于间接言语行为的研究，进一步揭示了语言表达形式与实际交际功能之间的关系 [45][48]。在计算建模层面，Frank与Goodman将说话者的表达选择和听者的意义推断引入概率框架，为语用推理提供了可计算的研究方法 [46]。这些研究为理解会话含意、间接表达及其他依赖语境的隐含意义现象提供了理论基础。

以一句表面疑问“你能把窗户关上吗？”为例，系统可以识别其疑问句形式，亦可以在具体生活情境中将其解释为间接请求。前者是句法/字面层的识别，后者涉及言语行为。再如“真是准时啊”在迟到的会话语境中可能表达反讽，而在实际准点的语境中也可能是真诚评价。同一表达在不同语境中可能具有不同的交际意义，因此对说话者意图的判断应建立在具体的交际情境和可获得的证据之上。

工作性定义与概念边界

本文采用以下工作性定义：**广义隐晦信息是指在语言或多模态交际中，其研究关注的意义、评价立场或交际功能不能仅由直接字面表达充分确定，因而需要额外的语境、语用推理、修辞映射、社群约定、编码形式或模态间关系才能获得可信解释的信息。**该定义旨在组织不同研究谱系的任务边界，不是主张这些文献已经采用共同的“隐晦信息”官方标签体系。

必须区分的概念如下：

为避免把意义现象、表达形式、语境条件和规范性判断混为同一层级，表1：概念与任务边界区分相关概念的适用范围与证据边界。

表1｜广义隐晦信息相关概念的层级与边界

层次	概念	核心判断问题	主要证据	不能直接推出的结论
综述范畴	广义隐晦信息	目标意义、立场或交际功能能否仅由显式字面内容充分确定?	语境、语用推理、修辞映射、社群约定、编码形式或模态关系	本文的工作性组织范畴，不是各子领域共同采用的正式标签；不预设内容有害
意义现象	隐含意义	是否需要推断未被直接表达的命题、行动或立场?	会话上下文、共同知识、言语行为及表达选择	不必是非字面表达，也不必意味着说话者有意隐藏
意义现象	修辞／非字面意义	字面形式是否通过映射、反差等方式传达其他含义?	源域—目标域映射、语境反差及修辞结构	不自动意味着欺骗、隐藏意图或有害
社群约定	编码语言	某种表达是否依据社群约定承载特定的次级意义?	社群用法、跨语境实例、社群与时间信息	生僻词或形式变体不必然具有编码义；编码不自动有害
社群约定（子类）	狗哨语言	同一表面表达是否面向不同受众保留普通义与社群特定的次级义?	受众知识差异、具体语境中的编码义实例及社群证据	狗哨是编码语言中的特定现象，不是所有暗语的同义词；不能仅凭词项确认使用者恶意
表达显著性	不易察觉的表达	相关线索是否强度较低、不显著或不易察觉?	线索显著性、表达强度及具体语境	细微不等于隐含；直接表达也可能很细微
表达形式	形音变体	是否通过读音、拼写、字形或符号变化形成替代表达?	变体与原表达之间的语音、字形或符号关系	形式变化不自动意味着规避审核或隐藏语义
解释条件	语境依赖	解释是否随场景、会话、社群或时间变化?	对照语境、会话轮次、社群知识及时间信息	语境依赖是解释条件，不是独立修辞类型；普通指称消歧不自动属于核心任务
规范判断	有害性	在指定政策、目标和受众条件下，内容是否构成伤害?	攻击对象、说话者立场、话语功能、社会语境及适用政策	有害内容可以显性或隐晦表达；不能由隐喻、反讽或编码标签直接推出

表注。 各行属于不同分析层级，允许在同一实例中交叉出现，并非互斥类别。本文所说的“广义隐晦信息”是用于组织相关研究的工作性范畴；表达机制、语境条件与规范性危害判断应分别分析。术语与语用任务参见 [1][7][4][5]。

“Dog Whistle”在本文中属于具有受众知识差异或多重受众解释机制的重要编码现象，但**不是所有编码语言的同义词**；是否存在有意双层沟通需看具体研究证据。[4]研究已知狗哨编码义的语境使用判定，而[5]研究词项发现，两者即使包含相似词汇也不具有相同预测标签。[7]则展示了中文编码策略和应用任务的关联，但出现编码并不自动代表仇恨或违规。

这些概念**可以相交但不能互为定义**。一段表达可能既是反讽又具有编码社群义，但无害；也可能没有任何隐喻或暗语，却借上下文表达隐含的群体偏见。另一方面，单纯视觉不完整或文本指代歧义，如果没有明确的隐含/非字面/编码/风险研究目标，应作为相邻语境理解而不是核心收录对象。

包含与排除的四个判定例。 无害隐喻若研究源目标映射，仍是T1/T2核心；只把谐音字符还原为常用字而不涉及社群编码义的任务是邻接信息处理；普通图文有害Meme可以属于T4，却不自动具备T5严格图、文单独Safe而组合Unsafe的标签；纯显式危险请求的泛化RLHF不作为隐晦意义核心方法，但直接研究组合风险后的误拒与帮助性时可作为相邻T6。纳入的判断对象是**预测目标、语义机制及其真值**，而非数据中是否出现“图像”“情绪”或“安全”一词。

2.2 五轴任务与证据记录框架



图2｜研究任务与实验协议的双层描述。 本文分别从意义机制、研究任务、模态与语境、辅助信息、标注与评价五个维度描述研究设置，再以Task = (X, Y, G, E)记录一项实验的输入、预测目标、标注依据和评价方式。两种描述互为补充，不构成模型的推理流程；同一评价指标下的实验结果仍须结合任务条件和标签定义理解。

若以“隐喻、仇恨、VLM、DPO”并列为一级类别，会把表达机制、风险类别、模型类型和训练方法混在同一个层次。为避免此问题，本文以五个**分析上应分离、但经验上可能相互影响**的维度（图2）记录具体实验协议，并将其作为后文比较论文的共同依据。它们不是数学意义上必须统计独立的变量。

A. 表达与意义机制。记录实例涉及会话含意、间接言语行为、隐喻/反讽/委婉语、编码/狗哨、形式伪装或跨模态组合关系。它描述*为什么需要超出字面的语义证据*；群体立场是T3可能判断的语用属性，歧视/危害为T4的规范性评价对象，安全回应属T6，**不把三者冒充语言意义机制**。

B. 研究预测目标。记录模型究竟在判定现象存在、生成/选择解释、判断交际功能、给出有害性类别，还是生成安全回应；同一个机制可对应多个不同任务，同一任务也可能利用不同机制。

C. 输入模态与情境条件。记录文本、图文、多图、音视频、对话轮次、社群身份和时间信息，以及分组/配对方式。模态个数和模态之间是否构成不可替代语义关系，是两个不同的问题。

D. 训练/测试可用信息预算。严格区分原始可观测文本/图像/音频，与作者提供的词典释义、gold情绪、源/目标概念、外部检索、OCR和Oracle caption等辅助内容。需分别记录这些字段是在训练时、测试推理时还是仅供评测者使用；提供gold辅助信息与模型自行预测辅助属性不是同等信息预算。

E. Ground Truth与证据协议。记录标注单位、标注者、指南、分歧、train/test拆分、真实外部时间/社群分布，以及衡量选择、开放解释或输出行为的指标。两篇论文同样报告F1，若标签、样本或指标平均方式不同，就不能依数值高低直接推导方法优劣。

因此，针对一**篇论文的一项具体实验协议**，本文用 Task = (X, Y, G, E) 记录输入及先验、预测目标、Ground Truth和评价形式。这里的记录式是本文组织综述的**分析记号**，不是作者提出的新模型、训练目标或被普遍接受的数学理论。

为操作化四元组，X应细分为原始输入X_raw、训练额外信息X_train_aux（教师解释、金标情绪、政策或风险说明）及推理时额外信息X_test_aux（候选、词典、检索、oracle）；G至少区分人类共识、模型构造后审修和政策代理，E记录样本单位、分母与Judge。DRInQ固定文字问句而变化会话语境、以五个候选含意的人类共识为评测；VAGUE依视觉场景和四个候选行动评判间接请求，候选由构造目标及人工筛选。二者都可称语用能力测评，但候选数和信息预算不同，不能直接比较其绝对Accuracy。 [8][29]

协议实例表｜同一字段记号下的真实实验（P与S分列）。“未知”表示本稿未核；评测候选／风险政策是X_test_aux，评测金标只进入评分而不默认进入模型。

具体协议／证据	X_raw	X_train_aux	X_test_aux	Y与G来源	E及分母	同预算对照及未知项
DRInQ困难集（P；ACL 2026 Main, CCF-A）	固定问句Q＋变化文本情境C	不新增模型微调；题目由GPT-4o构造后人审	五候选含意＋3个in-context例；Explanation另要求理由	选人类共识A_c；5人中至少4人一致，819共识例再筛400困难题	400题Accuracy，3次few-shot抽样；不是819全体或当前公开CSV	同模型Vanilla/Explanation及同题；额外输出token未匹配。引言和困难集数字不合并。正式§3–4/Table2
VAGUE 2.0 MCQ（P；ICCV 2025 Main, CCF-A）	场景图I＋间接表达p_i	不新增评测模型训练；生成时direct／solution是构造工具	四行动候选；LM无图、SM给caption、VLM给原图；**不预设direct／solution作为答案输入**	目标行动先由模型构造再经人工合理性筛选；非真实心理意图观测	全体1677题（VCR1144＋Ego4D533）；拒答计错；400人评子集另列	同模型多输入设定；caption与原图不等信息，推理token未匹配；代码prompt字段需另核。作者v3 §3–5/附录H–I
MultiMM情绪辅助检测（P；ACL 2025 Main, CCF-A）	广告图文	人工隐喻／情绪等属性监督	论文有情绪辅助配置；各表测试情绪来源和同入口对应仍O	隐喻检测标签，情绪不是隐喻真值	各split标签样本上的分类指标；具体表／输入映射未知	不能以论文结果直接认证下一行公开路径；同预算predicted-vs-gold对照仍O。[15]
MultiMM所审loader（**S，非论文run**）	CSV配文＋图像	train行读取第六列senti	val/test同样读取第六列并tokenize；OCR和该列gold／预测的有效来源仍待run核对	row[2]为metaphor目标；row[5]只作为情绪辅助输入	静态字段观察，无本轮模型得分／分母	公开源码参见MultiMM公开数据加载代码（固定版本）；正式实验run及各baseline的输入字段仍待核

具体协议／证据	X_raw	X_train_aux	X_test_aux	Y与G来源	E及分母	同预算对照及未知项
DOSE五任务（P；ACL 2026 Main，CCF-A）	新闻图像＋文章文本	五类任务标签、共享／私有专家训练；统一MCQ目标CE	对应任务提示＋候选；标签为评分目标，非默认额外gold输入	检测／机制／描述／对象／意图；基于原DocMSU，模型生成扩展并人审	作者1%训练、其余评价；各任务Accuracy后取均值，非按有效MCQ总数加权	Qwen3-VL-8B DOSE/LoRA同1%原始数据；有效任务数／token／训练参数并未因同百分比自动相同。正式§3、§5/Table3
VLSU Understanding（P；ICLR 2026，CCF-A）	image-only／text-only／joint三条件	冻结评测，无本轮任务训练	安全等级定义与分类提示，不提供人审目标标签	单图经验作者；文本／联合多评审；Safe/Borderline/Unsafe	各条件三级Acc/F1；Table1二分类另将Borderline→Safe；Figure5仅指定模型joint错误集合	同模型三条件对照；去模态信息不等，不能称同信息因果对照；正式PDF8187与固定CSV8159分开
VLSU Alignment（P；同上）	同一图文请求	冻结模型	Harmless或Helpful行为提示	G_{in} 按输入风险分组；回应Judge评分并非新的P_{in}金标	各严重度组的拒答／帮助性；Table3、附录E.4，不与分类F1互算	同模型同样本变提示；Judge、生成长度等固定细节以作者版本附录D为准，跨模型不默认同预算。作者v2

2.3 计算语用与操作性Ground Truth

计算语用研究为上述问题提供了可检验的建模和评价方式。概率语用模型通常通过说话者—听者之间对表达选择及潜在意义的假设进行推断，但模型中的先验、候选空间与语境构造会直接决定其适用边界。[3]进一步将修辞策略纳入RSA式语用推断；其研究目标是策略条件下的意义判断而非有害内容分类。[8]通过固定问句、改变语境的选择任务评价会话含意；[29]利用视觉情境及候选行动评价间接表达的适宜解释。这些研究提供的是**在特定构造任务和候选空间中的模型行为证据**，不应被解释为真实说话者内心意图已被直接观察或完全恢复。

上述任务虽然都与“语用”有关，却没有共同的心理意图金标。DRInQ在给定五个候选含意时评估语境化选择，并以人类共识构造测试答案；VAGUE在视觉语境和四个候选行动中评估模型的适宜判断；$(RSA)^2$依赖定义好的策略、先验与候选意义空间。其Accuracy或候选概率只支撑**各自协议下的选择或拟合表现**，不能据此判定真实发话者意图已被完整恢复，或直接与开放式意义解释的准确率合并。

2.4 T1–T6与Task = (X, Y, G, E)：任务目标与可观测标签

为比较不同研究要求模型识别何种现象、恢复何种意义或作出何种风险判断，表2：T1–T6 的输入、输出与 Ground Truth归纳预测目标、输入条件与标注依据。

表2｜T1–T6：研究任务、标注依据与评价方式

任务	模型需要回答的问题	输入与正确答案依据	主要评价方式	关系与解释边界
T1 表达识别	是否出现隐喻、反讽、编码表达等现象？相关片段在哪里？	文本或图文输入；人工现象标签或片段标注	分类Macro-F1、Span-F1等	识别出表达形式，不等于恢复了实例含义。代表研究：[7]
T2 意义解释	该表达在当前语境中传递什么含义？图文主张是否成立？	上下文、图文关系；可包含预先给定的候选意义或源／目标概念；GT可为人工审定释义、候选选择或图文关系标签	候选准确率、蕴含分类指标、解释文本的人评或匹配指标	候选空间会限制可测范围；参考解释匹配不等于恢复说话者真实心理意图。代表研究：[3][22]

任务	模型需要回答的问题	输入与正确答案依据	主要评价方式	关系与解释边界
T3 交际功能推断	表达在当前场景中起什么作用？是请求、含意、立场还是某种行动?	对话轮次或视觉场景；GT可能来自人类共识，也可能来自人工筛选的构造行动选项	多选题Accuracy、人评及标注一致性	DRInQ的人类共识与VAGUE的构造行动选项不是同一种GT；必须说明候选集合与负项难度。代表研究：[8][29]
T4 规范性危害判断	内容在指定政策下是否有害？针对谁？属于何种类别或程度?	文本或多模态内容，以及必要的目标、立场和社会语境；GT来自人工规范判断或明确说明的代理标签	Macro-F1、类别召回、混淆矩阵及两侧错误	修辞识别或编码词识别不能自动推出危害。代表研究：[2][6]
T5 联合模态风险判断	图像、文字分别输入与联合输入时，风险判断是否发生变化?	图像、文字及联合输入；若声称严格S-S-U，必须有同一政策下图像Safe、文本Safe、联合Unsafe的可比GT	分条件分类指标、联合错误分析及经人工复核的反事实对照	T5是T4的特定联合模态设定；图文并置不等于S-S-U。代表研究：[36][24]
T6 安全回应	模型应该拒答、警示、提供帮助还是采取其他回应？实际输出是否安全且有用?	风险请求、回应政策和模型输出；GT由人工或独立Judge评价输出安全性与帮助性	危险请求上的不安全帮助、正常请求上的不必要拒答及帮助性分别报告	T6评价回应行为，不是T4输入风险GT；拒答不能反推出模型内部一定完成了显式风险分类。代表研究：[38][35]

表注。 T1–T6是不同预测目标，不是模型必须依次执行的算法流水线。T5是T4在联合模态条件下的特定设定，T6是相邻的回应行为评价。具体实验仍需分别记录原始输入、训练辅助信息、测试辅助信息、预测目标、标注来源、评价分母和Judge；这些信息共同构成Task = (X, Y, G, E)的记录方式。不同任务的F1、Accuracy和ASR不能组成统一排行榜。

T1–T6不是必须逐级运行的算法流水线。例如，有害性分类器可能直接从原始内容估计T4标签，未显式输出T2或T3解释；而纯反讽研究可能只解决T1/T2，无需转向风险判断。任务之间存在概念联系，但只有同时给出独立中间标签和控制实验，才能进一步声称某种中间语义表征**因果促进**了有害性判断。

这里还需注意T5的特殊地位。对于一对模态 I, T 和语境 C，可用 $G(I, T \mid C)$ 表示在指定政策下的**联合输入风险标签**；$G(I, \varnothing \mid C)$ 与 $G(\varnothing, T \mid C)$ 表示在人类标注协议允许时的单模态条件判断。研究可讨论具有不同形式的联合关系风险，但**严格证明某项危险判断必须依赖两种模态**，还需人审的单模态/联合风险标签、对照或精心控制的配对干预；单纯去掉图片后分数降低不足以证明模型掌握了正确关系。双方单独安全、组合危险（S-S-U）是尤其明确的联合协同模式，却只是T5的更窄子类，且并非所有数据都拥有同协议的三条件人工GT。普通Hateful Meme图文分类器即使同时读取图与文，也不自动意味着其数据满足这种严格标签条件。

2.5 纳入/排除示例与解释、危害及响应的不同GT

前文任务的另一个关键界限体现在Ground Truth来源。对同一个被标为含有隐喻的句子，源域标注者可能给出“像洪水一样”的修辞标签；危害评审者则还需判断其中是否出现群体贬低、说话者是在赞同还是批评、语境是否为引用或社群内部自述。修辞检测与有害性判断的Ground Truth并不天然一致。[9]中的人工监督主要针对隐喻源域，而非每条语句的独立“非人化/仇恨成立”标签，因此不宜用其修辞准确率证明模型可靠识别了歧视性意图。

[6]进一步给出了真实社交平台中的规范性评价案例。其研究对象既包含可能的隐式歧视也包含显性讨论，并未为每条实例提供独立显性/隐性标签；9位受过专门培训的高年级本科研究志愿者参与标注，每条目标句由3人参考邻近语境作出判断；作者报告Fleiss's κ为0.25。论文提供社群内部求助、反用和引用引发分歧或误报的质性案例，但缺少在同一模型和相同数据划分下比较“目标句单独输入”与“目标句加语

境”的控制消融。因此，不能将该论文表述为已定量证明“上下文使模型更准确”。其论文称总量2,400，但正例242与负例2,160相加为2,402；该算术差异未由原始CSV核实，因此不能直接制作精确类别比例图，后续须遵守数据使用/自动审核用途的许可限制。

在多模态生成系统中，这种区分还延伸到模型行为。可把输入风险人审标签记为 G_{in}，模型可见的输入风险预测记为 P_{in}，实际输出的行为类型记为 R_{beh}，输出是否安全且帮助用户完成合理任务记为 Q_{out}。四者不是同一种Ground Truth：系统可以把危险输入识别正确，却仍给出危险指导；也可以把无害输入错误拒绝；甚至可能因保守拒答而提高某一安全评估分数，同时降低帮助性。若模型只生成最终回答而不显式报告风险分类，P_{in} 可能并不可观测，不能仅由拒答行为反推其内部识别过程。[38]与[35]分别对安全侧误拒和后训练中的风险感知与回应行为提供不同任务证据。

纳入与排除的操作性判断。 无害反讽、约定编码义的实例使用和需要语境的间接言语行为，即使没有有害标签，仍可作为T1–T3的核心对象；带独立规范性风险GT的隐晦歧视文本属于T4。若图文风险结论确实针对关系或联合证据展开，并能说明GT或受控条件，则可在T5讨论；只含图片和文本的普通二分类器并不自动满足严格联合依赖。相反，普通指示词消歧、纯字符恢复、一般OCR、纯隐写和不涉及隐含机制的一般显式危险输入仅作为邻接背景，除非研究问题具体关联本文的隐含意义或联合模态风险。仅评估拒答或回答质量的工作归为相邻T6，不冒充T4/T5输入风险真值。

本章小结

本章建立了两项贯穿全文的约定。其一，广义隐晦信息是组织研究的工作性范围，隐含、修辞、编码、表达的不易察觉性和有害性是相交而不等同的属性；文献是否属于核心研究，需要根据其操作性任务和真实标签决定。其二，论文比较必须保留表达机制、预测任务、输入与测试信息、Ground Truth及评价协议的多轴信息。只有这样，后文才能分别讨论文本修辞、社群编码、有害性以及多模态关系，并在第8章横向对比方法族而不制造虚假的统一SOTA排序。

3 文本修辞与语用含义的计算理解

3.1 修辞表达检测

文本修辞研究最先需要回答的是：模型识别了表达形式，还是已经确定了该表达在当前交际中的意义？隐喻通过源域描述目标域，夸张改变程度尺度，反讽可能使表面评价与语境立场相背；习语、委婉语和反问又分别涉及惯用组合、间接命名与疑问句的交际功能。它们可以共现，但标注对象并不相同。形式检测通常给出句子或片段的现象标签（T1）；要回答“究竟指什么”或“对谁表达何种行动”，还需另设意义（T2）与语用意图（T3）的任务真值。把三个层次合并为单一“隐晦理解”得分，会掩盖模型只抓住词面线索的可能性。 [12][11][14]

在修辞形式的联合识别上，EmoBi [12]以英文句子为输入，分别预测可共存的隐喻和夸张二元标签。方法先让语言模型生成情绪分析，再描述隐喻的源域和目标域，利用一个任务的预测辅助另一个任务，最后连同先前理由重新判断两种标签；这些环节是结构化提示与多次推理，并非新增的参数训练目标。作者在HYPO、HYPO-L、LCC 和 TroFi 的联合标注资源上报告分类结果，Table 1 的 F1 与 Table 2 的核验阶段消融支持“这一提示组合在该协议下有用”。但四套资源原有标签和补标标签的血缘不同，且现有消融未以相同调用次数和输出长度隔离情绪、源目标说明与反复判断的独立贡献。项目已有阅读卡提示公开实现顺序与方法命名的对称性可能存在差别；由于本稿尚未固定源码commit及行号，不能将其写作外部可重复的正式实现断言。 [12]

反讽检测揭示另一种局限。[10]在现成指令模型上做零样本二分类，作者报告模型在其合成样本与真人语料间出现显著表现差异，并用表示可视化、语言模型熟悉度代理、局部扰动和层消融分析错误。该论文没有先用合成数据训练待评模型，故不能把结果写成“合成训练导致真实测试失败”；真人与合成集合还同时改变平台、话题、长度、标签生成方式和表达难度。其 Table 2 的准确率差异是特定数据与推理协议下的现象，二维表示聚类与删词效应不足以单独证明模型在语用意义上“完全失明”。综述判断是：形式标签的高低分必须结合数据来源和标签操作定义解释；“反讽”这一类内部仍有真实语境依赖、显著语义反差和生成模板差异。 [10]

习语、委婉和反问也提醒我们注意标签粒度。SemanticQA [11]把多词表达的片段抽取、分类和语境解释分成原子操作，再要求模型在一次回答中同时给出抽取及判断；不同来源语料的标签与输出格式并不统一。[14]则沿用两个反问/信息寻求问句数据集的二元标签，测量隐藏表示能否被线性探针分开。前者检验可观察的多步骤输出，后者检验表征可分性；两者均不能直接替代对真实说话者意图的独立验证。[11][14]

EmoBi（ACL 2025 Main，CCF-A）在HYPO-L作者消融中，完整隐喻F1约80.3，去情绪约74.6、去核验约78.4。该证据支持情绪与再核验构成的提示协议在该数据下有效，却尚无等调用次数/等token控制可以独立分配贡献；相关语料的联合标签含既有数据与后续补标，并非2025论文新建的全部独立人类GT。[12]

3.2 非字面意义与语用意图推断

从识别修辞过渡到推断意义，关键变化是输出由“是否出现某种形式”变为“在这组语境中哪个解释更可接受”。(RSA)^2 [3]将修辞策略 r 明确加入理性言语行为模型：策略相容函数 f_r(c,m,u) 使话语 u 在特定策略下对非字面意义 m 也可赋非零概率；听者再按说话者选词的条件概率反推候选意义。方法解决了严格字面相容函数将非字面解释概率置零的建模障碍。它依赖候选意义与候选话语集合、意义先验及策略概率；在数值夸张任务中策略函数含人工规则，在天气反讽任务中又利用人类策略判断训练小网络，不能概括成无先验、开放式的意图恢复。作者在 PragMega+ 的有限候选反讽实验中报告策略条件化的收益；Table 2 最优配置为策略条件的 L0 而非更深递归的 L1，Table 3 的先验消融也显示意义先验贡献很大。因此，论文支持“显式策略条件有助于特定候选意义选择”，尚不足以把全部增益归因于递归语用推理。[3]

(RSA)^2（ACL 2025 Main，CCF-A）报告在其整体样本上，策略条件L0分配给正确候选意义的平均概率约0.85、普通L0约0.73；但Figure 4字面子群呈相反趋势（普通约0.95、策略条件约0.77）。这不是分类Accuracy，而是分配给正确解释的概率，说明增加修辞策略先验可能以字面情境过度解释为代价，不能称全组样本单调改善。 [3]

DRInQ [8]从评价设计切入：保持表面问句 Q 不变，改变情境 C，使五个候选含义中被人类共识支持的选项变化。候选不是任意干扰项，而是同一问句在其他情境下可能成立的解释，因此模型不能仅靠问句形式作答。论文把生成的情境和含义交给五人判断，仅保留至少四人一致的实例；其困难子集Table 2报告400道五选一题的结果；这些题从819条人审共识例中定向选择具有模型—人类或构造目标分歧的困难实例，而非自然语料的随机400题。解释提示并非对所有模型都有提升，这与“只要生成理由就能增强语用理解”的假设不符。其共识真值仍是对构造场景的可接受解释，不是对现实说话者心理状态的观测；本项目审计发现论文总体/困难集数量与当前公开 CSV 数量不同，故正文只使用论文中条件明确的困难集口径。 [8]

另一条技术线研究表征应如何分开否定与隐含意图。[13]从现有意图数据出发，用模型生成否定和含意变体，再以三元组距离及分类/聚类检验意图编码器。训练用语义对比拉近保留意图的表达、推远改变意图的表达；论文 Table 2–3 显示常规意图分类能力不能保证困难三元组排序正确，针对困难负例训练也可能

使不同指标出现取舍。不过原始意图类继承既有数据，变体主要由模型生成且人工核验仅覆盖抽样，不能将排序正确率直接解释为开放对话中的间接言语行为恢复。反问探针研究 [14]进一步显示，跨数据集分类仍可达到可用 AUROC 时，探针方向和高排名实例集合可能不稳定。综述判断是：表示可分、候选解释选对、真实交际功能恢复三者需要各自的检验。 [13][14]

3.3 情绪与交互辅助：从相关线索到可部署证据

情绪是修辞的重要线索，却既可能是表达后果，也可能只是与语料主题共同出现。EmoBi [12]把模型自生成的情绪描述送入源目标映射与隐喻/夸张相互提示，使情绪成为推理时的辅助文本。其关键优点在于把“何种情绪、何种映射”显式放进可检查的中间输出；其直接评测目标仍是两个形式标签，而非人工标注的情绪因果作用或最终语用意义。作者 Table 2 的去核验消融显示完整流程在所测资源上得分较高，但核验本身是同一模型基于更多提示再判断，没有外部真值纠错器。相关公开实现的执行顺序和依赖路径尚需固定版本核对；此前项目阅读卡可作复核线索，而非对正式运行的已证判决。 [12]

情绪信息的“可用”还取决于测试时如何获得。多模态隐喻研究 [15] 的测试输入构造可通过MultiMM公开数据加载代码（固定版本）核对：测试分支从CSV第六列构造情绪提示并作为模型输入。但尚未核实该代码路径对应作者正式论文哪一张表，因此可确认**所审代码输入预算**与纯原图文不同，而不能断言正式论文所有实验均用测试gold情绪。对文本修辞而言，同样应区分模型自行预测的情绪、训练时辅助情绪标签、测试时人工情绪标签以及随机或打乱的情绪提示。综述判断是：只有在相同模型、相同推理预算下比较这些条件，并检查情绪错误时标签是否随之翻转，才能更具体地论证情绪线索的部署价值。现有结果说明其作为设计线索有前景，却尚未证明所有修辞理解必须经由情绪中介。 [15][12]

3.4 测试形式的边界

同一“理解”标题下，测量对象可能相距很远。DRInQ 的五选一准确率要求在给定候选中选出共识含义；$(RSA)^2$ 的 PragMega+ 报告正确候选获得的平均概率；SemanticQA 的解释任务比较生成文本与参考解释的 METEOR/BERTScore，联合任务还把片段抽取是否正确计入综合分；反问线性探针的 AUROC 则只显示隐藏状态携带可供线性分类的信息。这些量的分母、随机基线、参考答案空间及信息预算不同，不能把数值放进统一排行榜。 [8][3][11][14]

尤需警惕“解释流畅”替代“解释忠实”。已有项目卡记录SemanticQA一个公开路径会在同一次提示中请求抽取与解释；由于固定源码版本尚未给出，本文只将它作为复核线索。联合分数下降也可能来自抽取边界、格式与参考解释覆盖不足，不能自动认定独立步骤的错误传播。[14] 的探针即便跨域保持分类能力，也未发现稳定唯一的反问表示方向；[10] 的二维可视化和局部词扰动同样不能直接呈现模型内部语用推理。更可信的比较需要同一表达在不同语境下的配对判断，分别给出字面与非字面负例，并报告候选意义、对象和立场的独立标注。这里的后两项属于综述提出的评价要求，而非上述论文已完成的统一实验。[11][14][10]

3.5 从修辞到社群编码的桥梁

委婉表达可以经由替代词、谐音或跨语言变形固定为社群约定，隐喻也可能成为群体内部识别信号；但两者没有必然包含关系。CodedLang [7]在真实中文评论中标注编码片段和主要编码方式，其“Newspaper Eat”一例需要音系与翻译链的逆推，不能仅以传统隐喻源目标映射说明。Silent Signals [4]则预给狗哨词项与编码定义，再判断具体上下文是否用了该义；一个表达在其他语境仍可按普通义使用。这些材料共同把研究问题从修辞类型扩展到受众共享知识、实例多义与词义变化。 [7][4]

由此进入第4章时，需要先问研究者究竟是在发现一种表达、消歧其一次使用、恢复所指意义，还是评价其危害。反讽、隐喻、委婉和编码都可能承载无害交流；无论形式多隐晦，仅凭形式标签都不能推出交际者有规避审核的目的。编码表达与有害性之间还隔着目标、立场及规范判断，这一层将在第5章讨论。[7][4][31]

4 编码语言、狗哨与动态词义

4.1 编码语言、狗哨与形音变体



图3｜编码语言研究中的四类不同问题。 编码语言研究分别涉及词项发现、实例义项判断、具体含义恢复和有害性判断。四类问题具有不同的预测目标与标注依据，且都受到语境、社群知识和时间变化的影响。识别出编码表达并不等于确认其具体含义，更不能仅凭编码形式认定内容有害。

表3：编码语言研究中的任务与证据比较词项发现、实例义消歧、意义恢复与新词风险判断的先验、单位及评价边界。

表3｜编码语言研究：任务先验、预测单位与评价边界

研究与任务	可用先验与预测单位	作者报告的结果与评价口径	不能据此推出的结论
Silent Signals：已知狗哨词的实例义消歧 [4]	测试时给定目标词及编码义定义；判断具体语境中的一次使用（instance/token）。论文模型筛选主集16,550条，另有400个筛选正例接受人工审查。	抽样人工审查Precision约85.3%；按作者较宽的可接受编码义口径约89.4%。两者均是抽样审查结果。	不是开放词项发现；400条抽审不能等同于16,550条全部人工核验，也不能据此报告整体Recall。
FETCH!：已知词典中的候选词项回收 [5]	约20%的参考词典作为种子，结合社群语料发现其余已收录词项；输出单位是词项类型（type/root），不是句中实例。	正式Table 4 Balanced PREDICT：P=14.81%、DPR=1.65%、F0.5=5.70%；Table 5同场景DIRECT Llama2-13B：P=2.97%、DPR=13.58%、F0.5=3.52%。P按输出候选词项计，DPR按语料中出现的留出参考根词计并按根词去重。	两条管线的模型和输出预算不同，不能把三项指标压成单一优劣结论；词典留出不等于现实时间外新词发现。

研究与任务	可用先验与预测单位	作者报告的结果与评价口径	不能据此推出的结论
FA-Net：固定候选目标义分类 [31]	源域有标签，目标域无标签文本可参与适应；测试时已定位委婉表达位置，并给定Drug、Weapon、Sexuality等候选目标类别。	作者报告固定候选分类的Acc@k改善；具体结果应按原论文相应任务和候选空间解读。	目标域并非完全不可见，不是零样本目标域迁移，也不是开放式新义生成；跨域伪正对未逐对获得独立人工同义核验。
CodedLang：中文评论中的编码表达 [7]	中文在线评论；通过种子、词典匹配和人工扩展构造样本；分别预测编码片段、编码策略及评论级属性。	7,744条评论中标注900条含编码表达；片段检测、策略分类和评论星级预测是不同任务。	星级是平台字段，不是编码义或有害性GT；构造样本的正例比例和策略分布不能代表整个中文互联网的自然发生率。
SeTox：检索辅助的新词毒性判断 [16]	推理时可在线检索；训练时使用工具调用轨迹SFT。624条测试样本按风险标签分为Unsafe 490、Safe 134；按相对指定基础模型的词义认知分为known 319、model-unknown 305。	DR/KDR/UDR按Unsafe子集报告检测率；Accuracy/F1则覆盖相应分类样本。作者报告检索设置改善其定义下的新词毒性判断。	model-unknown不等于严格时间外新词或词典外新义；毒性分类不等于恢复词义、受众或真实交际意图；在线检索还需报告语料快照与查询时间。

表注。 词项发现、实例义消歧、固定候选义分类和毒性判断是不同预测任务，不构成五篇论文共同验证的端到端系统。FETCH!中的P为Precision，DPR为Discovery Proportion Rate，F0.5偏重Precision；其计分单位是词项而非帖子或句子。SeTox的known/model-unknown是相对于指定基础模型的分组，不应解释为真实时间先后。不同任务的指标不能直接横向排名。

编码语言的计算问题不能由“含有生僻词”概括。表达者可能改变读音、字形、语言或符号组合，使表面形式与交际中预期的意义之间出现需要逆向恢复的距离；这种转换也可能借助社群习惯而非纯形式规则。CodedLang [7]以中文在线评论为对象，在 7,744 条评论中标注编码片段，其中 900 条被判有编码表达。其七类主要策略包括两类谐音、拼音等语音替代、表情符号、字形替代、跨语言语音编码及密码式表达。分类法描述“怎样被编码”，并不自动回答“为何编码”或“是否有害”。作者由种子、词典匹配和人工扩展收集低频样例，因而构造语料的正类比例与七类分布都不能当作整个中文互联网的自然发生率。[7]

狗哨语言在编码表达中强调受众差异：同一表面词对一般读者可保持普通解释，对熟悉特定社群约定者可能传递次级意义。Silent Signals [4]研究的正是这种已知表达在具体句子中的普通义/编码义消歧。这里“狗哨”作为研究对象并不要求每个实际使用者都可被确认有恶意；对个别语句的说话者意图仍需语境与独立证据。形音变体与狗哨也不是同义：前者可仅为表面变换，后者的关键在于受众共享的第二解释。有些无害的评论编码只是绕开直白评价或营造幽默，有些政治或歧视性表达则可能同时具备编码和社会风险。综述据此把形式机制、受众条件与有害判断分别记录。 [4][7]

P023 的评测进一步展示这一区分。论文 Table 2 考察是否存在编码表达，Table 3 考察评论级策略多标签，Table 4 用原始、遮蔽和词典解码后的评论预测商家星级。识别出某类策略不保证恢复其具体评价意义；星级也只是平台原始字段，既非逐例“解码正确”真值，更非危害标签。作者在同批已编码评论上比较遮蔽与解码，能够诊断形式变化对下游任务的影响，但不同编码与非编码评论的性能差异还混有话题、评论长度和星级分布。 [7]

4.2 已知编码词的实例消歧

给定词典条目时，研究问题不再是“找到这个词”，而是“本次出现是否用了词典给出的编码义”。Silent Signals 输入目标词、编码义定义及上下文，让模型在几种问法与定义下重复判断，再用输出一致性筛选高置信实例。方法实质上把社群先验作为显式输入，利用语言模型的语境判断扩充可用语料；它没有训练一个从零发明狗哨含义的解码器。作者既构建人工小评测集，也给出大规模模型筛选的正例主集；两者的

Ground Truth 质量和样本分母不同。论文报告的主集为16,550条模型筛阳数据；此前所见发布说明提示版本口径差异，但本轮未固定其README历史版本，故撤去发布版精确整数，差异仅记O，亦不把论文主集称作逐条人工核实的金标。 [4]

这种设置的优势是把多义词放回具体上下文，比“词典命中即风险”更接近真实判别；局限是定义本身可能带偏模型，普通义、引述、批评或戏仿都需要负例检验。论文小型人工检测、消歧评测与自动高置信抽样采用不同的提示与评分条件，不能把其中一次 Precision 直接当成整个自动标注流程的正确率，更不能据部分人机对照断言语言模型普遍优于懂社群语境的读者。综述判断是：已知定义下的实例消歧为开放词义研究提供了必要组件，但它尚未解决词典未收录的新表达和意义随时间漂移的问题。 [4]

4.3 词项发现与开放词义

当词项未知，输出的单位就从句子中的二元用义变成候选表达类型。FETCH! [5]以部分已知狗哨作为种子，用共同语境的句向量和近邻检索取得候选，再由模型过滤、抽取关键词；论文还考察直接让语言模型提词的基线。EarShot 等流程优化的是候选词项的发现与排序，指标包括词项 Precision、发现比例和偏重 Precision 的 F0.5，既非逐句普通义/编码义消歧，也非目标词义解释准确率。 [5]

作者正式版指标实例（P）。 §3.4及Tables 4–5以词项而非帖子计分：Precision的分母是系统输出候选词项，命中参考根词或其表面变体算正例；DPR的分母是该场景语料中实际出现的留出参考根词，按根词去重；F0.5由Precision和DPR计算。Table 4的Balanced场景RoBERTa R4＋KeyBERT为P=14.81%、DPR=1.65%、F0.5=5.70%；Table 5同场景DIRECT Llama2-13B为2.97%、13.58%、3.52%。同场景的精度／发现比例取舍不能化约为全面更强；两管线模型、筛选、输出规模亦不等预算。它们是**已收录词典type回收**的作者结果，不是逐句用义正确率或真正词典外未来新义准确率。本轮核了正式表和定义，未重跑预测列表／去重实现。

该研究的重要评测边界是“未见”的定义。主实验把已存在于参考狗哨词典的词项约 20% 用作种子，约 80% 暂不向系统提供，检验能否从语料中回收；这构成词典留出，不构成现实世界先按时间封存、后来才出现的新狗哨。基准中的词项出现多由正则命中确认，无法逐句排除普通义或引用；词典外真正新词还可能被自动指标误算为错误。作者在附录给出若干词典外候选的质性分析，但它们没有形成完整人工标注的开放世界测试集。因而，论文证明了一个有用的种子检索研究设置，并报告在三种稀疏度条件下的实验结果；它尚未证明现实时间外新义已被可靠发现。 [5]

与 Silent Signals 对照可见，前者在“未知词项”上承担更困难的候选搜索，后者在“已知词义”上提供更清楚的实例判断。两者不宜按 F0.5 与消歧 F1 排名。若要检验真实演化，未来数据需记录词项首次出现与定义形成时间、社群边界、语境中普通义负例及人工确认的词典外用例，并保证模型训练和外部检索只接触测试时间以前的信息。这是综述提出的评价条件，非 FETCH! 已完成的时间外实验。 [4][5]

4.4 固定候选解码与跨域适应

词项已定位之后，另一个目标是把委婉语映射到直白目标义。FA-Net [31]研究源域显性表达与目标域委婉表达之间的文本分布差距：训练时有带目标类别的显性语境，也可接触无训练标签的目标域语境；测试时在固定候选目标词集合中给已定位位置选择意义。模型使用监督分类和域内对比约束，使同类源域表示更接近；再以相似度选择跨域伪正对、作跨域对齐，并对目标域预测施加熵最小化。这些目标分别处理源域判别性、显隐语域差距和目标域决策不确定性，而非自动生成未见词的开放释义。 [31]

论文在 Drug、Weapon 和 Sexuality 三个任务上以 Acc@1/@2/@3 评估候选排序；Table 3 报告 BERT+FA 相对原 BERT 的 Acc@1 改善，Table 5 支持若干模块组合在该设置中的贡献。但跨域伪正对依据表示相似度，未提供每一对真实同义的独立核验；将相似文本错配到不同目标类的风险仍属综述审计的假设，而非作者已量化的错误率。目标域无标签文本参与适应，亦不能把实验叙述成从未接触目标语域的零样本泛化。固定候选、词典式标签与目标语料可用性决定了这种方法的有效范围。 [31]

相较之下，Silent Signals 把具体编码定义直接交给模型做实例消歧；FA-Net 将定义压缩为候选目标类，并训练跨域表示；FETCH! 则先寻找可能的表达类型。这三项研究分别使用了已知定义、固定类别和种子词典等不同先验。它们提示方法演进不是单一模型规模竞赛：问题设置的先验越充分，意义推断往往越可操作；但同时也越不能据其成绩声称开放式词义发现。 [4][5][31]

4.5 动态语境证据、外部知识与安全判断

新兴网络词的意义可能随圈层、事件和时间变化，静态模型参数未必保留所需背景。SeTox [16]让模型在中文句子中识别潜在新词，决定是否调用搜索，读取外部结果后输出安全类别及解释；训练以工具调用轨迹进行监督微调，而非用 PPO 或 DPO 训练奖励策略。作者报告带检索设置在所定义的新词毒性测试上优于无搜索消融，说明搜索证据可在这一任务中提供有用信息。其终点仍是有害性分类（T4），并未独立测得词义释义、受众识别或真实意图恢复。 [16]

对“动态”和“未知”还需保留协议限定。论文的 model-unknown 是相对指定基础模型能否解释词义的分组，不是严格的训练前未见词、词典外词或真实时间外出现；本项目尚未对公开 train/test 做词项交集和检索快照时点审计。在线搜索可能带来新证据，也可能带来来源偏差、错误网页、检索时间漂移或与标注依据循环依赖。上述后四项是可检验的审计风险，不能写作作者实验已发现的普遍污染。SeTox 还把多种安全类别合入分类框架，敏感话题、成人内容、群体攻击等是否应共享一项“有害”金标取决于具体规范。 [16]

CodedLang 和 SeTox 的对照尤为清楚：前者研究评论表面编码和原评价信息，后者研究新词相关的风险分类；即使模型正确恢复“这个词在此处意味着什么”，也未必能据此判断其是否针对某人、表达何种立场或违反哪项规范。若将检索系统用于有害判断，至少应把检索片段来源、采集时间、是否在标注前可见与独立人类危害标签一同报告，才能使结论可追溯。 [7][16]

先验预算与开放性的条件性比较。 Silent Signals把已有社群定义输入实例消歧，作者抽400个筛阳正例人工审查，报告Precision约85.3%（若计入更广的可接受编码义约89.4%），并非16,550条模型筛阳主集的完整人审准确率；FETCH!把已有词典20%种子作为输入，评估其余已收录词根的type回收；FA-Net使用固定目标候选空间及目标域无标语料；SeTox推理时允许获取检索证据后预测新词毒性。四者分别证实**给定不同先验时不同Y可以在特定GT下被预测**，不能将其统称为已经解决现实时间外未知编码词的开放语义发现。这一“先验预算—可测开放度”关系属于本文对原论文的条件性综合（H），非四篇共享数据上的独立对照。 [4][5][31][16]

4.6 从编码义到危害判断的桥梁

本章四项任务可以概括为不同的输入输出契约：词项发现问“哪些类型值得检查”，实例消歧问“此处是否为编码义”，意义解码问“它对应哪个解释”，危害判断问“在给定对象、立场和规范下是否有害”。FETCH!、Silent Signals、FA-Net、SeTox 分别为这些问题提供代表实验，却没有在同一批样本、同一预算与共享金标上组成经过验证的端到端流水线。CodedLang 的评论星级还展示：即使有解码形式，下游评价也不会自动改进。 [4][5][31][16][7]

因此，编码系统的错误需要按层定位。词项型检测容易漏掉真正新形式，也可能把普通义词项误报为狗哨；固定候选解码可能排除真实新义；搜索增强系统可能得到过时或不可靠的证据；即便前三层都正确，引用他人说法、批评歧视或社群内部自述仍可能改变危害判断。第5章由此把目标群体、说话者立场、话语功能和规范性 Ground Truth 置于中心，讨论隐晦有害内容，而不把“编码”作为有害性的替代标签。 [4][31][16][6]

5 语境化隐晦有害内容检测

5.1 隐式仇恨、隐性毒性、刻板印象与非人化

不同有害内容数据集的实际标注目标并不相同，表4：语境化有害内容的 Ground Truth比较其标注对象、标签来源与可以支持的结论。

表4｜语境化有害内容研究：标注对象、GT来源与规范边界

研究与数据	实际标注对象	标注协议或样本构造	结论能够支持的范围
Latent Hatred [17]	研究对象涉及隐式仇恨及针对性类别；本项目目前只有正式出版信息和索引级材料。	原始标注者构成、具体标签协议和完整实验细节尚未在本项目取得足够原始证据。	可作为隐式仇恨研究的基础先例；不据题名或摘要补写未核实的标注细节、训练损失和实验数字。
ToxiGen [2]	约27.4万条机器生成的群体相关文本，包含有害与无害构造条件。	按目标群体及有害/无害提示组织生成；另以人工子集和人写外部测试评估数据与模型。	支持受控生成难例用于压力测试；生成提示所设定的标签不等于逐条人工确认的隐含命题、说话者立场或真实意图。
When People Are Floods [9]	移民话语中的隐喻源域是否出现；GT针对隐喻源域。	人工标注源域表达及其出现程度，并结合文档级分析。	支持对特定隐喻源域的研究；不能把隐喻标注改写成每条样本均有独立“非人化”或“仇恨”标签。
Sheep’s Skin, Wolf’s Deeds [21]	将显性有害表达改写为隐喻后，是否保持原有有害意图。	从显性有害请求构造隐喻改写，并由人工审核意图保持；在特定检测与回应提示协议下测试。	支持特定合成改写条件下可能出现漏检；正例改写不能代替真实语境中的负例控制，也不能据此估计一般分布上的误报率。
AUTALIC [6]	目标句在邻近真实社群语境中是否表达歧视性态度。	9名受训的高年级本科研究志愿者参与，每例3人标注；原始标签为-1/0/1，其中-1（不相关/上下文仍不足）先并入0，再多数投票。	作者报告Fleiss κ=0.25；总量2,400与正负分项242+2,160=2,402相差2条，原始CSV尚未核清。多数票不等于真实作者意图，也不能用κ单独判定标注者“不可靠”。

表注。 本表按Ground Truth的标注对象选取代表研究，不是第5章全部方法清单；ImpCon、SMARTER、RV-HATE和CADET见正文§5.2–§5.5。AUTALIC的数据使用须符合作者授权条件，商业用途及自动内容审核工具开发/部署有额外许可要求；在原始CSV及授权条件核实前，不自行修正论文统计。

“隐式有害”首先是标注目标的问题，而非缺少禁忌词的纯形式问题。某句可在没有粗口时传播群体刻板印象或非人化比拟；另一句含有污名化词语，却可能是受害者自述、引述后反驳或求助。隐式仇恨、广义毒性、歧视性措辞、刻板印象和非人化并非一套可互换的金标：它们在攻击对象、所需上下文、规范阈值与允许的“不确定”状态上均可能不同。以“无显性辱词”筛样，是有用的困难例代理条件，却不是每条样本都存在复杂语用含意的证明。 [2][17][6]

较早的 Latent Hatred [17]把隐式仇恨的形式类别与隐含陈述纳入基准讨论，为“分类标签以外还需解释攻击何在”提供基础研究背景；本项目对该篇目前只有官方出版信息及索引级材料，故不从其题名推写具体训练损失或实验数值。ToxiGen [2]则从数据稀缺与虚假相关出发：按目标群体与有害/无害提示组织生成示例，并在解码阶段把语言流畅度与现有分类器的错误方向结合，形成对抗难例。论文报告约 27.4 万条机器生成文本，且通过人工子集、人写外部测试及微调前后对照检验效用（§3–5、Tables 2/4）。这支持“受控生成可以丰富指定检测器的压力测试，并在所测外部数据上改善 AUC”；生成时的提示标签仍是代理，论文以词表缺失衡量的“隐式”也不能代替逐句的隐含命题或说话者立场金标。 [2]

AUTALIC [6]把这一问题推进到真实社群语境。它以有关自闭症群体的目标句及相邻句为标注对象，评价是否表达歧视性态度，而非把所有句子限定为“隐式仇恨”；某些显性措辞和医学化称谓也在语料中。相较生成语料，真实讨论让引用、回收词汇、群体内部谈话与求助更突出，却同样不能把最终多数票当作可直接观察的作者心理意图。两种数据路径分别加强了可控困难样本和社会语境的覆盖，所回答的问题不同，不能据 AUC 或 F1 横排为同一任务的优劣。 [6][2]

5.2 从分类到隐含陈述、对象与解释

如果目标不仅是输出有害/无害标签，还希望说明攻击对象与隐含命题，额外监督必须交代来自哪里。ImpCon [18]利用部分训练样本已有的 implied statements：把有害原文与隐含陈述配对，其他样本则使用词汇增强，再以分类交叉熵和实例对比目标联合训练。其跨数据集实验报告相对普通分类与纯词汇增强的收益。机制假说是让模型表征靠近较稳定的含义层，但并非每条样本都有人工隐含解释；若配对文本不保留原有立场，或对比批次中存在语义相同的“负例”，对齐损失也可能引入噪声。原文一解释向量更接近是训练目标的结果，尚不是解释忠实或真实意图复原的独立验证。 [18]

SMARTER [19]转向低资源解释式分类。作者先利用 HateCOT 等先前解释资源做辅助监督微调，再在目标任务少量带标签样本上生成正误回答与解释，使用 DPO 使模型偏好较合适的标签一解释组合，最后尝试跨模型解释 refinement。DPO 优化的是相对参考策略的回答偏好，不是单独验证每条解释与真实推理路径一致；“只用部分目标任务数据”也不等于前期解释资源、生成计算与模型权重都被省去。论文 Table 1、Fig. 3 和 Table 5 记录不同样本预算下的分类及消融，支持其特定协议的低资源效果，但模型之间的交换收益并不对称，也不能将宏 F1 的改善全部归因于 DPO 或解释质量。 [19]

RV-HATE [20]采取不同思路：簇代表对比训练、NER/语言模型辅助的目标标记、离群样本处理与困难负例构成四个分类模块，最后用 PPO 在每个数据集上寻找四组固定 logit 权重。目标标记可帮助模型关注潜在群体，但被 NER 找出的实体未必就是被攻击者；删除簇内远点也可能删除少见而真实的隐晦样本。论文 Table 1–3 的分类结果支持所报设置下模块组合的总体效果，并未把“识别对象”“恢复隐含命题”“解释忠实”逐一独立测量。所审RV-HATE公开PPO评估入口（固定版本）显示：该入口用test_data构造包含标签的PPO环境并以同一test_data评价优化权重。**这只证明特定公开源码路径存在验证隔离风险，不证明论文正式结果由该入口或该commit生成**；因此不能据此否定作者正式所有结果。 [20]

三类方法分别增加人工隐含陈述、模型生成解释和目标标记/模块集成，其额外信息预算及训练目标差异大于名称表面相似性。真正要比较“分类到解释”的进展，至少应在同一语料上分开给出危害、目标、立场和隐含陈述的标注，并检验在删除或置换解释时预测是否合理变化。后一个要求属于综述提出的评测建议；现有跨数据集宏 F1 不能替代它。 [18][19][20]

解释优化需要扣除金标与教师知识的贡献。 SMARTER（ACL 2026 Main，CCF-A）先进行HateCOT解释SFT，再以训练gold类别构造chosen/rejected的标签一解释DPO偏好；即使不读取解释质量，正反样本的标签token也可能不同，因此其分类提升不能独立归因于解释更忠实，尚需同token的label-only

DPO对照。RV-HATE（ACL 2026 Main，CCF-A）的四分类器等权加权基准平均Macro-F1为83.78，经PPO优化四个固定权重为84.47，**增益为0.69个百分点**，并不是其整体方法相对最弱基线的全部收益。这里的解释SFT、类别条件偏好与低维权重优化是三类不同的监督/优化机制。 [19][20]

5.3 修辞形式与有害性不等价

隐喻既可能参与非人化，也可用于艺术、批评或亲密交流。When People are Floods [9]在移民话语中预设若干源域，把模型的局部词级判断与文档级源域原型相似度结合，以人工对“某种隐喻源域是否出现”的认同程度评测。论文在该源域任务上报告相关性与阈值化 AUC，并分析传播及政治立场的关联；它没有逐条独立的人类“此句构成非人化”“此句构成仇恨”标签。因此，把其隐喻 AUC 改写成仇恨检测 AUC，或把统计关联写成个体因果，都超出了实验所测对象。 [9]

Sheep’s Skin, Wolf’s Deeds [21]更直接考察风险：作者从显式仇恨表达生成受隐喻约束的改写，人工审核改写是否保持原仇恨意图，再在单轮检测和多轮警告/拒绝设置中测模型失败。论文报告特定合成隐喻正例上漏检与安全行为变化，为“形式变化可增加既有检测/回应协议的难度”提供证据。不过审核者看到原句，检测模型通常只见改写；单轮集合主要是仇恨正例，不能据其“准确率”推断安全语句误报率或普通分布上的精确率。多轮情境还可能同时改变话题、显式仇恨所在位置、历史长度和安全策略。因而，漏检不能唯一归因于模型不会恢复隐喻意义。 [21]

两篇论文恰好形成有用的反证边界：前者对源域的人工真值较明确，但没有危害真值；后者有经原句参照审核的有害改写，却缺足够负侧和中间意义标注。要判断“隐喻何时有害”，还需在相同语境下分别询问源域是否出现、该域如何指向人群、说话者是在赞同还是反对所述刻板印象，以及按特定政策是否构成伤害。这个多层标注方案是综述判断，不应误写成两篇论文已共同完成的基准。 [9][21]

5.4 真实语境、社群立场与标注分歧

语境化判断的重点不是把更长文本无差别拼给分类器，而是识别哪一段话提供立场、说话者关系和引用范围。AUTALIC [6]让标注者针对目标句判定，同时查看原帖相邻句；论文 Figure 1、3、5 分别讨论可能被误读的刻板印象、社群成员求助及引述后反对污名化说法的案例。它们直接支持“仅凭敏感措辞可能误报”的质性观察，也使群体内部话语与外部贬损不能被简单混为一类。这里不需要假设模型已准确恢复每位作者的真实意图；更可核验的是标注者如何在有限上下文下作规范判断。 [6]

其标注协议也解释了为何多数票不是无争议金标。九名受训的高年级本科研究志愿者参与，每个目标句由三人判断；原始选项包括歧视、非歧视与“不相关/上下文仍不足”，论文把后一项并入非歧视后取多数票。论文报告 Fleiss κ=0.25，保留个人标签，并对高分歧案例做质性分析（§3.2、Table 2）。这一结果显示规范性判定确有分歧，却不能仅由 κ 推断“标注者不可靠”或“多给上下文就能消除分歧”；少数类比例、规范理解和可见语境范围都可能参与其中。训练背景不应被写成全部标注者是临床专家。 [6]

证据纪律在此尤其重要。论文宣称总量 2,400 条，但正负类分项相加不一致，原始 CSV 最终类别分布尚未在本项目核对；本章故不报精确正负类数。论文也没有同模型、同划分、同预算的“只看目标句”与“目标句加上下文”消融，所以不能写“加入语境使 F1 提高若干点”或“已量化标签翻转比例”。其 Table 3 的同域微调模型与零/少样本语言模型条件不同，不能用分数差证明某类架构天生更懂语境。作者数据使用还有限制，后续实验应核最新授权和发布版本。 [6]

5.5 跨语域、跨风格与可解释性的局限

跨数据集或显式/隐式风格转换常被用来检验模型是否过度依赖词汇与来源。ImpCon [18]的原文一隐含陈述对比训练，在所选跨语料设置中取得分类增益，但 IHC、SBIC 与 DynaHate 的标签来源和对象不同，不能把跨基准分数直接解释为同一危害定义下的文化或时间外迁移。RV-HATE [20]对多个数据集分别训练分类器和权重，其汇总结果也不是“训练一次、部署到全部未见领域”的证据；在RV-HATE公开PPO评估入口（固定版本）中可以观察到test_data同时进入PPO环境与最终评估，但正式论文报表采用的实际入口、split及checkpoint映射仍未核证，不能由该静态证据指认作者正式实验已经使用测试标签调权。 [18][20]

CADET [40]研究显式与隐式风格迁移：RoBERTa编码后通过重建、对抗、正交和反事实相关损失试图降低表征与风格的耦合；作者报告相关分类和模块消融。然而几何正交不等于恢复真实社会语义潜因子，源域与目标域的正类比例及风格标签政策也可能不同。所审CADET公开数据加载代码与训练验证代码显示，相关加载路径两处返回(train,test,test)，且使用验证F1进行模型选择，提示**这条公开路径**的验证/测试隔离存在较大风险；但启动参数、正式论文是否使用该版本及样本split未做运行复核，故仍不可直接断言正式实验泄漏或所有表格无效。 [40]

因此，跨域方法的共同比较单位应是完整协议：训练和验证能见哪些目标域文本、是否见目标类别空间、人工解释或 API 辅助标记是否可用、测试是否封存，以及源/目标数据的正类比例和政策定义是否匹配。解释文本、目标标签或“因果”分支名称都不能代替这样的审计。以同一测试集报告总体宏 F1、少数类召回、引用/反用子群误报与不确定样本上的分歧，才能同时观察漏检和压制合法讨论的代价。这是综述从现有问题提出的评测要求，不是已有各篇均已完成的统一报告。 [18][20][40][6]

5.6 与多模态研究的关系

本章讨论的 T4 是给定文本及其社会语境作规范性危害判断。图文或音视频加入后，模型可能在不同模态找到对象、事件与立场线索；但“输入含多种模态”并不自动意味着危害只在组合后才出现。第6章将讨论多模态非字面意义本身，第7章才检验联合模态风险的 Ground Truth 与输入判断/输出回应。普通 Hateful Meme 的图文并置、严格“两侧单模态安全而联合危险”的配对设定，以及安全响应中的拒答率，属于不同的评价对象。

这一划分也使本章的结论保持清楚：隐晦有害检测需要将表达形式、候选意义、攻击对象、说话者立场与规范性标签逐层核对，但现有论文并未统一标注和验证一条必经的认知流水线。ToxiGen 的对抗生成、ImpCon 的解释对比、SMARTER 的偏好训练、AUTALIC 的多人语境判断及 CADET 的跨风格训练各自提供了不同类型的证据；它们共同推动评价从单一分类分数转向 Ground Truth、两侧错误与协议可追溯性。最后这一综合判断是本综述的分析立场，并非某篇论文单独证明的历史演进因果链。[2][18][19][6][40]

6 多模态非字面意义与修辞理解

6.1 多模态隐含意义的现象类型

第五章的危害判定需要社会语境与规范性标签；在此之前，多模态输入还可能提出一个纯意义问题：图像、文字或声音怎样共同构成非字面表达。广告将商品形象映射到另一概念域，图文反讽让文字的表层评价与画面事件相抵触，音视频反讽则可能依靠语调、面部表情和话语内容之间的不一致。这些现象并不共

享一个“多模态理解”金标。检测隐喻有无属于 T1，恢复源域与目标域、判断图文主张的蕴含关系属于 T2，识别反讽对象或交际目的更接近 T3；即使某数据另附“冒犯”属性，也不能据此把所有非字面样本改称隐晦有害内容。 [15][22][33][34]

模态的组合至少有两种情形：一个模态已经给出可识别线索，另一个模态只补充或重复；或者候选意义必须借助两者的关系才能作出。后一种“不可替代性”是具体样本和实验协议的属性，不是图文模型结构的固有性质。例如 OCR 把图片内文字转录到文本输入后，所谓“只看文本”实际上已获得一部分视觉载体的信息。音视频反讽中语音转写也会改变文本端的信息预算。因而，图文、音视频与多图研究可以共享模态依赖的审计问题，却不能共用一组去图分数来证明同一种机制。 [15][34][30]

6.2 数据集与细粒度语义标签

早期的二元修辞检测无法回答“什么映射到了什么”以及“谁是反讽对象”。MultiMM [15]收集中英文广告图文，论文 §3、Table 1 报告 8,461 对样本，并分别标记隐喻有无、源域、目标域与正／中／负情感。标注结构允许将跨文化隐喻检测与概念解释区分开；然而中文和英文的采集来源、题材及词汇分布同时不同，模型差异不能单独归因为文化因素。广告中的 OCR 文字也是输入的一部分，不能把语义来源简单写成“原始配文加图片”。 [15]

V-FLUTE [22]将隐喻、明喻、习语、反讽及幽默统一到可解释视觉蕴含：模型接收图片和文字主张，输出 Entailment／Contradiction 与自然语言解释。论文 §3、Table 1 给出 6,027 个实例，部分候选主张和解释由模型生成，再经专家审修；全量并非每条都由三名专家独立投票。此处的金标是图文主张关系及参考解释，既不是“作者真实心理意图”，也不是安全政策下的有害标签。其不同来源采用不同正负例构造规则，因此按来源检查数据和模型错误，与报告一个全局 F1 同样必要。 [22]

M3UCD [33]把任务粒度进一步扩至隐喻类型、源／目标概念及其模态、情绪、冒犯度、意图和其他修辞。论文 §3、Tables 1–3 报告 15,345 个实例，若干分类属性由受训标注者讨论或投票确定；概念生成却不能直接借分类标签的一致性数字证明可靠。其“Complementary”约占作者报告的58.36%，但这只是**人审模态归属类别**，而非在同样本同模型上移除任一模态后必然预测失效的行为证据。MGMCF [32]沿用 MET-MEME 的隐喻、情绪、意图和冒犯四种分类标签；它以源／目标域概念作为额外输入，和以域概念为预测目标的 M3UCD 不在同一输入条件。四项标签反映不同语义或评价维度，冒犯度尤其不能替代第七章的人审联合风险真值。 [33][32]

为区分多模态语义任务的标注目标与模型额外获得的信息，表5：多模态非字面理解的输入预算与辅助标签按照输入条件、标注依据、辅助信息和直接实验证据比较代表研究。

表5｜多模态非字面意义研究：任务、辅助信息与证据边界

研究与模态	任务与Ground Truth	辅助信息或训练设置	作者结果与尚未证明的事项
MultiMM [15]	中英文广告图文，8,461对；标注隐喻有无、源域、目标域及情绪极性。	作者研究情绪辅助配置；所审公开路径的测试数据会读取CSV情绪字段，但正式论文主结果与该代码路径的对应关系仍待核。	作者报告英文/中文隐喻F1分别为80.16/77.79，情绪辅助配置有收益；仍需同预算比较模型预测情绪与人工金标情绪，不能把公开路径静态观察直接说成正式实验已泄漏。
V-FLUTE [22]	6,027个图文主张实例；输出蕴含/矛盾关系及自然语言解释。部分主张和解释由模型生成后经专家审修，并非全量三名专家独立投票。	白图模型作为视觉输入对照；其余输入仍包含文字主张及任务构造信息。	特定设置下图像输入F1@0为72.78，白图为64.77；白图仍有残余表现，不能据此认定视觉信息在所有样本上不可替代；解释匹配分数不等于解释忠实性。
M3UCD [33]	15,345个图文实例；涉及隐喻类型、源/目标概念及模态、情绪、冒犯度、意图等细粒度属性。	多任务标签监督，共享LoRA；部分概念由标注者讨论或投票形成。	作者报告Complementary约58.36%，这是人工模态贡献归属类别，不是同一模型去图后的因果结果；不同任务存在正负迁移。
MGMCF [32]	图文Meme；隐喻、情绪、意图和冒犯度分类。	源域/目标域概念作为辅助文本输入；公开loader已固定，但预计算pkl字段究竟来自人工金标还是模型预测尚未独立确认。	作者报告对象特征、全局—局部交互和双语义模块的结构消融收益；尚不能把这些结果解释为等信息预算下各模块的独立因果贡献。
DOSE [23]	新闻图像与文章文本；五项主要反讽理解多选任务。	任务提示、共享/私有LoRA专家及投影正交；所审代码另有第六种变体，需与正式五项任务区分。	作者报告1%数据预算下五任务均值78.90，对比同底座LoRA的77.70；文本主导61.9%、等贡献22.5%、图像主导15.6%是人工模态归属类别，不是同模型去模态的因果准确率。
MCIB [34]	文本、音频、视频反讽二分类；使用MUStARD++R标签协议。	条件信息瓶颈、KL压缩与条件预测辅助训练；完整模型同时包含多模态表示和文本残差。	作者报告weighted-F1=75.64；去掉细粒度特征为71.19，Transformer换为MLP为74.32。没有同参数、同预算的no-CIB/no-KL/no-conditional对照，不能把完整模型收益独立归因于CIB。
MMSD3.0 [30]	多图与文本反讽基准，提出CIRM关系推理。	正式CVPR 2026 Main（CCF-A）论文已确认出版；本项目目前仅完成正式出版页和摘要级核验。	可作为多图反讽任务与方法存在的证据；未逐表核对GT、控制实验和模块消融，因此不据摘要宣称CIRM的独立收益或严格多图因果依赖。

表注。人工模态贡献归属、同一模型的text-only/image-only/joint预测变化，以及人工复标的单因素反事实，是三种不同证据，不能互相替代。比较前应分别报告原始输入、训练辅助信息和测试时额外信息的来源；公开代码静态观察不等于正式论文实验配置。

MCIB专项证据说明。论文Table 2中，完整模型weighted-F1为75.64；去掉细粒度特征后为71.19，Transformer换为MLP后为74.32，但没有单独移除CIB/KL/条件预测损失的匹配消融。另据本项目的公开代码审计，Transformer路径中预测张量与标签张量可能出现[B,1]和[B]的广播风险；最终分类表示还包含未经瓶颈约束的原始文本残差。这两项是公开实现的静态风险，**不能据此断言正式论文实验一定使用了该路径或正式结果错误**。正式run与该代码路径的对应关系仍待核。详见本轮提供的MCIB专项审计材料。

6.3 跨模态融合与多任务优化

方法从整图和整句的简单拼接，逐步转向对象线索、任务共享与任务分离。MGMCF 的输入是图像、Meme 文字及源／目标域辅助文本：文本编码、整图表示和对象区域特征经 Global–Local 双向交互更新，再把融合、文本和图像预测分支用于四项分类；训练损失包含各任务交叉熵与 Dual-Semantic 项。其英文 MET-MEME 实验的 Table 2 显示移除对象、Global–Local 或辅助损失后部分分类指标下降。这支持完整配置在特定数据和输入字段下的经验收益，却不等于对象分支已准确定位非字面映射，更不等于删除一个分支就完成了“只看单模态”的严格对照。 [32]

M3UCD 的 MCLF 让同一图文样本配合不同任务指令，冻结多模态基座并共享 LoRA 增量，以各任务标签的训练损失优化预测。情绪、意图和概念在这里是并列监督，不存在已证实的“先识别情绪，再恢复隐喻”的必经计算路径。论文 Table 4 中，同一 Qwen2.5-VL-7B 设置的源／目标模态分类 macro-F1 有所增加，而情绪及隐喻检测 macro-F1 下降；正负迁移并存，故不能用总体多任务优势掩盖任务级代价。公平比较还需匹配总训练样本、token、更新步数和参数预算。 [33]

DOSE [23]把反讽检测扩展到机制、描述、对象和意图等选择任务。输入为新闻图文及任务指令，输出相应类别或多选答案；训练数据的候选解释和难负例含生成辅助与人工审校。方法为每个低秩专家设置 shared／private 两组参数，以样本内容和任务身份混合路由，并惩罚两组输出投影的几何重叠。论文 Table 3在Qwen3-VL-8B的1%训练预算下报告五主任务等权Accuracy为78.90，LoRA为77.70；Table 4去正交项的总体成绩下降，Target单项却高于完整模型。作者对反讽正例的模态贡献标注还报告文本主导约61.9%、图文相当约22.5%、图像主导约15.6%，这些是**人工归属类别，不是同模型去图去文的实际准确率**。这说明模块组合有经验价值，并显示任务之间仍可能权衡。参数正交不直接测量不同任务的梯度冲突；选择题准确率也不能改写为自由文本解释忠实率。 [23]

三种方法分别优化局部线索交换、共享任务适配和专家参数分离。它们的主表与消融支持各自报告协议中的预测表现，无法在不同金标、基座、辅助字段和训练预算之间排出“语义理解能力”总榜。DOSE 所称双流是参数子空间，而非严格互斥的图像流和文本流；这一点也提醒读者不要把结构命名当成模态必要性实验。 [33][32][23]

6.4 情绪、多义与附加金信息

情绪可能帮助解释同一视觉对象为何对应不同隐喻或反讽，但“情绪是相关线索”与“部署时模型能自行获得情绪线索”是不同命题。MultiMM的SEMD报告英文/中文广告隐喻F1分别为80.16/77.79，作者情绪消融在相应协议下有收益。所审MultiMM公开数据加载代码（固定版本）显示，train/val/test均从CSV字段构造情绪提示，但是否对应正式论文主表训练或测试入口仍O。可以说该公开路径有**额外情绪字段输入**，不能将其不加条件地概括成论文主表测试金标已泄漏或作者实验违规。稳妥结论是：情绪辅助配置可在相应输入条件下取得经验收益，真正部署的纯原图文能力还需分别报告缺失/模型预测/gold情绪三种预算。 [15]

MGMCF的源域和目标域辅助概念字段使输入预算问题更直接：如果任务输出是隐喻或情绪类别，而测试时还提供域概念，模型获得了与解释相关的额外先验。原论文定义了这些输入，MGMCF公开数据加载代码（固定版本）显示train/val/test从相同加载流程取得预计算source/target特征，但这些pkl究竟来自人工gold、模型预测或外部数据仍未实物溯源。Dual-Semantic损失与论文的实现对照尚未在此固定为可单独复核的执行路径，不能据目前证据断言正式实验失效。与M3UCD将源/目标作为预测对象不同，必须首先在**表5（多模态非字面意义表）**分清输入的概念先验与输出的预测标签。 [32]

意图和对象标签同样属于标注者对文本效果的操作判断。DOSE 的多选题可能受到选项位置、长度或模板线索影响；项目只在公开 1% 训练子集观察到相关风险信号，不能外推为完整测试集偏差已证。比较情绪、源／目标与意图的实际作用，需同时报告无辅助、模型预测辅助、人工金标辅助三种输入，固定基座和预算，并分别测分类与解释；这些是综述提出的验证方案，而非现有论文已全部完成的控制实验。 [23]

6.5 视觉／音视频捷径与条件信息瓶颈

多模态模型的性能增益可能来自真正的互补关系，也可能来自转写文字、数据来源、选项格式或一项强模态。V-FLUTE 将真实图片替换为白图并重新训练，提供了图像有用性的一个诊断；但白图改变输入分布，数据来源与正负例构造仍可能留在文字中。其 F1@0 是蕴含标签 macro-F1，F1@53／60 还按解释与参考文本的相似性阈值将标签计错；该阈值曾在测试抽样的人评子集校准，不能当作严格独立的解释忠实评价。论文 Appendix H 中 GPT-4o 的少样本结果亦说明“最佳微调模型”不等于全篇所有设置的最高值。 [22]

MCIB [34]针对音频、视频和文本反讽检测提出条件信息瓶颈融合。其模型编码三种输入、构建细粒度模态表示，用条件预测与压缩目标约束融合特征，最后输出二元反讽标签；训练仍使用已有反讽金标，推理时不需要人工风险标签。作者在 MUStARD++R 上报告完整配置 weighted F1 为 75.64；正式论文 Table 2 的去细粒度表示为 71.19、以 MLP 替代 Transformer 为 74.32。这些是整体模型及结构替代的证据，不是“只去条件信息瓶颈、其他不变”的独立消融，因此不能把差值全归于瓶颈模块，更不能称其已因果消除捷径。 [34]

所审MCIB公开Transformer路径（固定版本）显示：条件loss对标签`squeeze`后直接计算MSE，若输入形状为[B,1]与[B]会发生跨样本广播风险；分类路径还可见融合输出与原文本x相加。**代码行已可外部复核，但真实batch形状、是否激活该路径及其与正式论文训练的对应关系仍O**，因此不能声称作者正式实验的损失已被复现证明错误。该方向的真正机制独立证据应是同参数同预算的无KL、无条件预测及双无控制，并结合受控模态置换检验决策是否真正依赖互补特征；结构消融和weighted-F1只能支持作者当前完整方法的经验效果。 [34]



图4｜跨模态研究：输入信息与验证方式。 应区分原始任务输入、辅助信息及其提供阶段，并分别通过单模态/联合输入对照、额外信息控制和有效反事实验证模态贡献与模型依赖。模态消融只能反映相应协议下的性能差异，正确的跨模态依赖仍需独立真值与受控干预。

6.6 多图、视频及更广模态的拓展

多图输入可能让反讽对象分散在连续画面之间，音视频则引入时间位置、语调和表情。MCIB（AAAI 2026 Technical，CCF-A）提供文/音/视反讽正式实验，不能与静态图文Meme方法的F1直接排行。MMSD3.0（CVPR 2026 Main，CCF-A）已正式出版多图反讽基准及CIRM模型，官方摘要提到Dual-Stage Bridge与Relevance-Guided Fusion；但本项目目前**仅完成出版页和摘要级核验**，未逐表审计其训练GT、控制实验或独立模块收益，所以本章仅将其作为已有多图任务与方法先例，不以摘要推断跨图因果关系已经被验证。 [34][30]

更广模态的共通难题是“证据是否位于该模态、何时被模型读取”。视频帧抽样或语音转写可能丢失反讽发生的时刻；多图模型即使输出正确类别，也可能只利用其中一张图或文字选项。若要称跨模态组合式理解，应提供同一样本的局部时间／图像干预和新的人工语义判断，而不只是在每个数据集各报一个总体Accuracy。这一实验设计属于综述判断，现有工作尚未共同完成可直接比较的统一协议。 [23][30][34]

6.7 从多模态语义到联合风险

本章展示了意义层的多种可测目标：修辞识别、源／目标域、图文蕴含、对象、意图与解释。它们与规范性风险可能有关联，但现有任务并没有证明“正确理解隐喻就会正确判危害”的单向机制。V-FLUTE 的蕴含真值不包含安全政策；M3UCD 和 MGMCF 的冒犯属性也不能自动转化为“单图安全、单文安全、组合危险”的三条件金标。反过来，一个风险分类器输出正确标签，也不说明它准确恢复了反讽对象。[22][33][32]

第七章因此换用规范性输入风险与行为响应作为评价对象，并要求标明单模态和联合输入的各自真值。本章的图4与表5审计语义证据和辅助信息，第七章的图5与表6则审计风险标签、显式预测及安全输出。两章共享模态依赖问题，不能共享未定义的“理解正确率”。

7 多模态联合风险理解与安全响应

7.1 联合风险的任务定义

第六章的非字面意义判断以修辞或蕴含关系为目标；安全研究还需回答某一图文请求在给定政策、受众和环境下是否构成风险。设图像为 I、文字为 T、可见情境为 C，可以分别要求人或评审者判断图像、文字与联合输入的风险等级；也可以要求模型直接生成回应。前者属于 T4 输入危害判定，其中强调模态组合依赖的协议构成 T5；后者是相邻的 T6 安全响应。图文同时出现并不自动满足 T5：危险可能已由文字单独给出，也可能由视觉情境解除文字表面风险。严格的 Safe–Safe–Unsafe（S-S-U）仅指图与文分别安全、联合危险的一个更窄子类。 [36][37]

为了防止指标偷换，本章分开记录四层。第一层 G_{in} 是依据明确政策或人工标注得到的输入风险真值；第二层 P_{in} 是模型**实际显式输出**的风险类别，只有接口要求模型分类时才可观察；第三层 R_{beh} 是拒答、警示、执行或转向安全建议等响应行为；第四层 Q_{out} 评价输出是否安全且是否帮助合法用户。危险输入上拒答率升高不必然等于风险分类召回升高，安全输入上的误拒也不等于输入分类误报。对没有显式分类步骤的生成模型，不应从最终一句拒答反推其内部一定判断了 Unsafe。 [36][38][27]

典型联合关系不只“两个安全部分组成危险整体”。同一请求在图中出现特定实体或环境时可能升级，图像也可表明危险词语处于否定、教学或非现实语境，从而降低风险；另有图片单独已经含明显危险信号，文字只是指令化。要判断组合**改变**了标签，必须为同一政策下的单模态与联合条件建立可比较的真值，并

区分人类“无法单独判断”和政策上的 Borderline；VLSU 中 Borderline 是安全等级，而非标注概率。[36][37][27]

7.2 图文安全数据、视觉泄漏与版本边界

Hateful Memes [39]使图文组合成为有害内容检测的重要基准，但普通 Meme 的联合分类标签不能自动证明每个样本均属严格 S-S-U。本项目目前只将该篇作为官方出版与任务背景，不从摘要级材料杜撰其细节或复现成绩。VLSBench [25]转向视觉安全信息泄漏：若文本或其他捷径已足以触发拒答／危险回答，加入图像后的安全表现可能误导对视觉依据的判断。其主要评测对象是生成回应的拒答、警示和不安全行为；不能直接当作独立的三条件输入风险金标。 [39][25]

MMSafeAware [27]直接让MLLM预测联合图文Safe/Unsafe：论文有Unsafe1000条及Over-Safety500条，并以图、文字、联合三向人审筛除不合构建条件的候选，但当前公开仓库不含完整逐例三条件人工投票。此前发布材料提示编号、图像和重复文件的口径可能不一致；因本轮未固定该发布状态及计数方法，撤去过细整数，仅保留版本待核（O）。不能由文件状态推定作者正式评测使用的样本或图像数。在正式2:1类别比例下，恒判Unsafe即可获66.67%总Accuracy，必须报告危险侧召回、安全侧召回或Balanced Accuracy。 [27]

VLSU [36]以图像、文字、图文联合三个条件分别标Safe/Borderline/Unsafe。正式PDF报告8187条、15风险类、17种组合；此前项目读取的公开CSV为8159条，差28条原因未明。严格S-S-U在论文Figure9为37条、所查公开版35条，属于较小的test-only子集，不能把其他风险升级模式都称为S-S-U。三条件人审强度也不同：图像单独标签由一名经验作者给出，文字/联合多由3人、少量2人标注；因此三标签是任务操作性共识，不等于对每对图片做过相同标准的严格单因素反事实实验。正式PDF写17模型而官方摘要曾写11，版本差异仍留OPEN。 [36]

VLSU的Safety Understanding要求显式风险标签，而Safety Alignment自由生成回答后评审拒答与帮助性。其Table1为兼容旧基准采用独立二**分类提示**并把Borderline→Safe，不能与正式三分类F1直接换算。正式论文第8页Figure5的图内标题明确为**Qwen2.5-VL-32B**；33.8%是**该模型joint三分类已经预测错误的集合**中image-only与text-only均预测正确的占比。图注说明其按错误类型拆分联合错误，正文§5亦以全部joint错误作为分母；不是17个模型汇总，也非全库8187/8159或严格S-S-U的37/35条。附录E.3在第38页引出扩展分析，第39页Figure18按模型分别画图，不能把示例33.8%读成全部模型统一百分比；该现象是预测条件统计，不能单凭它定位内部推理的因果缺陷。所查公开CSV另有141条image_grade=not_sure，在三条件组合模式统计时需说明排除/映射，不意味着仅评joint时所有这些记录均被丢弃。 [36]

Multimodal Situational Safety [37]把活动请求放入视觉环境，MSSBench 论文报告 1,960 个图文对，区分显式安全判断诊断和是否遵循／拒绝的行为评估。同一句请求配不同场景图的 Chat 部分适合讨论视觉条件；Embodied 部分不一定严格只改图像。其 IF Judge 对回答模式评分，并非直接读取模型内部风险分类；给模型 Oracle 环境状态也提高了可用信息预算。SIUO [26]观察表面安全的跨模态输入引发不安全输出，主要是行为对齐挑战，不能并入 VLSU 的人工输入三等级真值。 [37][26]

多模态安全研究既包括输入风险分类，也包括生成回应和攻击行为。表6：多模态风险真值、响应行为与指标将两类评价对象分开呈现，并保留真值与版本差异。

表6｜多模态风险与安全回应：输入识别和输出行为分开评价

A. 输入风险真值与显式风险判断

研究与任务	输入真值与标注协议	模型预测或训练目标	证据边界
Hateful Memes [39]	图文仇恨二分类标签；不是图像Safe、文本Safe、联合Unsafe的三条件GT。	研究重点为图文联合分类。	普通图文仇恨分类基准不能被整体称为严格S-S-U数据。
MMSafeAware [27]	作者报告Unsafe 1,000、Over-Safe 500及三向人工筛选；发布版文件和图像差异尚未固定。	联合Safe/Unsafe分类。	2:1比例下恒判Unsafe的总Accuracy已达66.67%；应同时报告Unsafe召回与Safe召回，不能只报总准确率。发布版精细数量仍为待核。
VLSU输入分类 [36]	正式PDF报告8,187条、17个模型；官方摘要写11个模型；所查公开CSV为8,159条；严格S-S-U分别为37/35条。三类标签为Safe、Borderline、Unsafe。	显式三级输入风险分类；Table 1为兼容旧基准另设二分类，并将Borderline并入Safe。	正式PDF、摘要和公开CSV版本口径不同；不能把二分类结果与正式三级结果直接换算。公开CSV另有141条image_grade=not_sure。
CrossGuard输入Guard [24]	1,616条Guard混合训练数据，联合类约占12.5%（约202条为估算）；ImpForge另有1,390条红队样本，尚未逐例映射。	使用LoRA/SFT训练图文Safe/Unsafe Guard。	SIUO中Guard ASR报告60.33→5.39%，但训练数据量与类别构成也发生变化；不能把全部收益归因于新分类架构。FigStep为0.12→0.21，并非所有基准都单调改善。
ThinkingGuard输入风险归因 [41]	作者报告TriggerBench共5,600条，Safe/Unsafe各2,800；图片分别生成，配对不等于只改变Trigger。	风险标签和五步分析；SA-MCTS离线搜索轨迹，Trajectory-DPO与Step-DPO更新模型。	作者Table 3的Unsafe F1由0.779升至0.810，Recall由0.699升至0.749；额外Unsafe监督、训练token和配对图像的单因素有效性尚未独立控制。作者称ACM MM 2026录用，会议CCF-A，正式Track仍待核。

B. 生成式回应、攻击行为与回应质量

研究与任务	输入或触发条件	实际观察的回应与指标	不能混同的内容
VLSBench回应评测 [25]	比较模型面对图文风险、仅文本或附加图像描述时的回应。	Safe Rate按Refusal+Warning统计；Qwen2-VL-7B特定200例中，text为29.5%、text+image description为22.5%、image+text为16.0%。	这些是回应比例，不是输入风险分类准确率；必须说明提示、模型和样本分母。
VLSU安全回应提示 [36]	同一模型和请求，将推理提示从Harmless改为Helpful。	Gemini-1.5的Borderline拒答62.4%→10.4%，Unsafe拒答90.8%→53.9%；QwenVL-32B的Borderline拒答23.4%→30.7%，Unsafe拒答71.2%→57.5%。	这是回应策略变化，不是显式输入分类P_{in}的变化；模型间趋势并不一致。
MSSBench情境回应 [37]	1,960个图文情境请求；Chat与Embodied设置的行动能力不同。	IF Judge评价情境行动或回答；部分设置可额外提供Oracle环境状态。	Oracle环境事实改变了信息预算；Judge评分不是模型内部风险分类标签。
MOSSBench过度拒答 [38]	作者目标安全图文请求300条；约9%的人工判断对能否安全作答存在争议。	安全主集上的ARR为拒答比例；危险对照可另行测量。	安全侧误拒不是输入分类FPR；发布版contrast配对和ID映射未完全固定，不能把全部样本称为严格单因素配对。
SIUO攻击回应 [26]	表面安全的跨模态输入可能诱导模型给出危险回复；不提供VLSU式三条件人审输入GT。	输出Safe Rate或攻击成功率，包含人工与AI辅助构造子集及Judge参考信息；NAACL 2025 Findings，会议CCF-B，非Main。	行为攻击评测不能并入输入风险三分类准确率；Judge、参考安全警示及样本构造方式必须单独说明。
ImpForge红队生成 [24]	生成隐晦联合攻击图文，PPO优化文本改写器并结合图像生成。	观察被测模型是否产生不安全回应，即攻击成功率。	攻击成功率不是Guard漏检率；PPO必要性仍需与同预算检索、Best-of-N等控制比较。
Meerkat-VL安全有用回应 [35]	训练材料包含user_intent、harmful_intent和safety_warning等规范风险说明。	Cold-start SFT、同Actor NPSV评分、一致性惩罚DPCA及GRPO优化安全且有帮助的回答。	训练评分使用风险文本，但不重新读取原图；不等于独立视觉验证。模型Judge与帮助性评价应分别报告。

表注。 输入风险真值、显式风险分类、实际回应行为和输出安全/帮助性质量是不同评价对象。危险输入上的漏判、安全输入上的误报、不安全帮助和正常请求误拒应分别报告。不同论文中的ASR可能分别指攻击得逞、Guard漏检或生成危险回复，必须同时给出主体、Judge和分母。S-S-U只是严格联合风险的一个子类。

7.3 检测器、触发归因与反事实训练

在明确输入风险标签之后，方法研究才可分析哪种图文关系触发风险。CrossGuard [24]包含两种不同学习对象：ImpForge固定视觉场景，使用PPO改写有害请求以生成**红队攻击图文**；随后CrossGuard使用LLaVA基座及LoRA/SFT从混合Safe/Unsafe数据训练**输入Guard**。论文Figure6的ImpForge **1390条**属于生成攻击评测集，Figure7的**1616条**是Guard混合训练集，其中联合隐含恶意类占约**12.5%≈202条**（比例近似推算，不是作者公布精确202条ID）。当前无逐样本索引证据证明这约202条究竟是1390中的哪部分，也不能说1390条全部进入1616训练集。

作者Figure4将有无ImpForge联合类训练数据对照：SIUO防护ASR **60.33→5.39%**、MM-SafetyBench **10.20→0.38%**，但FigStep **0.12→0.21%**小幅变差，因而可说部分联合隐含防护基准显著改善，不能说所有基准都单调改善。新增数据数量/类别比例也变了，不能将全部收益归因于PPO本

身或新检测架构。该文在线被测MLLM可能依据拒答模板判危险输出，离线生成模型用GPT裁判，Guard则由输入Safe/Unsafe漏判计算指标；**攻击生成的ASR、Guard的输入漏检以及回应的危险输出ASR不是同一统计对象**，不能不注明分母与Judge便做直接性能排名。 [24]

在同一段“解释—检测”方法谱系中，**ExPO-HM（ICLR 2026 Main，CCF-A）**[47]直接研究图文Hateful Meme的解释后分类，GT是二元仇恨与细粒度攻击类别，**不是**VLSU的逐例图、文各Safe而联合Unsafe三标签。其Policy Manual辅助SFT之后，作者用课程GRPO和条件决策熵（CDE）奖励训练解释后分类；在Hateful Memes上的binary macro-F1，朴素GRPO为74.5，完整配置为81.1，但强直接检测RA-HMD已有80.2，边际仅约+0.9个百分点。这说明额外结构化政策监督及后训练组合可改善作者协议下的检测和解释指标，尚不能把全部差距独立归因于CDE，也不能由决策低熵推断解释真正参与了预测。它需要与SMARTER的标签条件DPO、ThinkingGuard的步骤DPO、Meerkat-VL的回应对齐分开比较Y、训练先验与评价对象。 [47][19][41][35]

ThinkingGuard [41]在同一模型内组合风险标签预测与结构化归因。作者报告TriggerBench共有5600条图文实例（Unsafe与Safe各2800），用同index/文字形成配对，但Safe/Unsafe图片**分别生成**，不能据共文本和文件配对认定只改变触发元素E_T。SA-MCTS离线搜索五阶段轨迹时可获知构造时的关键实体/Trigger教师字段，随后Trajectory-DPO及Step-DPO改变部署模型参数，推理时模型直接输出分析和风险标签。其Table3报告去Step-DPO时Unsafe F1为0.779、Recall为0.699，完整配置为0.810/0.749，即分别增加3.1/5.0个百分点；然而额外Step偏好对集中于Unsafe、也增加训练token与类别权重，未有同预算额外Trajectory或Unsafe重采样消融，不能独立证明逐步解释的因果忠实性。还需要按pair隔离数据及逐图人审Key保持/Trigger变化/生成纹理干扰。 [41]

ThinkingGuard 的出版状态须单独说明：作者仓库与研究组称其获 ACM MM 2026 接收并给出 DOI，ACM MM 会议在项目采用目录中属 CCF-A；截至本稿日期，尚未独立取得 ACM 出版社最终条目和论文实际 Track。因此本文仅用作已公开的直接竞争研究先例，不将其列为“已核 ACM MM Main 正式论文”，也不凭作者标注 Oral 推断 Track。对其 SA-MCTS 奖励提示、配对反事实的单因素程度和 Step-DPO 等预算效应，保持开放状态。 [41]

CrossGuard 与 ThinkingGuard 已分别推进防护训练和触发因素归因，故“构建联合风险配对”“让模型解释危险所在”本身不能写作无人研究。尚需的实验证据是：在同一对人工复标的图文上，固定模型和训练预算，置换一**个**关键因素后输入风险真值与显式预测是否同步变化，并排除图像生成纹理、文本模板及对象类别泄漏。分类 F1、风险分析文本和反事实敏感性应分别报告。 [24][41]

7.4 安全响应与过度拒答

输入风险预测正确也不能唯一规定回答策略。MOSSBench（ICLR 2025 Main，CCF-A）[38]以300条作者目标为安全可答的图文请求测过度拒绝（ARR），但有约9%的人审认为无法在不产生有害内容的情况下安全回答，说明“全部毫无争议的安全GT”不成立。公开有害contrast与安全主集的逐ID映射和发布版数量本轮未固定，故不保留精确映射数；目前无证据把全部主集视为严格只变单因素的反事实。删图可能移除风险环境事实，因此低拒答不一定意味着更好地理解视觉语义；ARR属于回应行为，不等于输入误报率。 [38]

Meerkat-VL（ICML 2026 Main，CCF-A）[35]把目标从输入类别转向安全且有帮助的回答。Cold-start SFT先使VLM输出风险感知分析及答复；训练自评分NPSV由**同一个Actor**依据先前生成的推理/回答以及训练用规范性risk文本（user_intent、harmful_intent、safety_warning）产生多个维度的质量分，在Meerkat-VL公开评分函数（固定版本）中可以看到，该评分函数重用先前回答和风险说明并将其tokenize为文本，**不在该函数中重新提供图像张量**；是否实际用于正式论文报告的训练配置仍O。DPCA

把分析与回答的安全/帮助评分差异作为一致性惩罚，最终通过GRPO更新；一致性值为零只代表分数吻合，不能保证视觉事实或规范判断正确。作者报告综合回复安全/帮助改善，但本项目没有独立核完正式ICML论文的逐项基线/消融数字；因此只能把独立NPSV、DPCA与额外风险知识的贡献列为待同预算对照，不冒称自验证是独立重新看图。 [35]

VLSU（ICLR 2026，CCF-A）的同模型行为提示提供具体**安全—帮助性双侧权衡**：对Gemini-1.5仅把推理时提示从Harmless换到Helpful，Borderline输入上的拒答率由62.4%降至10.4%，但Unsafe输入拒答率也由90.8%降至53.9%。这不是SFT/PPO重训练，也不是风险分类F1变化；前者提示过度拒绝可能降低，后者提醒危险请求的拒绝同样下降，不能只挑有利一侧解读。与MOSSBench的正常请求误拒和Meerkat-VL的训练后回应一起看，研究问题应是能否在相同模型/政策/Judge下改善两侧，而不能把异构数据集拼成统一Pareto曲线。 [36][38][35]

VLSU 的拒答／帮助性实验、MSSBench 的情境行动、MOSSBench 的正常请求误拒和 Meerkat-VL 的安全回应，分别对响应链的不同层施压。SIUO 的攻击成功率关注危险输出，MMSafeAware 的危险召回关注输入判别。即使数字看似都以百分比报告，拒答率、ASR、分类 F1 和安全回复率也不能换算为同一个“安全性能”。尤其不能把高拒答率视作模型已经识别图文组合的风险来源。 [36][37][38][27][35][26]



图5｜多模态安全评价：风险判断与回应行为。 输入风险分类依据外部风险真值评价模型显式预测；生成式安全回应则考察实际行为及输出的安全性与帮助性。危险请求的风险漏判和不安全帮助、正常请求的分类误报和不必要拒答应分别报告，不能通过拒答与否倒推模型的内部风险判断。

7.5 正负两侧评价与失败归因

安全系统的失败有两面。在输入分类协议中，危险样本被判 Safe 是漏检，安全样本被判 Unsafe 是误报；在回应协议中，危险请求收到可执行有害帮助与正常请求被拒绝是不同错误。前两者依赖 G_{in} 与显式 P_{in}，后两者依赖 R_{beh}、Q_{out} 和相应人工或评审器标准。一个方法可降低危险侧漏检，却扩大安全侧误拒；若只报总 Accuracy 或总拒答率，这种代价会被类别比例遮盖。MMSafeAware 的 2:1 设计、MOSSBench 的安全主集和 VLSU 对 Safe／Borderline／Unsafe 的分组，正好说明需要同时呈现条件分母、两侧召回与策略质量。 [27][38][36]

失败归因也须受控。文本单独模型的错误不必然意味着图像“不可替代”，因为图片可能含 OCR 或模型未被训练处理白图；图像置换后的标签如果未经人工复标，沿用原联合金标会把无效反事实当成模型错误。VLSBench 的视觉泄漏诊断、VLSU 的单模态与联合标注、ThinkingGuard 的配对触发、MSSBench 的同请求换场景图，分别提供了可借鉴的控制环节，却各有数据构造和指标限制。测试图像缺失、近重复、生成模板、评审器提示词和不确定标注也应随分数一并公开。 [25][36][41][37]

因此，第七章可得的稳妥结论是：联合模态风险及安全回应已拥有多个直接研究方案，但现有证据尚不能用一个拒答或分类指标证明模型同时具有正确的风险感知、忠实归因与安全有用的行为。第八章将把这类证据链与前面语用、编码、修辞和文本危害研究并列，讨论信息预算、Ground Truth 与干预设计如何决定跨任务比较的可信范围。 [24][36][35]

8 方法族与评价可靠性的横向综合

前文分别讨论了语用含意、修辞表达、编码语言、隐晦有害内容以及多模态意义与安全。尽管这些研究常被共同归入“隐含理解”，它们并不解决同一个预测问题：判断一句话是否使用隐喻、解释某个暗语在当前语境中的意义、识别图文联合形成的风险，以及决定模型应如何回应，所需信息和正确答案均不相同。因此，横向比较的重点不应是为所有方法排出统一名次，而应是理解不同技术路线如何利用语境与外部知识、怎样形成预测，以及现有实验究竟支持了何种能力主张。

8.1 从规则推断到大模型后训练：不同方法在解决什么问题

早期和相邻研究常通过明确的语义假设收缩解释空间。概率语用模型将说话者的表达选择与听者的意义推断联系起来；$(RSA)^2$进一步引入修辞策略，使非字面意义能够在给定候选集合中获得概率支持。编码语言研究也可以从先验知识出发：Silent Signals在已知狗哨词及其定义的条件下判断某次使用是否表达编码义，FETCH!则利用种子词典寻找尚未收录的相关词项。这些方法的优势是输入条件与预测对象较为明确，便于追踪错误来自语境解释还是候选选择；局限则是模型能够回答的问题部分取决于研究者预先提供了什么。已知词义的实例消歧、既定词典内的词项回收与真正开放的新义发现，不能因为都涉及暗语而被视作同一任务。[3][4][5]

监督学习把语境理解转化为可训练的表征和判别边界。对比学习通过正负样本关系约束表示，域适应利用源域标注与目标域可见信息减少分布差异，多任务学习则借助情绪、意图、源域—目标域概念或相关标签提供辅助监督。ImpCon、FA-Net与CADET分别体现了隐含陈述配对、目标域适应和显隐表达风格迁移的不同思路；在多模态研究中，MGMCF、M3UCD与DOSE进一步通过对象级交互、共享参数或任务专家协调不同语义线索。这类研究说明，适当组织监督信号通常比仅依靠通用编码器更适合特定数据集，但表示相近、模块消融有效或分类得分提高，并不自动说明模型恢复了唯一正确的交际意图。[18][31][40][32][33][23]

大语言模型使另一种路线成为可能：模型可以在推理时接受候选解释、调用检索工具、生成理由，或在训练时利用带有解释与规范知识的样本。SeTox将网络搜索用于动态中文词义与毒性判断，解决静态训练知识可能滞后的问题；SMARTER与ExPO-HM通过不同形式的解释监督或偏好优化改进有害内容分类；ThinkingGuard把风险分析轨迹用于输入风险识别与归因，而Meerkat-VL进一步优化模型面对风险请求时的安全且有帮助的回答。这里虽然都出现了监督微调、偏好优化或强化学习，但**更新的是不同能力**：有的学习选择含义，有的学习区分有害输入，有的学习如何回答。把这些方法简单归为“推理增强”或“安全对齐”会掩盖它们真正改变的预测目标。[16][19][47][41][35]

多模态模型又增加了一层困难：图像、文字和声音不仅各自提供特征，还可能通过组合改变表达的意义。多模态融合方法试图在局部对象、全局场景与语言信息之间建立联系；信息瓶颈方法则尝试抑制与目标无关或易形成捷径的特征。MCIB是后一方向的代表，其完整系统报告了反讽分类性能提升，但现有消融尚未把条件信息瓶颈损失的独立作用与细粒度特征及融合结构充分分离。由此可以看到，**方法设计动机、整体模型效果和关键机制得到验证，是三个应当区分的层次**。[34]

表7：跨子域方法族、优化对象与证据边界汇总上述研究的实际优化对象和可支持的结论。表中方法之间并非简单替代关系：明确先验的模型便于控制意义空间，监督学习擅长利用既有标签，检索适合引入变化中的社群知识，多模态融合处理信息之间的相互作用，而后训练使分类与生成行为受到更直接的目标约束。选择方法时首先需要明确研究问题，而不是预设某一种技术能够同时解决所有隐晦信息任务。

8.1.1 三项跨研究方向的综合认识

第一，已有知识决定了模型能力能够被测量到什么程度。 在给定候选解释的语用推断中，模型取得高分可能说明它善于根据上下文从若干答案中选择，而未必能够独立提出这些解释。$(RSA)^2$的意义先验消融显示，候选意义的先验分布会显著影响正确解释获得的概率。与之类似，FETCH!的词项发现建立在已提供部分词典及明确回收范围的基础上；Silent Signals预先给出编码词和定义，SeTox则允许模型检索外部语境。这些研究都具有价值，却测量了不同程度的“开放性”。因此，对动态词义与隐含意义的研究，至少应区别已知表达的实例消歧、给定候选范围内的发现，以及不预先限定词项与意义的开放解释。前两类表现良好并不能直接推导出第三类能力。[3][5][4][16]

第二，生成解释有时有助于预测，但解释的作用取决于它如何获得和使用。 DRInQ在同一400题困难子集上比较普通提示与先解释再选择：GPT-5-Mini的准确率由0.56升至0.62，而Claude Sonnet 4.5由0.65降至0.62。VAGUE在部分视觉行动选择实验中也观察到解释提示的正负变化。这意味着让模型“多想一步”并不是跨模型稳定有效的操作。另一方面，SMARTER和ExPO-HM把解释、标签或政策约束纳入训练目标，与测试时临时要求生成理由并非同一种干预；ExPO-HM的完整训练结果也不能脱离其政策监督、课程安排和奖励设计，独立归功于“解释”二字。预测分数的变化可以说明解释相关训练或提示对任务有影响，却尚不能证明模型所写理由真实构成了其决策依据。[8][29][19][47]

第三，总体改进可能伴随不同样本群体之间的错误转移。 在$(RSA)^2$的修辞策略实验中，策略条件有助于反讽样本获得较高的正确意义概率，却可能使字面样本的解释变得过度复杂。多模态安全评测中的类似警示更为直观：VLSU报告，同一Gemini-1.5模型将指令从侧重无害性调整为侧重帮助性后，Borderline请求的拒答率由62.4%降至10.4%，但Unsafe请求的拒答率也由90.8%降至53.9%。前者涉及候选意义概率，后者涉及输出拒答行为，不能将两组指标直接换算，也不能据此认定模型内部具有相同机制。可以从中提出的共同评价要求是：任何旨在减少“过度理解”“过度拦截”或“漏检”的方法，都应同时观察互补子群是否承受新的错误代价。[3][36]

这三项认识并非新的普遍定律。它们提示我们，隐晦信息研究中的性能变化通常同时涉及候选空间、监督方式和决策取舍；若忽略这些条件，便容易把特定实验协议下的优势误读为通用理解能力。

8.2 输入信息与监督条件：性能提升究竟来自哪里

不同研究看似都将文本或图文输入模型，实际能够使用的信息却可能相差很大。模型可能只接收原始表达，也可能额外获得词典释义、上下文摘要、源域与目标域概念、情绪标签、检索结果，甚至来自人工或教师模型的规范性风险说明。对于这些资源，关键区别不在于它们是否“辅助”，而在于**它们从何而来、在什么时候提供，以及真实使用场景中能否取得**。

以多模态隐喻检测为例，情绪与概念线索可能帮助模型确定映射关系，但需要区分模型自己从图文中预测出的线索、训练阶段使用的人工标签，以及测试阶段直接提供的标签。MultiMM的一个已审公开代码路径会读取测试样本中的情绪字段；由于该路径与正式论文各项实验的对应关系尚未完全核实，只能把它视为需要控制输入条件的实例，不能据此断言论文所有结果均依赖测试真值。同理，MGMCF使用源域与目标域概念等辅助信息，其性能应结合这些字段的来源解释。将提供额外语义信息的系统与仅接收原始图文的系统直接比较，难以分清收益来自表示学习还是更充分的输入。[15][32]

检索与跨域学习也存在类似区别。FA-Net利用目标域未标注文本，因而其跨域设置不同于完全不可接触目标域资料的零样本迁移；SeTox借助实时搜索获得新词线索，评价结果会受到搜索语料、查询时间和返回材料质量的影响。检索增强的优势恰恰在于引入外部知识，不应为了强调模型能力而隐去这一点。更合理的比较是分别报告不使用外部知识、使用自动获得的辅助信息以及使用人工确认信息时的表现，从而回答“外部知识能带来什么收益”和“模型自身能够恢复多少信息”这两个不同的问题。[31][16]

训练监督也需要以相同原则理解。更多任务标签、解释文本、教师评分或偏好样本能够改善训练信号，但同时改变了模型接触的信息量。因而，结构模块的消融回答的是“去掉这一模块后完整系统如何变化”，未必回答“该模块提出的理论机制是否独立成立”。对于MCIB，尤其需要在保持输入、编码器与训练预算相近的条件下区分条件压缩、辅助预测和细粒度融合的贡献；对于含有多阶段优化的安全模型，则应区分新增监督数据、奖励设计和训练时长的影响。严谨的比较不要求每篇论文使用完全相同的资源，而是要求结论与实际可用资源相匹配。[34][47][35]

8.3 从表达标签到交际意义：什么才算正确答案

隐晦信息研究中的一个根本困难是：同一句话可以拥有明确的表达形式，却不存在不依赖语境、受众与任务的唯一解释。检测到隐喻并不等于确定其所指对象；识别出编码词并不等于判断其本次使用必然具有攻击意图；判断某段话有害，又需要额外考虑目标群体、说话者立场以及具体规范。因而，“正确答案”首先由研究任务和标注过程定义，而不是由“隐晦信息”这一总称统一赋予。

语用研究通常把理解操作化为给定语境下的候选含义选择，或让人工评价某种解释是否得到上下文支持。DRInQ通过保持问句形式不变而改变情境，检验模型能否随语境选择不同的含意。编码语言研究则可能标注词项是否属于编码表达、某次出现是否使用编码义，或者表达实际指向哪一对象。隐晦有害内容检测又进一步引入攻击对象、冒犯程度或规范性危害类别。这些标签都能提供可重复的实验目标，但不能无条件相互替代。尤其是由模型生成再经筛选的解释，与自然交流中说话者不可直接观察的心理意图，并不具有相同的证据地位。[8][4][7][2]

语境与社群知识还使标注分歧成为研究对象，而不只是数据清洗时应消除的噪声。AUTALIC考察真实话语环境中的含混与攻击性判断，提醒我们同一表达可能因引用、群体内部使用或反用而获得不同解释。多数票可以产生可训练的操作性标签，却不会自动消除少数合理解释，更不能代替独立验证说话者意图。因此，涉及较强社会语境的研究应当说明标注者看到的上下文、所依据的规范、争议如何处理，以及模型在争议样本上的表现。若数据仅标注隐喻形式，便不能把检测成绩直接作为模型识别“隐喻所承载的非人化意图”的充分证据。[6][21]

解释生成还需要与解释可靠性区分。V-FLUTE的参考解释匹配、M3UCD的概念相关输出、SMARTER的标签—解释偏好，分别评价可观察的文本或训练目标；这些设计能够促使模型产生更符合标注要求的解释，但解释合理不等于解释真实反映了预测时使用的证据。要进一步讨论解释是否参与决策，必须检查改变解释所依赖的关键事实是否相应改变预测，同时避免让干预顺带改变标签或引入不自然输入。这样，研究才能从“模型会解释”推进到“解释与模型判断之间存在可以验证的关系”。[22][33][19]

8.4 多模态融合的核心问题：相关信息是否被正确利用

对于图文、音视频等多模态任务，融合更多特征并不必然意味着获得了真正的联合理解。一方面，单一模态可能已经包含足以预测标签的线索：图片中的文字可被OCR提取，配文模板可能暗示类别，背景和人物属性也可能与训练标签偶然相关。另一方面，一些隐含意义确实只有在模态关系中才会出现，例如文字与画面相互反转形成反讽，或原本普通的文字因具体场景而表达新的交际功能。前者会使模型借助捷径取得不错的分数，后者才要求研究者检验模态之间的互补关系。[25][22][34]

因此，多模态方法至少需要区分三种不同结论。**联合模型优于某个单模态基线**，说明融合配置在该测试集上更有效；**移除或替换某个模态会改变预测**，说明模型对该输入敏感；只有在替换前后的正确含义或风险标签也经过可靠确认时，才可以进一步判断这种敏感性是否对应合理的跨模态依赖。将图片换成白图、将文本置空，可能同时造成输入分布变化，不能把由此出现的性能下降全部归因于“理解了图片”。VLSBench对视觉信息泄漏的分析、VLSU对单模态与联合安全条件的区分，以及ThinkingGuard的触发配对，分别提供了诊断思路，但它们的标注目标和配对强度并不一致。[25][36][41]

从评价设计上看，最有解释力的不是“图像是否影响答案”，而是“在其他相关条件尽量相同的情况下，图像中的哪一项事实改变了应有答案”。若要考察图文组合带来的新风险，便需要核实原图、原文及其组合各自的风险依据；若改动图像还改变了人物、环境或行为背景，则应重新确认标签，而非沿用原样本的真值。严格的Safe–Safe–Unsafe组合只是联合风险的一种特殊情况，也不能拿普通图文有害分类的结果充当其验证。[36][37]

同样重要的是，模态依赖不应只在同一语料分布中成立。编码词会随社群和时间改变，图文素材可能存在跨划分的近重复，来源不同的多模态数据还可能在OCR质量、语言分布和图像风格上形成系统性差异。跨域实验应明确究竟改变了哪些条件：新词、新社群、新时间段、新图像来源，还是仅改变了训练样本的表达风格。只有区分这些变化，模型在某一迁移设置下的成绩才可能支持相应的泛化主张。[5][16][40][15]

8.5 从风险识别到安全回应：不能用一个分数概括安全性

隐晦有害内容检测与安全回应在应用中紧密相连，但评价对象不同。输入风险识别关心模型能否根据内容与语境判断某项请求是否有害；生成式安全回应关心模型实际给出了怎样的回答，以及该回答是否符合安全要求、是否对合理请求提供必要帮助。前者的错误包括危险输入漏判和正常输入误判，后者则包括对危险请求提供不安全帮助，以及对正当请求不必要地拒绝。这四种现象不能简单用一个“安全率”代替。[36][38][35]

VLSU将Safe、Borderline和Unsafe分开评估，显示安全策略不仅涉及是否拦截明确危险内容，还涉及如何处理边界情形。前述Gemini-1.5提示实验表明，减少边界请求拒答有可能伴随危险请求拒答下降；但另一个模型可能出现不同趋势，不能将一次提示调整概括为所有模型共有的安全—帮助性规律。MOSSBench主要暴露正常请求上的过度拒答问题，Meerkat-VL则研究如何训练模型作出安全且有帮助的回应。它们共同说明，安全性的评价至少需要分别保留危险侧与正常侧，而不能将“更经常拒绝”直接等同于“更懂风险”。[36][38][35]

这一区分还关系到实验指标的解释。Guard把图文判断为Safe或Unsafe，其分类错误应依据输入标注衡量；红队方法观察目标模型是否产生不安全回应，测量的是攻击结果；安全对齐方法还可能通过人工或模型评审回应的帮助性。CrossGuard同时涉及攻击样本生成与Guard训练，但攻击成功率、Guard漏检率和最终回答质量属于不同实验对象。若把这些数值并列为同一种“ASR”或“安全准确率”，很容易得出错误的性能排序。可靠的安全实验需要说明是谁作出判断、判断依据是什么，以及分数的统计单位是输入、配对样本还是生成回答。[24][26][35]

在更完整的系统评价中，模型还可能正确识别风险，却采取不恰当的回应策略；或者没有输出显式风险标签，却给出符合规范的回答。因此，从最终回复倒推模型内部“已经正确识别风险”并不可靠。只有当研究同时观察输入判断与输出行为，或设计了能够独立评价二者的实验，才有可能分析风险理解与安全行动之间的关系。这种分层评价并非要求所有模型采用同一种系统架构，而是要求研究结论不超出实际观察到的行为。[25][36][35]

8.6 评价可靠性与本领域仍需解决的共同问题

对广义隐晦信息而言，可靠评价的核心不只是采用更复杂的指标，而是使实验回答的问题与研究者声称解决的问题保持一致。若研究目标是识别修辞现象，形式标签和相应分类指标可以充分服务于该目标；若要宣称理解了实例含义，则需要能够区分候选解释、语境变化和对象指向的证据；若要论证正确使用了视觉信息，应验证模态变化引起的标签变化，而不仅是预测变化；若研究目标涉及安全回应，则必须检查危险内容防护和正常请求帮助是否同时得到满足。不同层级的证据各有价值，但不能相互代替。

现有文献也提示了三类值得优先解决的评价困难。其一是**开放环境中的意义变化**：当词典、候选解释和外部检索提供不同程度的先验知识时，如何判断模型对从未见过的新表达具有多少自主解释能力。其二是**解释与决策的关系**：如何在不改变任务真值的情况下检验模型生成的理由确实影响判断，而不是事后补写。其三是**跨模态与安全决策的有效归因**：当图文组合、策略提示和背景知识同时变化时，如何识别导致错误的实际因素，并判断某一改进是否以另一组样本的性能下降为代价。上述问题已有多个直接研究先例，未来工作的价值在于提供更清晰的实验区分，而非重新宣称这些问题无人提出。[5][8][34][25][36]

由此，本综述认为，推动该领域发展的关键不在于建立一个覆盖所有任务的统一排行榜，而在于使研究对象、可用信息、标注依据与模型行为形成可追溯的对应关系。当研究者明确“模型被要求理解什么”“获得了什么线索”“预测为何被判正确”以及“在哪些条件下仍会失败”时，语用、修辞、编码语言与多模态安全之间的技术经验才更有可能被可靠迁移。这也为下一章从具体方法进展转向未来研究方向提供了基础。

9 总结与展望

9.1 研究进展与主要认识

隐晦信息的计算理解，核心难点并不只是表达中缺少某个显式词语，而在于话语意义往往需要由表达形式、交际语境和共享知识共同确定。间接请求可以不改变句子的字面形式而改变其交际作用，隐喻与反讽通过概念映射或语境反差传递非字面意义，社群编码又使同一表达在不同受众之间形成解释差异。在多模态场景中，图像、文字与声音之间的关系还可能改变信息的指向和意义。本文以这些相互关联、但并不具有统一生成机制的现象为研究范围，梳理了从语用与修辞理解、编码语言分析到隐晦有害内容检测和多模态安全研究的主要进展。

现有研究的重要进展之一，是逐渐将笼统的“理解隐含意义”分解为具有明确预测目标的计算任务。表达识别回答某种修辞或编码现象是否出现，意义解释尝试恢复具体语境中的含义，交际功能推断进一步关注话语所实现的请求、评价或行动；有害性判断则需要额外考虑攻击对象、说话者立场及适用规范。在此基础上，多模态联合风险判断与生成式安全回应形成了各自独立的评价对象。相关数据集和评测方法使这些问题得以被系统研究，但不同任务的标签并不等价：识别出隐喻，不意味着已经理解其指向；恢复了编码意义，也不意味着能够据此判断其是否有害。语用推理、隐式仇恨和多模态风险等研究共同表明，只有明确“模型究竟需要判断什么”，性能结果才具有可解释的学术含义。[1][8][2][36]

在方法层面，研究者已探索概率语用建模、监督与对比学习、跨域适应、外部检索、多模态融合以及基于偏好优化的模型训练等不同路径。这些方法并非依次取代的技术阶段，而是针对不同任务约束和信息条件形成的解决方案。例如，概率语用方法可以在已知候选意义的条件下刻画解释选择，基于种子词典的方法可以扩大编码词项的搜索范围，检索增强模型可以在推理时利用不断更新的语境知识，多模态模型则尝试结合不同信息来源完成意义判断。已有结果说明这些路径各具价值，同时也揭示了一个共同限制：模型表现不仅取决于架构，还受到候选集合、训练监督、推理时可用知识及数据构造方式的影响。因此，在给定词典或辅助标注下取得的良好结果，不能不加区分地解释为对未知表达的开放理解能力。[3][5][16][33]

多模态研究进一步凸显了“利用多个模态”与“理解模态之间的意义关系”之间的差别。图文联合输入可能包含只有组合后才显现的含义或风险，也可能存在文字提前泄露视觉信息、模型依赖单一模态线索等情况。多模态融合结构的性能改善、人工标注的模态贡献类别，以及同一模型在单模态与联合输入下的预测变化，分别提供不同性质的证据，尚不能相互替代。与此同时，安全研究已经从单纯识别有害输入，延伸到模型应如何回应复杂请求：正确判断输入风险、避免产生有害回答，以及对正常请求提供有效帮助，是相互关联但不能混为一谈的目标。[25][22][36][38][35]

基于上述研究的横向比较，本文形成三点相互关联的认识。首先，隐含意义的可测范围受到词典、候选意义及外部知识的影响，评价开放语义能力必须说明这些先验是否已经提供给模型。其次，解释生成和解释监督能够在一些实验条件下改善预测，但解释的合理性、标签一致性与其是否真实反映决策依据，是需要分别检验的问题。最后，安全策略的调整可能改变模型对不同风险程度请求的回应倾向，局部或总体指标的改善未必意味着危险请求与正常请求上的表现同步提高。这些认识源于不同任务中的相关实验与对照，其价值在于指出值得进一步验证的共性问题，而非宣称不同领域已被证明遵循同一种内在机制。[3][5][47][36]

9.2 未来研究方向

更充分的语境建模与开放语义理解，仍是广义隐晦信息研究的基础问题。现有方法往往借助预设候选意义、已有词典或特定领域的训练数据，将原本开放的意义推断转化为相对可控的预测任务。然而，真实交流中的语义会随事件、社群、文化背景和时间变化；同一表达既可能具有普通用法，也可能在局部语境中承担隐喻、反讽或编码功能。未来研究需要更加重视从具体实例恢复意义的能力，并区分已知词项的语境消歧、已有词典之外的表达发现，以及真实时间变化下的新义形成。相应的评价应控制词项、社群和时间上的信息重叠，考察模型能否在缺少预设答案的情况下利用可靠语境证据形成解释，而不仅是完成固定候选集合内的选择。[4][5][16]

从现象标签走向更可靠的意义与意图评价，是提升研究解释力的另一关键。隐喻类别、源域与目标域、会话含意、说话者立场及规范性危害，虽然可能出现在同一段话语中，却对应不同的标注判断。将某一现象标签直接作为意义理解或有害性的替代依据，容易使模型学会数据集的表面关联，而难以揭示实际理解能力。未来的数据与评价设计应更清楚地区分表达形式、实例意义、交际功能和规范性判断，记录必要的上下文及标注者之间的合理分歧。对于多义、引用、戏仿或社会规范存在争议的样本，保留解释条件和分歧信息，比简单压缩为一个缺乏说明的二元标签更有助于分析模型错误及其适用范围。[7][6][33]

多模态语义依赖的识别与验证，有望成为连接非字面意义理解和内容安全研究的重要方向。未来方法不仅需要从图像、文字和音视频中提取有效特征，还应能够判断哪些信息由单一模态充分提供，哪些意义真正依赖模态之间的关系。为此，评价应在可比条件下区分仅文本、仅图像和联合输入，明确图中可转写文字、额外检索内容与人工辅助标签的来源；对于通过图文替换或情境变化构造的反事实样本，还需要重新核对变化后的实际含义和风险标签。只有在排除文本泄漏、额外信息优势及无关视觉变化之后，才能对模型是否正确利用跨模态证据作出更有说服力的判断。[22][25][36][41]

面向可验证推理的解释方法，值得在语用、修辞和安全任务之间开展进一步研究。自然语言解释能够帮助研究者观察模型如何描述其判断依据，也可以作为训练时的辅助监督；但一段与正确标签一致的解释，仍可能只是模型在预测之后生成的合理叙述。未来需要结合解释中的关键证据定位、受控信息干预及独立的人类判断，区分解释是否正确、是否充分，以及其变化是否实际影响模型决策。对于使用政策说明、教师推理轨迹或偏好数据训练的模型，还应考察性能提升来自额外监督信息、模型优化策略，还是更准确的证据利用。这类研究不仅关系到解释的可信度，也关系到隐晦内容检测系统在复杂场景下的可分析性和可纠错性。[22][19][47][41]

兼顾风险识别与正常交互的安全评价，则是隐晦信息研究走向实际应用时不可回避的议题。模型既可能因忽视语境或跨模态关系而漏判有害请求，也可能因过度依赖表面敏感线索而拒绝正常的讨论、引用或求助。未来研究应将输入风险判断与生成式回应评价分开，在明确的政策条件下同时考察危险内容的识别能力、正常请求的误拒情况，以及回答的安全性与帮助性；对于边界性和存在标注争议的案例，还需要分析不同规范阈值如何影响系统表现。这种双侧评价并不要求将不同数据集的指标合成为一个分数，而是促使研究者更准确地认识安全防护与正常交互之间的实际关系。[36][38][35]

总体而言，广义隐晦信息研究正在形成从表达现象识别、具体语境中的意义解释，到社会规范下的风险判断与安全回应的多层次研究格局。其进一步发展，不仅取决于更强的语言与多模态模型，也取决于研究问题能否被准确界定、语境知识能否被有效利用，以及实验结果能否支持关于模型能力的实质性结论。沿着语境化、开放性、跨模态证据验证与可靠安全评价等方向持续推进，有助于使隐晦信息研究从特定数据集上的预测，进一步走向对复杂真实交际情境的可信理解。

表7｜跨子域方法族：优化对象、直接证据与未闭合问题

方法族	代表研究（正式出处与CCF等级）	方法实际改变什么	现有证据与关键边界
概率语用推断	$(RSA)^2$（ACL 2025 Main，CCF-A）	在给定候选意义、语境和修辞策略下，建模说话者/听者的概率推断；不依赖新增类别微调。	正式实验显示修辞策略和意义先验会改变候选意义概率；这支持候选空间内的概率推断，不等于开放式释义或真实心理意图读取。
提示式含意与行动选择	DRInQ（ACL 2026 Main，CCF-A）；VAGUE（ICCV 2025 Main，CCF-A）	冻结LLM/MLLM，通过上下文示例、解释提示或CoT完成候选含意/行动选择。	部分模型因解释提示而提升，另一些模型下降或不变；提示收益不具有跨模型单调性，也不证明解释忠实。
编码词项与检索辅助	Silent Signals（ACL 2024 Main，CCF-A）；FETCH!（ACL 2025 Main，CCF-A）；FA-Net（AAAI 2024 Technical，CCF-A）；SeTox（ACL 2026 Main，CCF-A）	分别使用已知编码义、种子词典、固定目标类别或在线检索；其预测单位包括实例义、词项类型、候选目标义和毒性标签。	证明不同先验可支持各自定义任务；不能把它们合称为统一开放词义发现，也不能横排Precision、Acc@k和毒性F1。
监督表示学习与多模态融合	ImpCon（COLING 2022 Main，会议CCF-B）；MGMCF（AAAI 2025 Technical，CCF-A）；M3UCD（AAAI 2026 Technical，CCF-A）；MultiMM（ACL 2025 Main，CCF-A）；DOSE（ACL 2026 Main，CCF-A）	使用对比学习、多任务标签、源/目标概念、情绪辅助、共享/私有LoRA或任务专家，改变表示和融合方式。	作者报告了各自协议下的性能收益，也有负迁移和额外监督；结构消融或人工模态归属不能单独证明因果机制或模态必要性。
信息瓶颈与条件压缩	MCIB（AAAI 2026 Technical，CCF-A）	将条件预测、KL压缩与多模态表示结合，用于音视频文本反讽分类。	完整配置报告weighted-F1=75.64；现有消融未单独隔离CIB损失。公开Transformer实现还存在潜在维度广播风险及原始文本残差路径，正式run对应关系仍未核实。
解释与轨迹偏好优化	SMARTER（ACL 2026 Main，CCF-A）；ExPO-HM（ICLR 2026，CCF-A）；ThinkingGuard（ACM MM 2026，会议CCF-A，正式Track待核）	分别使用标签—解释DPO、政策SFT+课程GRPO+CDE，以及离线SA-MCTS轨迹与Step-DPO；优化目标分别是毒性分类、仇恨Meme解释后检测和输入风险归因。	作者报告的性能收益来自不同监督对象与训练协议；额外教师信息、gold标签、Unsafe偏好和token预算尚未完全匹配，不能把收益统一归因于解释或逐步推理。
红队攻击生成与输入Guard	ImpForge/CrossGuard（ACL 2026 Main，CCF-A）	ImpForge用PPO优化隐晦攻击改写；CrossGuard用LoRA/SFT训练图文Safe/Unsafe Guard。	攻击成功率、Guard漏检率和生成模型危险回应率是不同指标；训练数据量与类别组成也会影响结果，不能把全部提升归因于分类架构。
安全回应对齐与行为评价	Meerkat-VL（ICML 2026 Main，CCF-A）；VLSU（ICLR 2026，CCF-A）	Meerkat-VL通过SFT和GRPO优化安全且有帮助的回答；VLSU的Harmless/Helpful提示实验则在冻结模型上比较回应策略，不更新参数。	回应安全性、帮助性和拒答行为可发生不同方向变化；它们不等同于显式输入风险分类，也不能据拒答率反推模型内部风险判断。

表注。本表按方法实际优化对象归纳，不构成跨任务排行榜。各论文的具体数据、指标和GT见表3–表6；第8.1.1节C1–C3负责跨子域条件性综合，本表不重复其全部数字。CCF等级按项目采用的2026年第七版目录口径；Findings、Technical、Main和作者录用但正式Track未核的状态分别标明，不以会议整体等级替代论文Track信息。

附录A 代表性研究的任务设定与评价协议

广义隐晦信息研究涉及多种彼此关联、但不能直接等同的评价任务。本附录选取正文中具有代表性的研究，进一步说明它们的样本构成、预测对象和标注依据，以便读者在阅读第3—7章的结果时理解具体分数所衡量的能力。以下介绍旨在补充主要任务和方法比较，而非重新罗列所有数据集，也不将不同论文的标签统一改写成某一种“隐晦程度”。

A.1 语境变化与非字面意义的评价

语用含意研究的关键是，同一句话在不同情境中可能表达不同的交际目的。DRInQ通过保持表面问句不变、改变对话情境的方式构造问题，让模型从五个候选解释中选择与当前情境相符的含义。这种设计能够减少模型只凭问句形式进行判断的可能性。其评价结果反映的是模型在给定候选答案与人工认可情境下的解释选择能力，而不是不借助候选项自由恢复说话者内心意图的能力。论文另构造困难测试子集，其成绩不能不加说明地解释为自然对话总体表现。[8]

VAGUE将类似问题拓展至视觉语境：相同或相近的间接表达可能因为画面中的人物、物体和情境不同而对应不同的行动意图。与仅判断文本是否具有隐含意义不同，这类评价要求模型把视觉事实与话语联系起来。由于DRInQ的正确答案属于语境下的候选含意，而VAGUE着重于视觉情境中的行动或意图选择，两者即使都使用多选准确率，也不能简单比较数值高低。共同值得关注的是：当词面基本不变时，模型能否随语境证据作出有根据的判断。[29]

对修辞表达而言，“识别现象”和“解释含义”也应分别评估。隐喻或反讽分类可以依据形式标签判断模型是否识别了某种表达；要求进一步解释时，则需要考察解释与语境、对象及说话者立场之间的对应关系。形式分类正确并不确保解释正确，解释流畅亦不意味着模型真实利用了相应语境证据。不同研究若只共享“隐喻”“反讽”等现象名称，却使用不同的输出目标，就不构成同一评价任务。[11][10]

A.2 编码表达的词项发现、实例消歧与风险判断

编码语言研究中，首先应区分研究对象是一个表达形式，还是这个表达在某次使用中的具体含义。Silent Signals以已知的狗哨表达及其编码定义为基础，结合上下文判断一个实例是否使用了该编码义。同一词项可能在部分场景中具有普通意义，因此预先知道某个表达能够被编码使用，并不足以确定其每次出现都属于编码表达。这里的主要评价单位是具体使用实例，而非新词项的发现数量。[4]

FETCH!研究的重点转向词项层面的寻找：研究者先提供部分参考词典，再利用相关语料和检索策略发现尚未纳入已知种子集合的表达。其评价依赖给定的参考词表、已出现于语料中的词项范围，以及预测候选的去重与匹配规则。因此，词项回收能力与实例语境中的用义消歧是两个不同的评价目标；从既有参考范围中成功回收词项，也不能直接等同于发现完全未知、尚无人工释义的新社群表达。[5]

进一步的有害性判断还需要额外的标注目标。CodedLang涉及中文编码片段及编码方式的识别，SeTox则利用检索语境判断动态中文新词的毒性。即便模型能够成功发现某个编码表达，仍需要考虑该表达在当前语境中的对象、立场和有害性，才能判断是否存在内容安全风险。尤其在允许外部搜索的设置下，模型的结果也与可检索材料的覆盖范围和时间条件有关。因而，词项发现率、实例消歧准确率与毒性分类表现，应分别在各自标签和样本单位上报告。[7][16]

A.3 语境化有害内容的标注对象与分歧

隐晦有害内容的标签不仅涉及语言形式，还涉及针对对象、立场和社会规范。Latent Hatred等研究将不含明显攻击词的仇恨表达及其隐含陈述纳入评价，为模型识别间接攻击提供了研究基础；然而，数据集中的隐含陈述属于特定标注与生成协议所获得的解释，并非对真实说话者全部心理意图的直接观察。[17]

真实语境可能进一步改变人们对同一表达的判断。AUTALIC关注社群语境中的含混与冒犯性，说明引文、群体内部称呼以及反用等情况会影响表达如何被理解。该研究采用多名标注者的判断来建立可使用的标签，同时也揭示人类判断的不一致。对于此类语料，评价时有必要区分单个标注者的理解、通过聚合产生的最终标签，以及模型输出与聚合标签是否相符。多数票可以提供清晰的训练目标，却不能保证每个争议样本只存在一种合理解释。[6]

非人化与隐喻的关系尤其需要审慎解释。When People Are Floods研究移民相关话语中的隐喻，其正式标注对象主要是隐喻现象或源域；这种证据可以用于讨论某些表达如何以概念映射描述群体，却不能直接替代对非人化意图或仇恨性质的独立逐例标注。一个数据集是否适合评价特定社会危害，取决于它实际提供了哪些人工标签，而不是研究者能否从例子中推断潜在风险。[9]

A.4 多模态意义、联合风险与回应行为

多模态任务首先要明确什么信息构成模型的原始输入，以及需要输出哪一种判断。V-FLUTE围绕图文关系与解释开展评价，关注模型能否判断给定视觉与语言信息之间的关系，并为该判断提供文本解释。M3UCD则进一步涉及隐喻、源域—目标域和交际属性等多个相关目标。后者的辅助标签和人为区分的模态贡献类型，有助于分析可能的语义线索，却不等于已经通过单因素干预证明图像对于每个实例的预测都不可替代。[22][33]

图文联合风险的标注目标与一般图文有害分类有所区别。Hateful Memes以联合输入的仇恨类别为主要评价目标，但不能据此认为每个样本均具有“图像单独安全、文本单独安全、两者组合有害”的三个独立真值。VLSU明确区分Safe、Borderline和Unsafe，并对单模态及联合模态条件进行分析，其中严格的Safe–Safe–Unsafe只是较窄的一类。若研究声称模型识别了仅由组合产生的风险，就应核对是否具备可比较的单模态与联合标注，而不能从普通图文分类准确率直接推导这一结论。[39][36]

最后，风险分类与模型回应也应保留各自的评价对象。MOSSBench侧重考察模型对正常图文请求的不必要拒绝，Meerkat-VL则研究安全且有帮助的生成式回应。对于前者，样本是否属于可以正常完成的请求，是解释拒答率的必要条件；对于后者，还需要评价实际生成内容的安全性与帮助性。它们不同于显式输入风险分类中的漏检率或误报率。将这些协议分开，才能理解某一模型究竟是在识别风险、执行回应策略，还是在两者之间进行权衡。[38][35]

综上，跨领域比较时应回到每项研究实际设置的评价单位、可见语境、预测目标与标注依据。相似的模型结构或指标名称，并不意味着这些实验在衡量相同的隐含理解能力。上述差异构成正文讨论方法有效性、跨模态依赖和安全可靠性的基本前提。

附录B 文献检索、选择与综述方法

B.1 综述定位与文献范围

本文采用批判性叙述综述的方式，围绕“表达为何需要超出字面信息的理解，以及模型如何检测、解释或应对此类信息”组织相关研究。文献范围涵盖计算语用学、修辞与非字面语言理解、社群编码与动态词义、语境化有害内容检测、多模态意义理解，以及与上述问题直接相关的模型安全回应。不同方向的纳入依据是共同的研究问题，而非将其中任一方向视为其他方向的子集。既有计算语用、修辞和有害内容综述为这一范围的设定提供了基础；本文的重点在于跨任务比较其方法假设、监督条件和评价对象，而非重复单一领域的研究清单。[1][50][28]

文献选择以2024—2026年的相关正式研究为主要时间范围，同时保留对研究背景、经典理论与代表性基准不可或缺的更早工作。例如，会话含意和言语行为的经典理论用于交代语用解释的基础，较早的隐式仇恨和图文仇恨数据集则用于说明现有评价目标的形成。时间范围并不作为机械的排除条件，评价对象和研究贡献的相关性更为重要。[44][48][2][39]

B.2 检索来源与主题组合

主要检索和出版信息核对围绕ACL Anthology、AAAI官方论文平台、CVF Open Access、ICLR Proceedings等正式出版入口展开，并针对相关工作扩展至PMLR、ACM及其他出版平台。针对语用与非字面意义，重点使用implicature、pragmatics、speech acts、metaphor、sarcasm、rhetorical questions等术语；针对编码语言与词义变化，结合dog whistle、coded language、euphemism、slang及中文谐音与形音变体等表达；针对有害内容与安全，使用implicit hate、contextual toxicity、multimodal safety、situational safety、visual leakage、over-refusal等概念开展定向检索。为避免某一研究方向因关键词差异而被遗漏，还结合已有核心论文的参考文献及相关综述进行主题补充。

文献收集与核验并非一次性完成：已有研究资料先按任务归类，再针对语用含意、编码语言动态变化、多模态语义与情境安全等覆盖不足的方向进行补充。所用检索策略以相关性和代表性为导向，没有对全部出版数据库执行统一的可穷尽查询。因此，本文不以检索命中数、筛选淘汰数或PRISMA流程图声称已经完成系统性穷尽检索，也不把所收录文献数量解释为各子领域的真实研究规模。

B.3 纳入原则与证据使用

核心文献的纳入主要考虑三点：研究是否对隐含意义的识别、解释或应用提供直接问题定义；是否提出具有可识别输入、输出和实验比较的方法或基准；是否有助于解释相邻任务间的联系与差异。针对多模态安全等邻近方向，只有当工作实质涉及组合语义、情境风险、输入判定或安全回应时，才将其纳入相关讨论。一般的显式毒性分类、通用视觉识别、传统隐写和宽泛安全对齐研究，除非对上述问题具有明确的理论或方法关联，否则不构成本文的核心对象。

发表状态与方法证据分别判断。对于已经正式出版的工作，优先依据出版版论文、附录和正式书目信息叙述任务定义与实验结果；对于尚未取得正式出版信息的工作，保留其预印本或作者报告身份，不将录用声明等同于正式出版事实。会议整体的CCF等级也不能代替对具体Main、Technical、Findings或其他Track的核对。对于可获取的公开代码与数据，仅在能够对应具体发布版本时用于解释实现细节或数据口径；公开仓库中某个函数的行为，不自动证明论文报告的模型由相同版本、相同入口训练或评估。

在跨论文比较中，本文优先讨论具有相近预测目标和评价条件的实验；当论文采用不同输入信息、标注定义或评审方法时，着重分析差异产生的含义，而不是直接比较最终分数。对解释忠实性、因果模态依赖及安全一帮助性权衡等较强主张，本文区分论文实际展示的结果与基于多项工作提出的综合判断，不把结构消融、模型生成的解释或风险拒答率当作这些机制已经被完整证明的证据。

B.4 覆盖边界与研究局限

本文的文献选取受到主题划分、出版平台可检索性和公开材料可得性的影响。部分新近成果可能缺少稳定的出版条目或可访问数据；不同研究的原始代码、辅助标签和正式实验配置也并非总能逐项对应。尤其在快速发展的多模态安全领域，预印本、正式版、摘要与数据发布版本可能采用不同的统计口径。本文据可核实的版本说明相关结论，未解决的资料差异不被自行补齐，也不被直接解释为原研究存在错误。

因此，本综述的目标是提供覆盖主要研究问题的批判性综合，而不是对领域全部论文进行无遗漏的系统评价或定量元分析。本文所呈现的技术发展方向与开放问题，应理解为在当前可获得证据范围内形成的分析性认识；对方法优先权、普适性能和因果机制的更强判断，仍需要后续针对性的原始研究与可重复实验。

参考文献

[1] Ma, Bolei; Li, Yuting; Zhou, Wei; Gong, Ziwei; Liu, Yang Janet; Jasinskaja, Katja; Friedrich, Annemarie; Hirschberg, Julia; Kreuter, Frauke; Plank, Barbara. (2025). Pragmatics in the era of large language models: A survey on datasets, evaluation, opportunities and challenges. *Proceedings of the 63rd annual meeting of the Association for Computational Linguistics (volume 1: Long papers)*, 8679–8696. Association for Computational Linguistics. DOI: 10.18653/v1/2025.acl-long.425

[2] Hartvigsen, Thomas; Gabriel, Saadia; Palangi, Hamid; Sap, Maarten; Ray, Dipankar; Kamar, Ece. (2022). ToxiGen: A large-scale machine-generated dataset for adversarial and implicit hate speech detection. *Proceedings of the 60th annual meeting of the Association for Computational Linguistics (volume 1: Long papers)*, 3309–3326. Association for Computational Linguistics. DOI: 10.18653/v1/2022.acl-long.234

[3] Spinoso-Di Piano, Cesare; Austin, David Eric; Piantanida, Pablo; Cheung, Jackie CK. (2025). $(RSA)^2$: A rhetorical-strategy-aware rational speech act framework for figurative language understanding. *Proceedings of the 63rd annual meeting of the association for computational linguistics (volume 1: Long papers)*, 20898–20938. Association for Computational Linguistics. DOI: 10.18653/v1/2025.acl-long.1019

[4] Kruk, Julia; Marchini, Michela; Magu, Rijul; Ziems, Caleb; Muchlinski, David; Yang, Diyi. (2024). Silent signals, loud impact: LLMs for word-sense disambiguation of coded dog whistles. *Proceedings of the 62nd annual meeting of the association for computational linguistics (volume 1: Long papers)*, 12493–12509. Association for Computational Linguistics. DOI: 10.18653/v1/2024.acl-long.675

[5] Sasse, Kuleen; Aguirre, Carlos Alejandro; Cachola, Isabel; Levy, Sharon; Dredze, Mark. (2025). Making FETCH! Happen: Finding emergent dog whistles through common habitats. *Proceedings of the 63rd annual meeting of the association for computational linguistics (volume 1: Long papers)*, 5687–5709. Association for Computational Linguistics. DOI: 10.18653/v1/2025.acl-long.284

[6] Rizvi, Naba et al. (2025). AUTALIC: A dataset for anti-AUTistic ableist language in context. *Proceedings of the 63rd annual meeting of the association for computational linguistics (volume 1: Long papers)*, 20999–21015. Association for Computational Linguistics. DOI: 10.18653/v1/2025.acl-long.1022

[7] Wan, Ruyuan; Li, Changye; Huang, Ting-Hao Kenneth. (2026). “Newspaper eat” means “not tasty”: A taxonomy and benchmark for coded language in real-world Chinese online reviews. *Proceedings of the 64th annual meeting of the Association for Computational Linguistics (volume 1: Long papers)*, 9433–9446. Association for Computational Linguistics. DOI: 10.18653/v1/2026.acl-long.426

[8] Arai, Hirona Jacqueline; Ren, Xiang. (2026). DRInQ: Evaluating conversational implicature with controlled context variation. *Proceedings of the 64th annual meeting of the Association for Computational Linguistics (volume 1: Long papers)*, 34594–34611. Association for Computational Linguistics. DOI: 10.18653/v1/2026.acl-long.1597

[9] Mendelsohn, Julia; Budak, Ceren. (2025). When people are floods: Analyzing dehumanizing metaphors in immigration discourse with large language models. *Proceedings of the 63rd annual meeting of the association for computational linguistics (volume 1: Long papers)*, 8079–8103. Association for Computational Linguistics. DOI: 10.18653/v1/2025.acl-long.398

[10] Mahato, Priyanshu; Mishra, Aniket Santosh; Ghosh, Kripabandhu. (2026). LLMs in sarcasm detection? It’s elementary! (Or is it?). *Proceedings of the 64th annual meeting of the Association for Computational Linguistics (volume 1: Long papers)*, 29169–29199. Association for Computational Linguistics. DOI: 10.18653/v1/2026.acl-long.1346

[11] Liu, Yang; Li, Hongming; Qin, Melissa Xiaohui; Huang, Chao; Liu, Qiankun. (2026). Revisiting a pain in the neck: A semantic reasoning benchmark for language models. *Proceedings of the 64th annual meeting of the Association for Computational Linguistics (volume 1: Long papers)*, 4595–4618. Association for Computational Linguistics. DOI: 10.18653/v1/2026.acl-long.210

[12] Zheng, Li; Wang, Sihang; Fei, Hao; Peng, Zuquan; Li, Fei; Fu, Jianming; Teng, Chong; Ji, Donghong. (2025). Enhancing hyperbole and metaphor detection with their bidirectional dynamic interaction and emotion knowledge. *Proceedings of the 63rd annual meeting of the association for computational linguistics (volume 1: Long papers)*, 489–499. Association for Computational Linguistics. DOI: 10.18653/v1/2025.acl-long.23

[13] Zhang, Yuwei; Singh, Siffi; Sengupta, Sailik; Shalyminov, Igor; Su, Hang; Song, Hwanjun; Mansour, Saab. (2024). Can your model tell a negation from an implicature? Unravelling challenges with intent encoders. *Proceedings of the 62nd annual meeting of the association for computational linguistics (volume 1: Long papers)*, 552–567. Association for Computational Linguistics. DOI: 10.18653/v1/2024.acl-long.33

[14] Yao, Louie Hong; Anand, Vishesh; Zhuang, Yuan; Jiang, Tianyu. (2026). Rhetorical questions in LLM representations: A linear probing study. *Proceedings of the 64th annual meeting of the Association for Computational Linguistics (volume 1: Long papers)*, 155–172. Association for Computational Linguistics. DOI: 10.18653/v1/2026.acl-long.5

[15] Yang, Senqi; Zhang, Dongyu; Ren, Jing; Xu, Ziqi; Zhang, Xiuzhen; Song, Yiliao; Lin, Hongfei; Xia, Feng. (2025). Cultural bias matters: A cross-cultural benchmark dataset and sentiment-enriched model for understanding multimodal metaphors. *Proceedings of the 63rd annual meeting of the association for computational linguistics (volume 1: Long papers)*, 26301–26317. Association for Computational Linguistics. DOI: 10.18653/v1/2025.acl-long.1275

[16] Cui, Shiyao; Zhang, QingLin; Wang, Di; Lu, Yida; Zhang, Zhexin; Gao, Jinhua; Yang, Jinglin; He, Min; Qiu, Han; Huang, Minlie. (2026). New terms, new toxicity: Consensus-based Chinese neologism toxicity detection via search-augmented LLMs. *Proceedings of the 64th annual meeting of the Association for Computational Linguistics (volume 1: Long papers)*, 34683–34701. Association for Computational Linguistics. DOI: 10.18653/v1/2026.acl-long.1602

[17] ElSherief, Mai; Ziems, Caleb; Muchlinski, David; Anupindi, Vaishnavi; Seybolt, Jordyn; De Choudhury, Munmun; Yang, Diyi. (2021). Latent hatred: A benchmark for understanding implicit hate speech. *Proceedings of the 2021 conference on empirical methods in natural language processing*, 345–363. Association for Computational Linguistics. DOI: 10.18653/v1/2021.emnlp-main.29

[18] Kim, Youngwook; Park, Shinwoo; Han, Yo-Sub. (2022). Generalizable implicit hate speech detection using contrastive learning. *Proceedings of the 29th international conference on computational linguistics*, 6667–6679. International Committee on Computational Linguistics. URL: https://aclanthology.org/2022.coling-1.579/

[19] Nghiem, Huy; Sachdeva, Advik; Daumé III, Hal. (2026). SMARTER: A data-efficient framework to improve toxicity detection with explanation via self-augmenting large language models. *Proceedings of the 64th annual meeting of the Association for Computational Linguistics (volume 1: Long papers)*, 34306–34332. Association for Computational Linguistics. DOI: 10.18653/v1/2026.acl-long.1584

[20] Lee, Yejin; An, Hyeseon; Han, Yo-Sub. (2026). RV-HATE: Reinforced multi-module voting for implicit hate speech detection. *Proceedings of the 64th annual meeting of the Association for Computational Linguistics (volume 1: Long papers)*, 45364–45383. Association for Computational Linguistics. DOI: 10.18653/v1/2026.acl-long.2104

[21] Zeng, Jingjie; Yang, Liang; Wang, Zekun; Sun, Yuanyuan; Lin, Hongfei. (2025). Sheep’s skin, wolf’s deeds: Are LLMs ready for metaphorical implicit hate speech? *Proceedings of the 63rd annual meeting of the Association for Computational Linguistics (volume 1: Long papers)*, 16657–16677. Association for Computational Linguistics. DOI: 10.18653/v1/2025.acl-long.814

[22] Saakyan, Arkadiy; Kulkarni, Shreyas; Chakrabarty, Tuhin; Muresan, Smaranda. (2025). Understanding figurative meaning through explainable visual entailment. *Proceedings of the 2025 conference of the nations of the Americas chapter of the Association for Computational Linguistics: Human language technologies (volume 1: Long papers)*, 1–23. Association for Computational Linguistics. DOI: 10.18653/v1/2025.naacl-long.1

[23] Guo, Diandian; Cao, Cong; Yuan, Fangfang; Xu, Pin; Hu, Cheng; Zhang, Zhicheng; Liu, Yu; Liu, Yanbing. (2026). Two streams, one sarcasm: Orthogonal expert tuning for holistic multimodal sarcasm understanding. *Proceedings of the 64th annual meeting of the Association for Computational Linguistics (volume 1: Long papers)*, 7054–7072. Association for Computational Linguistics. DOI: 10.18653/v1/2026.acl-long.319

[24] Zhang, Xu; Li, Hao; Lu, Zhichao. (2026). CrossGuard: Safeguarding MLLMs against joint-modal implicit malicious attacks. *Proceedings of the 64th annual meeting of the Association for Computational Linguistics (volume 1: Long papers)*, 25693–25707. Association for Computational Linguistics. DOI: 10.18653/v1/2026.acl-long.1178

[25] Hu, Xuhao; Liu, Dongrui; Li, Hao; Huang, Xuanjing; Shao, Jing. (2025). VLSBench: Unveiling visual leakage in multimodal safety. *Proceedings of the 63rd annual meeting of the Association for Computational Linguistics (volume 1: Long papers)*, 8285–8316. Association for Computational Linguistics. DOI: 10.18653/v1/2025.acl-long.405

[26] Wang, Siyin; Ye, Xingsong; Cheng, Qinyuan; Duan, Junwen; Li, Shimin; Fu, Jinlan; Qiu, Xipeng; Huang, Xuanjing. (2025). Safe inputs but unsafe output: Benchmarking cross-modality safety alignment of large vision-language models. *Findings of the Association for Computational Linguistics: NAACL 2025*, 3563–3605. Association for Computational Linguistics. DOI: 10.18653/v1/2025.findings-naacl.198

[27] Wang, Wenxuan; Liu, Xiaoyuan; Gao, Kuiyi; Huang, Jen-tse; Yuan, Youliang; He, Pinjia; Wang, Shuai; Tu, Zhaopeng. (2025). Can’t see the forest for the trees: Benchmarking multimodal safety awareness for multimodal LLMs. *Proceedings of the 63rd annual meeting of the Association for Computational Linguistics (volume 1: Long papers)*, 16993–17006. Association for Computational Linguistics. DOI: 10.18653/v1/2025.acl-long.832

[28] Hee, Ming Shan; Sharma, Shivam; Cao, Rui; Nandi, Palash; Nakov, Preslav; Chakraborty, Tanmoy; Lee, Roy Ka-Wei. (2024). Recent advances in online hate speech moderation: Multimodality and the role of large models. *Findings of the association for computational linguistics: EMNLP 2024*, 4407–4419. Association for Computational Linguistics. DOI: 10.18653/v1/2024.findings-emnlp.254

[29] Nam, Heejeong; Ahn, Jinwoo; Ka, Keummin; Chung, Jiwan; Yu, Youngjae. (2025). VAGUE: Visual contexts clarify ambiguous expressions. *Proceedings of the IEEE/CVF international conference on computer vision (ICCV)*, 1537–1547. URL: https://openaccess.thecvf.com/content/ICCV2025/html/Nam_VAGUE_Visual_Contexts_Clarify_Ambiguous_Expressions_ICCV_2025_paper.html

[30] Zhao, Haochen; Kong, Yuyao; Xu, Yongxiu; Gou, Gaopeng; Xu, Hongbo; Wang, Yubin; Zhang, Haoliang. (2026). MMSD3.0: A multi-image benchmark for real-world multimodal sarcasm detection. *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition (CVPR)*, 37885–37895. URL: https://openaccess.thecvf.com/content/CVPR2026/html/Zhao_MMSD3.0_A_Multi-Image_Benchmark_for_Real-World_Multimodal_Sarcasm_Detection_CVPR_2026_paper.html

[31] Hu, Yuxue; Li, Junsong; Wu, Mingmin; Huang, Zhongqiang; Chen, Gang; Sha, Ying. (2024). Uncovering and mitigating the hidden chasm: A study on the text-text domain gap in euphemism identification. *Proceedings of the AAAI Conference on Artificial Intelligence*, 38((16):18270–18278. DOI: 10.1609/aaai.v38i16.29786

[32] Zheng, Li; Fei, Hao; Dai, Ting; Peng, Zuquan; Li, Fei; Ma, Huisheng; Teng, Chong; Ji, Donghong. (2025). Multi-granular multimodal clue fusion for meme understanding. *Proceedings of the AAAI Conference on Artificial Intelligence*, 39((24):26057–26065. DOI: 10.1609/aaai.v39i24.34801

[33] Zheng, Tianlong; Yang, Yating; Dong, Rui; Ma, Bo; Wang, Lei; Zhou, Xi; Miao, Siru; Osman, Turghun. (2026). M3UCD: A multi-task multimodal metaphor understanding challenge dataset for LLMs. *Proceedings of the AAAI Conference on Artificial Intelligence*, 40((41):35030–35040. DOI: 10.1609/aaai.v40i41.40808

[34] Wang, Yihua; Jia, Qi; Xu, Cong; Chen, Feiyu; Liu, Yuhan; Zhang, Haotian; Jin, Liang; Liu, Lu; Wang, Zhichun. (2026). Conditional information bottleneck for multimodal fusion: Overcoming shortcut learning in sarcasm detection. *Proceedings of the AAAI Conference on Artificial Intelligence*, 40((31):26652–26660. DOI: 10.1609/aaai.v40i31.39874

[35] Zhou, Peicheng; Liu, Chuanbin; Fang, Shancheng; Pu, Bowei; Sun, Yiwei; Hu, Zhangchi; Xie, Hongtao. (2026). Meerkat-VL: Implicit risk safety alignment in multimodal LLMs via perceptual reasoning and self-verification. *Proceedings of the 43rd international conference on machine learning*, 306:165400–165449. PMLR. URL: https://proceedings.mlr.press/v306/zhou26ae.html

[36] Palaskar, Shruti; Gatys, Leon; Abdelrahman, Mona; Jacobo, Mar; Lindsey, Laurence; Moharir, Rutika; Lund, Gunnar; Xu, Yang; Shiee, Navid; Bigham, Jeffrey; Maalouf, Charles; Cheng, Joseph. (2026). VLSU: Mapping the limits of joint multimodal understanding for AI safety. *International conference on learning representations*. URL: https://proceedings.iclr.cc/paper_files/paper/2026/hash/a36e092659c42b2c92b8b0eb2394bf74-Abstract-Conference.html

[37] Zhou, Kaiwen; Liu, Chengzhi; Zhao, Xuandong; Compalas, Anderson; Song, Dawn; Wang, Xin. (2025). Multimodal situational safety. *International conference on learning representations*. URL: https://proceedings.iclr.cc/paper_files/paper/2025/hash/1cb57fcf7ff3f6d37eebae5becc9ea6d-Abstract-Conference.html

[38] Li, Xirui; Zhou, Hengguang; Wang, Ruochen; Zhou, Tianyi; Cheng, Minhao; Hsieh, Cho-Jui. (2025). Is your multimodal language model oversensitive to safe queries? *International conference on learning representations*. URL: https://proceedings.iclr.cc/paper_files/paper/2025/hash/50d4f8ff0416cedfe0771b7ad947a197-Abstract-Conference.html

[39] Kiela, Douwe; Firooz, Hamed; Mohan, Aravind; Goswami, Vedanuj; Singh, Amanpreet; Ringshia, Pratik; Testuggine, Davide. (2020). The hateful memes challenge: Detecting hate speech in multimodal memes. *Advances in neural information processing systems*, 33. URL: https://papers.nips.cc/paper/2020/hash/1b84c4cee2b8b3d823b30e2d604b1878-Abstract.html

[40] Zhao, Chengshuai; Wan, Shu; Sheth, Paras; Patwa, Karan; Candan, K. Selçuk; Liu, Huan. (2026). Causality guided representation learning for cross-style hate speech detection. *Proceedings of the ACM web conference 2026*, 1819–1829. DOI: 10.1145/3774904.3792669

[41] Zhang, Ruochen; Huang, Yao; Sun, Yitong; Xie, Jiahe; Yan, Jin; Ma, Jifan; Guo, Yuanfang; Wei, Xingxing. (2026). ThinkingGuard: Decoding implicit hazards via step-by-step risk attribution in multimodal large language models. URL: https://arxiv.org/abs/2609.36562

[42] Kühn, Ramona; Mitrovic´, Jelena; Granitzer, Michael. (2026). Computational approaches to the detection of lesser-known rhetorical figures: A systematic survey and research challenges. *ACM Computing Surveys*, 58((2). DOI: 10.1145/3744554

[43] Farabi, Shafkat; Ranasinghe, Tharindu; Kanojia, Diptesh; Kong, Yu; Zampieri, Marcos. (2024). A survey of multimodal sarcasm detection. *Proceedings of the thirty-third international joint conference on artificial intelligence*, 8020–8028. DOI: 10.24963/ijcai.2024/887

[44] Grice, H. P. (1975). Logic and conversation. *Syntax and semantics, volume 3: Speech acts*, 41–58. Academic Press

[45] Searle, John R. (1969). Speech acts: An essay in the philosophy of language. Cambridge University Press. DOI: 10.1017/CBO9781139173438

[46] Frank, Michael C.; Goodman, Noah D. (2012). Predicting pragmatic reasoning in language games. *Science*, 336((6084):998. DOI: 10.1126/science.1218633

[47] Mei, Jingbiao; Sun, Mingsheng; Chen, Jinghong; Qin, Pengda; Li, Yuhong; Chen, Da; Byrne, Bill. (2026). ExPO-HM: Learning to explain-then-detect for hateful meme detection. *The fourteenth international conference on learning representations*. URL: https://openreview.net/forum?id=bEejbORUI5

[48] Searle, John R. (1975). Indirect speech acts. *Syntax and semantics, volume 3: Speech acts*, 59–82. Academic Press

[49] Ye, Mang; Rong, Xuankun; Huang, Wenke; Du, Bo; Yu, Nenghai; Tao, Dacheng. (2025). A survey of safety on large vision-language models: Attacks, defenses and evaluations. URL: https://arxiv.org/abs/2502.14881v1

[50] Mao, Rui; Ge, Mengshi; Han, Sooji; Li, Wei; He, Kai; Zhu, Luyao; Cambria, Erik. (2025). A survey on pragmatic processing techniques. *Information Fusion*, 114:102712. DOI: 10.1016/j.inffus.2024.102712